

연구·집필 로드맵

도시의 본성

코드로 그려낸 공간의 연쇄반응

— 점과정으로 읽는 서울의 상권과 젠트리피케이션 —

작성자: yunskim · 버전: v1.5 (영화 흥행 박스 + 부록 A 신설) · 문서 성격: 책 집필 로드맵 겸 개인 연구 계획서

이 문서는 완결된 제안서가 아니라, 스스로가 길을 잃지 않기 위한 항해 지도다. 6개월마다 갱신한다.

v1.5 — 영화 흥행 분석을 본문에 박스 두 개(\$4.4 포아송의 overdispersion 박스 + \$IV.4 Cox 회귀 박스 + 그림 IV.4.1 4사분면 산점도)로 추가하고, 자세한 설계는 부록 A로 분리. "도시의 본성"이라는 책 정체성을 본문에서 유지하면서 도구의 일반성을 부록에 보존. 부록 A는 6개 소절(A.1 사각지대 / A.2 두 축 분해 / A.3 두 가지 생존분석 / A.4 4사분면 동학 / A.5 cannibalization 다변량 Hawkes / A.6 KOFIC + 후속 계획). v1.4까지의 \$4 인식론적 입문, 12개 이론적 정정, 7개 Part 구조 그대로 유지. 내용 손실 없음.

책 구조 — 목차 초안과 §번호 매핑

이 목차는 v1.2 재편의 골격이다. 책의 최종 장 번호(1~44)는 outline을 따르지만, 이 문서 내부의 본문은 v0.9에서 형성된 §번호 체계(\$1~\$8)를 유지한다. 두 번호는 아래 표로 대응된다. 책 출판 시점에 §번호를 최종 장 번호로 linear 재매핑할 예정이다.

책의 최종 장 번호 (outline)	장 제목	이 문서의 §번호 (본문 위치)
서두		
1. 서론	연구 배경	\$0 초록 + \$1 연구 배경과 문제의식
2. 문제의식	왜 이 주제인가	\$1.1~1.3 (왜 점과정·왜 젠트리피케이션·사례로서의 가로수길)

책의 최종 장 번호 (outline)	장 제목	이 문서의 §번호 (본문 위치)
3. 연구 질문	RQ, SQ1~5, PQ	§2 연구 질문
4. 수학 직관	모델은 외우는 것이 아니라 가정 에서 선택된다 (v1.4 확장)	§4 (v1.0 신설, v1.4 6개 소절로 확장)
4.0 목적	이 장의 인식론적 선언	§4.0
4.1 평균·분 산	분포에 대해 처음 묻는 두 가지	§4.1
4.2 공분산	ρ 는 "X가 1σ 움직일 때 Y의 따라 감 비율" — 산점도 4패널 (킬러 그림)	§4.2
4.3 지수 분 포	기억 없음의 약속 $\rightarrow \exp(-\lambda t)$	§4.3
4.4 포아송	독립 사건의 약속 $\rightarrow$ 평균=분산. overdispersion이 Hawkes를 부 름	§4.4
4.5 정규분 포	디스카운트가 거리에 비례 $\rightarrow$ 종 모양·가우시안 커널	§4.5
4.6 패턴 인 식	왜 모두 지수함수인가 — maximum entropy 원리 (Jaynes 1957)	§4.6
Part I 1차 라운드		§3 모델의 점진적 확장

책의 최종 장 번호 (outline)	장 제목	이 문서의 §번호 (본문 위치)
5. 1단계	스타벅스의 정적 분포 (H3 Heatmap + KDE)	§3.1 단계 1
6. 2단계	지역 간 부동산 전파 (다변량 시간 Hawkes)	§3.2 단계 2
7. 3단계	상업 상권 α 행렬 (시공간 Hawkes)	§3.3 단계 3
8. 4단계	가로수길 Blue/Red 2x2 (네트워크 커널)	§3.4 단계 4 + §3.6 단계 4 심화
9. 5단계	스타벅스 revisited (잠재 $\mu(x)$)	§3.5 단계 5
Part II 관문	과연 이 모델로 충분한가	§II (v1.0 신설)
10. 복잡성 정당화	네 심판관 개요	§II.1
11. AIC/BIC	1차 심판관 — 정보 기준	§II.2
12. Residual	2차 심판관 — Ogata residuals	§II.3
13. OOS likelihood	3차 심판관 — 홀드아웃 예측	§II.4
14. Recovery	4차 심판관 — 합성 복원	§II.5
Part III 2차 라운드	같은 문제를 더 나은 렌즈로	§III (v1.0 신설)

책의 최종 장 번호 (outline)	장 제목	이 문서의 §번호 (본문 위치)
15. 1-1	버거지수 revisited	§III.1
16. 2-1	marked Hawkes	§III.2
17. 3-1	stochastic declustering	§III.3
18. 4-1	비모수 background	§III.4
19. 5-1	nonstationary background	§III.5
Part IV 생 존분석	점포 수명으로 젠트리피케이션 읽기 — life table → KM → Cox → AG → Frailty → Cox process	§IV (v1.1 신설, v1.2 재설계)
20. 파트 구 성	도구 시퀀스와 사례(1-2 ~ 5-2) 매핑	§IV.0
21. 도입	무소식이 희소식 — 비사건의 정 보	§IV.1
22. Life table	점포 영업 기간의 이산 표 — 5 년 생존율 정책 진입점	§IV.2
23. KM ↔ 1-2	살아남은 스타벅스 — 매장 생존 지도 (킬러 그림)	§IV.3
24. Cox ↔ 3-2	스타벅스 폐점 시 다른 프랜차이 즈 — spillover 곡선	§IV.4
25. AG ↔ 2-2	아파트 거래의 침묵 — 자치구별 inter-arrival 분포	§IV.5

책의 최종 장 번호 (outline)	장 제목	이 문서의 §번호 (본문 위치)
26. Frailty ↔ 4-2	옆 점포가 살아남으면 — 공간적 frailty 지도	§IV.6
27. Cox process ↔ 5-2	버티는 힘 $\lambda_{\text{survive}}(x)$ — $\mu(x)$ 와 의 두 지도 비교 (킬러 페이지)	§IV.7
28. 한계 → V	이 단계가 대답할 수 없는 것 — Cox process + self-excitation = Cox-Hawkes	§IV.8
Part V Cox- Hawkes	외생적 배경 + 내생적 자기여기 의 결합	§3.7 (v0.6~0.7 본문) + §V 도입 (v1.1)
29. 도입	Cox와 Hawkes는 어떻게 만나는 가	§V.0 (v1.1 신설 도입부)
30. 6단계	공변량 조건부 background — Mohler 2013 계보	§3.7 서두
31. 6.1	정신을 바짝 차려야 하는 이유 (진단)	§3.7.1 진단 — 네 가지 구조적 한계
32. 6.2	base μ 와 공변량 z 의 역할 분리	§3.7.2 공변량 조건부 배경을 제안
33. 6.3	Andersen-Gill multiplicative intensity로의 등치	§V.1 (v1.1 신설) — 두 어휘의 다리
34. 6.4	선형 → 비선형 (log-linear, GAM, GP)	§3.7.4 구현 전략 · 비선형 확장 Stage 1~3

책의 최종 장 번호 (outline)	장 제목	이 문서의 §번호 (본문 위치)
35. 6.5	식별 문제는 어떻게 남는가	§3.7.4 전반 · 세 재설계 옵션 비교
36. 6.6	residual · sensitivity · simulation	§3.7.4 경감 전략 (L2, multiple starts, VIF)
Part VI 엔트로피	복잡성의 해석	§VI (v1.0 신설, v1.1 라벨 변경)
37. 도입	엔트로피는 왜 여기서 등장하는가	§VI.1
38~42	branching / interaction / regime / background entropy · 지수 연결	§VI.2 ~ §VI.6
Part VII 뒷부분		§4, §5, §6, §7, §8 (v0.9 체계 유지)
43. 방법론 메모	MLE·EM 실행 세부	§4 방법론 심화
44. 데이터 메모	LOCALDATA 파이프라인 포함	§5 데이터와 실행 가능성
(응용)	젠트리피케이션 지수 G1~G6	§6 지수 — 책에서는 Part VI과 Part VII 사이
45. 한계	한계와 자기비판	§7 한계와 열린 문제 + §4.5 방법론 한계
46. 결론	마무리 + 참고문헌	§7 후반 + §8 참고문헌
부록 A 영화 흥행	도구의 일반성 시연 — 영화 흥행을 본 연구 도구로 분석하는	부록 A.1~A.6 (v1.5 신설)

책의 최종 장 번호 (outline)	장 제목	이 문서의 §번호 (본문 위치)
	설계 (v1.5 신설)	
A.1	기존 영화 흥행 통계의 사각지대 — 누적 관객 수가 가리는 것	부록 A.1
A.2	두 축 분해 — 스크린 수 vs 스크 린당 관객 수 + 4사분면 정적 분 류	부록 A.2
A.3	두 가지 생존분석 — 강도 생존 (KM-Cox)과 공급 생존(상영 종료 hazard)	부록 A.3
A.4	4사분면 동학 — 시간에 따른 위 치 이동 궤적	부록 A.4
A.5	영화 간 cannibalization — 다변 량 Hawkes α 행렬 (§3.3과 동일 구조)	부록 A.5
A.6	KOFIC 데이터·향후 페이퍼 계획 (Stage 1~4)	부록 A.6

이 구조의 의미

이 재구성의 핵심은 $\mu(x, t)$ 와 식별 문제를 너무 이른 시점에 전면화하지 않는 것이다.

- Part I은 독자가 점과정적 사고를 자연스럽게 익히는 구간이다.
- 연구 질문 직후의 '지수감쇠 직관'을 짧게 두어, 이후 Hawkes 커널과 감쇠 구조를 따라갈 최소한의 감각을 미리 열어 둔다.

- 1단계는 복수 브랜드 전체지도를 한 번에 펼치기보다, 스타벅스라는 단일 사례로 정적 분포와 H3/KDE의 기본 직관을 먼저 익히게 한다. 버거지수는 1-1단계의 revisit로 이동.
- 5단계는 추상적 방법론 장이 아니라 '같은 스타벅스 자료를 잠재 배경을 $\mu(x)$ 의 렌즈로 다시 읽는' revisit 장으로 명확히 한다.
- Part II는 Part I의 모델들이 충분한지 심판하는 관문이다. Part III가 필요한 이유를 여기서 정당화한다.
- Part III는 stochastic declustering $\rightarrow$ 비모수 background $\rightarrow$ nonstationary μ 의 연속적 흐름으로, background와 triggered event를 점점 정교하게 분리해 간다.
- Part IV는 v1.1에서 신설된 생존분석 파트. 점포 수명을 hazard 관점에서 다루며, 자영업 폐업 연구의 표준 도구를 본 연구의 데이터에 적용한다. 독립 산출물(KM 곡선)을 가진다.
- Part V Cox-Hawkes는 Part III의 자기여기 분석과 Part IV의 hazard 분석을 둘 다 만난 독자가 비로소 자연스럽게 도달하는 결합 모델. Mohler(2013)의 multi-source clustering이 직접 계보.
- Part VI 엔트로피는 Part II의 '심판관'이 아니라, 복잡한 모델이 드러낸 구조와 불확실성의 '해석 언어'다. 앞선 모든 파트의 결과를 한 단계 위에서 요약.

§번호 체계에 대한 안내

본문을 읽으실 때:

- **§0~§8:** v0.9까지 형성된 내부 §번호. 본문 내 상호 참조('§3.6.6 참조', '§5.5 파이프라인' 등)는 모두 이 체계를 사용. 기존 참조를 깨지 않기 위함.
- **§3.6 (Blue/Red), §3.7 (공변량 조건부 μ):** 형식상 §3 하위 절이지만 분량과 무게가 큰 독립 장 수준. 책 구조에서는 §3.6이 Part I 8장(가로수길)의 본체, §3.7이 Part IV 전체에 해당.
- **§II, §III, §V:** v1.0에서 신설된 Part별 소절 번호. Part II, III, V는 통째로 신설이므로 §를 그대로 할당.

- **Part 번호(I~VI):** 책 구조상의 파트. 책 출판 시 각 장은 위 표의 '1~37'로 재라벨링 예정.

0. 초록 (One-pager)

문제의식. 도시 공간에서 일어나는 사건들 — 카페의 출점, 아파트의 거래, 자영업자의 퇴거 — 은 서로 독립이 아니다. 한 사건은 다음 사건의 확률을 높이고, 그 영향은 공간적으로 감쇠하며 시간적으로 변진다. 그러나 이런 *자기여기(self-exciting)* 성격을 명시적으로 다루는 도구는 국내 도시 연구에서 드물게 쓰인다.

접근. 점과정(point process) 계열 모델을 *가장 단순한 것에서 가장 복잡한 것으로* 순차적으로 쌓아 올린다. 각 단계는 앞 단계가 해결하지 못한 구체적인 실패를 지적함으로써 정당화된다. KDE → 시간 Hawkes → 시공간 Hawkes → 네트워크 커널 → 잠재변수 $\mu(x)$.

학술적 기여. Mohler(2011, 2014)의 self-exciting point process를 도시 공간 변화(특히 상권 변동과 젠트리피케이션)에 적용한 국내 최초 수준의 종합적 실험. 배경율을 상수가 아닌 공간적으로 변하는 잠재 함수 $\mu(x)$ 로 추정하는 EM 절차를 적용한다.

정책적 기여. 가로수길을 전범(典範)으로 하여 *젠트리피케이션 진행도 지수*를 구성한다. 이 지수는 임계치를 넘기 전에 개입이 가능한 골든타임을 식별하는 것을 목표로 한다. **v0.2 추가:** 4 단계(가로수길)는 로컬 자영업자(Blue)와 대형 프랜차이즈(Red)의 입·폐점을 4개 이벤트 유형으로 구분한 다변량 시공간 Hawkes로 설계한다. 16개 상호작용 계수 행렬의 *rolling window* 궤적이 단계 전이의 조기 신호를 제공한다 (§3.6). **v0.3 추가:** 사건 timestamp는 **지방행정 인허가 데이터(LOCALDATA)**에서 전수 추출. 인허가일-개점일 지연을 Red로 학습해 Blue에 이식하는 보정 절차 (§5.5). **v0.4 추가:** (a) 단계 1을 H3 r9 격자 기반 시공간 heatmap + 버거지수 재구성으로 재설계 (§3.1). (b) 시기별 2변량 분해 및 multi-site 확장 전략 (§3.6.6-7). **v0.5 추가:** (a) Reduced set을 선택적이지 아닌 *데이터 기반*으로 선택하는 절차 (§3.6.6). (b) 파라미터의 **3층위 전이 가능성**(μ 불가, 커널 조건부, α 용도의존)과 **정책 시뮬레이션의 '거울'** 개념 (§3.6.8). (c) 쇠퇴기 α 를 활용한 조기 경고 지수 G_6 (§6.6). **v0.6 추가:** 자기비판에서 출발한 구조적 보강. (a) 5 단계 EM의 한계 — 이벤트 유형별 독립 $\mu_k(x)$, 시간 불변 배경율, 비정상성의 서술 vs 설명 — 을 §3.5 말미에 명시. (b) **단계 6 제안(§3.7)** 신설: 공변량 조건부 배경율 $\mu_k(x, t) = \mu_k^0(x) \cdot$

$h_k(z(x,t))$ 로의 확장. 이는 Mohler(2014)의 α 과대추정 지적을 본 연구 맥락에서 정면으로 다룬다. **v0.7 추가:** 외부 피드백을 반영해 §3.7의 **식별 문제**(불변 입지 μ^0 와 시변 공변량 z 의 공간 상관)를 한계 ④로 추가하고, §3.7.4에서 세 재설계 옵션(동시 추정·순서 역전·직교화)을 비교 후 재설계 A(동시 EM + L2 + multiple starts)를 기본 경로로 확정. **v0.8 추가:** 2·3단계를 독립 산출물로 격상. (a) 단계 2는 단일 아파트 단지 분석에서 **자치구·생활권 단위 × 상승/하락 방향의 다변량 시간 Hawkes**로 확장 — 지역 간 선행/후행 네트워크 산출 (§3.2). (b) 단계 3은 **브랜드 간 α 행렬 heatmap을 킬러 페이지**로 지정 — 한 장의 그림으로 상권 동학 전체를 담고, 지역별 3장 비교로 동네별 상권 논리 차이를 드러냄 (§3.3).

문서의 전제. 이 로드맵의 다섯 단계는 **목표 지점**이 아니라 **반복적으로 되돌아가 수정할 궤적**이다. 5번이 끝이 아니라, 5번을 끝낸 뒤 1번으로 돌아가 같은 데이터를 더 나은 렌즈로 다시 본다.

1. 연구 배경과 문제의식

1.1 왜 점과정인가

서울의 한 동네에 스타벅스가 들어서면, 그 주변 반경 수백 미터에서 1~2년 안에 카페, 편집숍, 브런치 식당이 연쇄적으로 생긴다. 동시에 기존 세탁소, 분식집, 철물점은 임대료 상승을 못 견디고 밀려난다. 이 흐름은 특정 시점·공간의 **정적 분포**로 포착되지 않는다. 사건이 사건을 부르는 **동적 연쇄**이기 때문이다.

통상적인 공간 분석 도구(군집분석, Moran's I, 회귀)는 '지금 어디가 뜨거운가'는 말해주지만 '왜 그 지점이 뜨거워졌는가', '다음은 어디가 뜨거워질 것인가'는 설명하지 못한다. 점과정, 특히 Hawkes 과정은 이 연쇄 구조를 **수학적으로 직접 모형화**한다는 점에서 유일하게 적합한 도구다.

1.2 왜 젠트리피케이션인가

젠트리피케이션은 사회 문제이기 이전에 **속도의 문제**다. 어떤 동네는 10년에 걸쳐 서서히 변하고, 어떤 동네는 2년 만에 원주민과 자영업자가 사라진다. 전자는 정책 개입의 여지가 있고, 후자는 개입이 불가능하다. 그렇다면 행정이 물어야 할 질문은 '이 동네는 젠트리피케이션 중인가?'가 아니라 '어떤 단계에 있으며, 얼마나 빨리 진행 중인가?'다.

이 질문은 본질적으로 **강도(intensity)와 분기비(branching ratio)의 추정 문제**다. 바로 Hawkes 과정이 대답하도록 설계된 질문이다.

1.3 사례로서의 가로수길

가로수길은 2000년대 후반부터 2010년대 중반까지 한국형 젠트리피케이션의 교과서적 경로를 보였다. 예술가·소규모 디자이너 유입(1기) → 브랜드 카페·편집숍 진입(2기) → 대형 프랜차이즈·글로벌 브랜드 진입(3기) → 공실률 급증과 상권 공동화(4기). 이 경로가 **데이터로 남아 있다**는 점에서 가로수길은 모델을 훈련시키고 검증하기 위한 최적의 사례다.

2. 연구 질문

주 질문 (RQ). 도시 공간에서의 상업·부동산 사건들은 자기여기 점과정으로 얼마나 잘 설명되며, 이 모델의 모수들은 젠트리피케이션의 진행 단계를 식별하는 지수로 활용 가능한가?

세부 질문.

1. 스타벅스의 공간 분포는 단순 Poisson으로 설명되는가, 아니면 명백한 군집 구조를 보이는가? (SQ1)
2. 지역 간 아파트 거래 전파에 자기여기와 비대칭적 선행/후행 구조가 존재하는가?
강남·서초·마포 등 주요 권역 간 상승·하락 거래의 전파 강도는 어떤 방향성을 가지는가?
(SQ2)
3. 스타벅스 입점은 다른 프랜차이즈 입점을 유도하는가(excitation), 아니면
배제하는가(inhibition)? 방향성은 대칭적인가? (SQ3)
4. 상권의 '번짐'은 유클리드 거리로 설명되는가, 도로·지하철 네트워크로 설명되는가?
(SQ4)
5. 배경을 μ 를 상수로 고정했을 때 간과되던 공간 구조는 무엇이며, $\mu(x)$ 를 공간 함수로
풀었을 때 어떤 해석적 이점이 생기는가? (SQ5)

정책적 질문 (PQ). 추정된 모수 집합 (α , β , $\mu(x)$, 분기비 n^*)로부터 '젠트리피케이션 진행도 지수'를 어떻게 구성할 것이며, 이 지수는 정책적 의사결정에 어떻게 활용될 수 있는가?

4. 수학 직관 — 모델은 외우는 것이 아니라 가정에서 선택된다

v1.0 신설, v1.4 전면 확장. 연구 질문 직후에 이 장을 두는 이유는 단순하다. 본문에서 만날 거의 모든 함수와 분포 — Hawkes의 지수 감쇠, 가우시안 공간 커널, LGCP의 다변량 정규, Cox 회귀의 log-linear, 엔트로피의 공분산 행렬 — 가 같은 사고 패턴 위에 있고, 이 장은 그 패턴을 외우는 함수가 아니라 가정의 형태로 읽는 법을 미리 다진다.

4.0 이 장의 목적 — 모델은 어떻게 선택되는가

이 장의 인식론적 선언.

- 우리는 모델을 외우지 않는다. 정규분포·지수분포·포아송분포 같은 함수를 "이렇게 생긴 식"으로 받아들이지 않는다.
- 우리는 모델을 선택한다. "이런 특성을 가진 분포"라는 약속이 정해지면, 그 약속을 만족하면서도 가장 단순한 분포가 거의 강제로 결정된다.
- 그 결정의 결과는 거의 언제나 지수함수의 어떤 꼴이다. 이는 우연이 아니라 maximum entropy 원리의 결과 (Jaynes 1957). 평균을 알면 지수분포, 평균과 분산을 알면 정규분포, 단위 시간당 평균 발생을 알면 포아송분포.
- 따라서 본문의 모든 함수는 "가정의 형태"로 읽는다. Hawkes 시간 커널 $\exp(-\beta t)$ 는 "감쇠율이 시간에 무관하게 상수"라는 약속의 결과. 가우시안 공간 커널 $\exp(-x^2/2\sigma^2)$ 는 "디스카운트가 거리에 비례"라는 약속의 결과.

이 장의 목표는 통계학을 가르치는 것이 아니다. 본문에서 만날 함수들이 어떤 약속에서 나온 것인지를 미리 익히는 것. 그러면 §3.3의 가우시안 공간 커널, §V.3의 LGCP, §VI의 다변량 정규 엔트로피를 만났을 때 "또 정규분포인가?"가 아니라 "이 가정 하에서 또 그 형태가 나오는구나"로 받아들이게 된다.

주의: 이 장은 수식의 정밀한 도출을 다루지 않는다. 직관과 가정의 형태에 집중한다. 정밀한 정의는 §4 끝의 참고문헌으로 충분.

4.1 평균과 분산 — 분포에 대해 우리가 처음 묻는 두 가지

평균 ≠ "전형적인 값".

평균을 "평균적인 값"으로 가르치는 표준 방식은 **틀린 직관**을 심어준다. 평균은 전형적인 값이 아니라 **물리적 무게중심**이다. 데이터 점들이 시소 위에 놓여 있다고 상상하면, 시소가 균형을 이루는 받침대 위치가 평균이다.

- 비대칭 분포에서 평균은 다수의 사람이 위치한 곳이 아닐 수 있다. 예: 소득 분포에서 평균 소득은 "평범한 사람의 소득"이 아니다 — 일부 고소득자가 시소를 한쪽으로 끌어당기기 때문.
- 평균이 무게중심이라는 직관이 잡히면 "평균에서 1σ 떨어졌다"가 "무게중심에서 얼마나 멀리 갔다"의 의미를 가진다.

분산 = "평균에서 떨어진 거리의 제곱 평균".

분산을 "퍼짐 정도"라고 정의하면 정성적이라 약하다. 정확한 정의:

$$\text{Var}(X) = E[(X - \mu)^2]$$

- 각 데이터 점이 평균에서 떨어진 거리를 잰다.
- 그 거리를 제곱한다 — 부호를 없애기 위함, 그리고 멀리 떨어진 점에 더 큰 가중치를 주기 위함.
- 그 제곱들을 평균낸다.
- 표준편차 $\sigma = \sqrt{\text{Var}(X)}$ 는 같은 단위로 환산된 "평균에서의 전형적인 거리".

평균과 분산의 한계.

같은 평균과 분산을 가진 분포는 여럿 있을 수 있다 — 정규분포·균등분포·이봉분포 등. 따라서 평균과 분산을 안다는 것은 분포에 대한 *매우 약한 제약*. 그래도 분포 형태가 결정될 수 있는가? — 이 질문이 §4.5 정규분포의 출발점이 된다.

4.2 공분산과 상관 — 한 축이 움직이면 다른 축은

공분산의 정의와 단위 문제.

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

X가 미터, Y가 초라면 공분산의 단위는 미터·초. *이게 무슨 뜻인지 직관이 안 잡힌다.* 그래서 표준화한 것이 상관계수:

$$\rho = \text{Cov}(X, Y) / (\sigma_X \cdot \sigma_Y)$$

- ρ 는 단위 없는 -1 과 1 사이 숫자.
- 그러나 "이 숫자가 무엇을 의미하는가"는 여전히 명확하지 않다.

ρ 의 핵심 직관 — "한 축이 1σ 움직일 때 다른 축의 따라감 비율".

이변량 정규분포에서:

$$E[Y \mid X = \mu_X + 1 \cdot \sigma_X] = \mu_Y + \rho \cdot \sigma_Y$$

말로 풀면:

- $\rho = 0.75$ 은 "X가 평균에서 1σ 위로 갔을 때, Y는 평균에서 평균적으로 0.75σ 위로 따라간다"는 비율.
- $\rho = 0$ 이면 X의 움직임이 Y의 위치에 정보를 주지 않는다 (두 축 무관).
- $\rho = 1$ 이면 X와 Y가 같은 비율로 움직인다 (완전한 동행).
- 음의 ρ 는 반대 방향 — X가 늘면 Y는 줄어드는 비율.

이 직관이 강력한 이유. ρ 는 단위 없는 추상적 숫자가 아니라 *예측의 비율*. 회귀의 표준화 기울기와 정확히 같은 양 — "X 1단위 변화에 Y 몇 단위가 따라가는가"의 σ 단위 표현.




그림 4.2.1 — 이변량 정규분포에서 ρ 가 결정하는 "한 축이 1σ 움직일 때 다른 축의 따라감 비율". 점선은 $X = +1\sigma$, 빨간 점은 그 위치에서의 Y 평균값($= \rho\sigma$). 빨간 선은 conditional expectation $E[Y|X] = \rho \cdot X$. ρ 가 클수록 점들이 직선에 가까워지고, 동시에 X가 움직일 때 Y가 더 강하게 따라간다.

ρ 의 한계.

- **선형 관계만 측정.** $Y = X^2$ 이면 $\rho \approx 0$ 이지만 X 가 Y 를 완전히 결정한다. 비선형 종속성은 ρ 가 못 잡는다.
- **이상치에 약함.** 한두 개의 극단값이 ρ 를 크게 흔든다. 정규성 가정이 깨지면 ρ 의 해석이 무너진다.

본문에서의 ρ — 미리 보기.

- §3.7.4 식별 문제: μ^0 와 z 의 공간 상관 ρ 가 0.9 가까우면 "z가 1σ 늘 때 μ^0 가 평균 0.9σ 따라가는" 거의 같은 정보. → multicollinearity의 정확한 의미.
- §V.3 LGCP length scale: "두 점이 거리 d 떨어져 있을 때 그 점들의 함숫값이 $\rho \approx 0.37$ 로 상관됨"이 length scale의 정의. → §4.2의 ρ 직관이 거리 함수에 적용된 것.
- §VI.2 이하 엔트로피: 다변량 정규의 엔트로피가 공분산 행렬의 determinant로 결정. "공분산 행렬"이 무엇을 인코딩하는지가 §4.2에서 다져지면 엔트로피의 의미가 자연스럽게 들어옴.

4.3 첫 약속 — "기억 없음"이 만드는 분포 (지수 분포)

약속의 형태.

"지금까지 사건이 발생하지 않았다는 사실이 앞으로의 발생 시점에 정보를 주지 않는다."

이것이 **memoryless property**. 5분 기다렸는데도 사건이 안 일어났다 → 다음 1분 안에 일어날 확률이, 처음 1분 안에 일어날 확률과 같다.

이 약속의 결과.

memoryless를 만족하는 연속 분포는 **지수 분포**뿐. 형태가 강제됨:

$$f(t) = \lambda \exp(-\lambda t), \quad t \geq 0$$

- "기억 없음"이 약속이고 "지수함수"가 결과. 외운 게 아니라 약속의 결과.
- **평균 = $1/\lambda$.** 이 평균이 "평균 대기 시간".
- **분산 = $1/\lambda^2$.** 표준편차 = 평균. 이게 지수분포의 특이한 성질 — 평균과 표준편차가 같다.

지수 함수의 형태 직관 (이전 §4의 핵심).

- 선형 감소는 같은 '양'이 줄어드는 경우. $100 \rightarrow 90 \rightarrow 80 \rightarrow 70$.
- 지수 감소는 같은 '비율'이 줄어드는 경우. $100 \rightarrow 50 \rightarrow 25 \rightarrow 12.5$.
- **핵심: 상대적 감쇠율이 시간에 무관하게 상수.** $d/dt \log f = -\lambda$.

반감기 직관.

$$\text{반감기} = \ln(2)/\lambda \approx 0.693/\lambda$$

- $\lambda = 0.1/\text{월}$ 이면 반감기 ≈ 7 개월. 7개월 뒤 절반, 14개월 뒤 1/4.
- $\lambda = 1/\text{월}$ 이면 반감기 ≈ 21 일. 훨씬 빠른 소실.
- "스타벅스 입점 효과의 반감기는 몇 개월인가?" 같은 질문이 자연스럽다.

이 약속의 한계 — §IV.7로의 다리.

- 기억 없음 가정이 도시 현상에 적합한가? 점포가 5년 영업했다는 사실이 다음 1년 폐업률에 정보를 주지 않는다는 것은 비현실적.
- 실제 점포는 개점 직후 hazard가 높고(초기 폐업), 안정기에 낮아지고, 임대료 인상기에 다시 높아짐.
- §IV.7의 "버티는 힘 $\lambda_{\text{survive}}(x)$ "가 hazard를 시간 상수가 아닌 함수로 다루는 이유 — 기억 없음 가정의 거부.

본문에서의 지수 분포 — 미리 보기.

- **Hawkes 시간 커널:** $g(t) = \alpha \exp(-\beta t)$. 한 사건의 영향이 시간에 대해 일정한 비율로 감쇠한다는 가정.
- **§IV.2 Life table-§IV.3 KM:** 점포 수명이 지수 분포라는 가정을 검증하는 도구. 실제 분포가 지수에서 얼마나 벗어나는지 본다.

4.4 두 번째 약속 — "독립 사건"이 만드는 분포 (포아송)**약속의 형태.**

"단위 시간당 평균 발생 수가 일정한 λ 이고, 사건들이 서로 독립적이다."

이 약속의 결과.

정해진 시간 구간 $[0, T]$ 에서 발생한 사건 수 $N(T)$ 의 분포가 포아송:

$$P(N(T) = k) = (\lambda T)^k \cdot \exp(-\lambda T) / k!$$

- **"독립·균일"이 약속이고 "포아송"이 결과.** 외운 게 아니라 약속의 결과. 다시 지수함수가 등장 — 약속의 형태가 지수함수를 부른다.
- **평균 = 분산 = λT .** 이 "평균 = 분산"이 포아송의 진단 신호.

이 약속의 한계 — Hawkes로의 다리.

실제 데이터에서 분산이 평균보다 훨씬 크면 (overdispersion), "독립 사건" 가정이 깨졌다는 신호. 사건들이 서로 영향을 주고 있다는 것. 도시에서:

- 점포 입점이 강남 vs 노원에서 평균과 분산이 다른 패턴을 보임 → 강남에서 입점이 입점을 부르는 자기여기 가능성.
- 이 자기여기를 명시적으로 모델에 넣은 것이 Hawkes process. 포아송 + 자기여기 = Hawkes.

본문에서의 포아송 — 미리 보기.

- **Part I 1단계 §3.1:** 스타벅스 분포가 단순 Poisson인가, 아니면 군집 구조가 있는가? — 이 질문이 단계 1의 출발점.
- **Part I 2단계 §3.2:** Poisson에서 Hawkes로 가는 진화. "독립 사건" 가정의 거부.
- **§II.4 simulation-based recovery:** Hawkes로 합성 데이터 생성 = Poisson + self-excitation의 명시적 결합. 포아송이 무엇이었는지 알아야 simulation의 의미가 보임.

📺 박스 — 다른 도메인의 포아송 검정: 영화 개봉 첫 주 관객 수 (v1.5 추가)

이 박스는 본 연구의 도구가 도시 부동산을 넘어 일반적임을 시사하는 보조 자료. 본문 전체 사례는 부동산이지만, 같은 도구가 영화 흥행에도 적용된다는 점을 짧게 짚는다.

한국 영화의 개봉 첫 주 일별 관객 수가 포아송 분포를 따른다면, 평균과 분산이 같아야 한다. 그러나 KOFIC 박스오피스 데이터를 살펴보면 분산이 평균보다 훨씬 크다 — 일별 관객 수가 평

균 50,000명, 분산은 수백만 단위의 overdispersion이 흔히 관찰됨.

의미.

- "독립 사건" 가정이 깨졌다는 신호.
- 관객 한 명의 관람이 다음 관객의 결정에 영향 — SNS 입소문, "천만 영화" 마케팅의 자기여기적 성질.
- 같은 주 개봉작끼리의 cannibalization — 관객 풀이 한정되어 있어 한 영화의 흥행이 다른 영화의 손실.

이 두 효과 — 자기여기와 cross-excitation — 가 결합된 구조가 정확히 **다변량 Hawkes 과정**.
본 연구의 §3.3 시공간 α 행렬과 동일한 도구가 영화 흥행 분석에도 적용 가능. 자세한 설계는 부록 A 참조.

4.5 세 번째 약속 — "디스카운트가 거리에 비례"하는 분포 (정규)

약속의 형태.

"평균에서의 디스카운트 비율이 거리에 선형 비례한다."

이 약속의 결과 — 1차원.

$$\phi(x) \propto \exp(-x^2/2\sigma^2)$$

지수 분포(상수 디스카운트)와 정규분포(거리 비례 디스카운트)의 차이를 미분으로 보면 명확:

- **지수 분포:** $d/dt \log f = -\lambda$ — 상수.
- **정규분포:** $d/dx \log \phi = -x/\sigma^2$ — x 에 선형. 평균에서 멀수록 디스카운트가 가속.

이 결과가 만드는 모양 — 종 모양.

- 중심 근처 ($x \approx 0$): 디스카운트가 작음 → 천천히 줄어듦.
- 멀리 ($|x|$ 큼): 디스카운트가 큼 → 빠르게 줄어듦.
- 결과: 종 모양. 지수 분포는 0에서 시작해 단조 감소하지만, 정규분포는 평균에서 정점을 이루고 양쪽으로 가속하며 떨어진다.

Maximum entropy 관점.

실수 전체에 정의되고 평균과 분산만 정해진 분포 중 **가장 무지한(엔트로피가 최대인) 분포가 정규분포**. 평균과 분산이라는 두 약속만 있을 때 "그 외에는 아무 것도 가정하지 않는" 분포가 정규분포라는 것. 외운 게 아니라 약속의 결과.

다변량 정규 — 공분산 행렬의 등장.

$$\phi(\mathbf{x}) \propto \exp(-\frac{1}{2} (\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu}))$$

- **$\boldsymbol{\Sigma}$ 는 공분산 행렬:** 대각 성분은 각 축의 분산, 비대각 성분은 축 간 공분산.
- **§4.2의 ρ 직관이 여기서 그림이 됨:** 이변량 정규의 등고선은 타원. 두 축의 σ 가 다르면 타원이 찌그러지고, ρ 가 0이 아니면 타원이 회전.
- **$\rho = 0$:** 축에 평행한 타원. 두 축이 무관.
- **$\rho = 0.75$:** 기울어진 타원. 한 축이 1σ 움직일 때 다른 축이 0.75σ 따라감 — §4.2의 산점도 그림 그대로.
- **$\rho = 1$:** 타원이 직선으로 붕괴. 두 축이 완전히 결정됨.

가우시안 커널의 의미 — 본문 §3.3과의 직접 연결.

Hawkes의 공간 커널 $f(\mathbf{x} - \mathbf{x}_i) = (1/2\pi\sigma^2) \exp(-|\mathbf{x}-\mathbf{x}_i|^2/2\sigma^2)$ 는 같은 약속을 공간 영향에 적용:

- **약속:** "한 사건의 공간 영향이 거리에 따라 가속해서 약해지고, 방향에 무관".
- **결과:** 정규분포 형태의 영향 함수.
- **이 약속의 강도:** 공간 영향이 모든 방향으로 같다는 것은 강한 가정. 도로망·지하철 노선이 영향을 비대칭으로 만든다면, 가우시안이 적합하지 않음 — §3.4 단계 4의 네트워크 커널이 이 비판에 답.

본문에서의 정규/가우시안 — 미리 보기.

- **§3.3 Hawkes 공간 커널:** 정규분포 형태. 위 약속이 그 근거.
- **§V.3 LGCP의 GP prior:** 다변량 정규의 무한차원 일반화. 공분산 함수가 §4.2의 ρ 를 거리 함수로 일반화한 것.

- **\$VI** 다변량 정규 엔트로피: 공분산 행렬의 determinant로 결정. "공분산 행렬에 인코딩된 자유도"의 의미가 \$4.2~\$4.5에서 다져짐.

4.6 패턴의 인식 — 왜 모두 지수함수인가

지금까지 본 세 약속과 그 결과를 한 표로 정리:

약속의 내용	강제되는 분포	지수함수 안의 인수 형태
평균만 정해짐 (양의 실수)	지수 분포 $\exp(-\lambda t)$	$-\lambda t$ — 시간에 선형
평균과 분산이 정해짐 (실수)	정규분포 $\exp(-x^2/2\sigma^2)$	$-x^2/2\sigma^2$ — 거리에 제곱
단위 시간당 평균 발생 (이산)	포아송 분포 $(\lambda T)^k \exp(-\lambda T)/k!$	$-\lambda T$ — 시간에 선형
평균·분산·공분산 (다변량 실수)	다변량 정규 $\exp(-\frac{1}{2} \Delta^T \Sigma^{-1} \Delta)$	$-\frac{1}{2} \Delta^T \Sigma^{-1} \Delta$ — 거리의 이차형식

패턴.

- 모두 지수함수의 어떤 꼴.
- 지수함수 안의 인수가 약속의 형태에 따라 달라짐 — 시간에 선형이면 지수분포, 거리에 제곱이면 정규분포, 거리의 이차형식이면 다변량 정규.
- 이게 우연이 아닌 이유: maximum entropy 원리(Jaynes 1957)에서 "제약 조건 하의 최대 엔트로피 분포"는 지수족(exponential family)에 속함이 정리(theorem)로 증명됨.

Jaynes의 통찰.

"우리가 가진 정보(평균·분산 등의 제약)만 받아들이고, 그 외에는 가장 무지한 분포를 선택하라." 이게 maximum entropy 원리. 결과가 지수함수 형태로 나오는 것은 정보 이론적 자연스러움이지 마법이 아님.

본 책의 자세 — 이 패턴을 자각하기.

- 본문에서 만나는 모든 함수 — Hawkes 시간 커널, 가우시안 공간 커널, Cox 회귀의 log-linear, LGCP의 GP — 가 같은 패턴 위에 있다.
- 각 함수를 만났을 때: "어떤 약속의 결과인가?"를 묻는다.
- 그 약속이 본 연구 데이터에 적합한가를 검증한다 (Part II 4대 심판관, §II.6 도구별 진단).
- 적합하지 않으면 약속을 풀고 다른 형태로 간다 (Part III 2차 라운드, Part IV 생존분석, Part V Cox-Hawkes).

이것이 본 연구의 인식론적 자세다 — 모델은 외우는 것이 아니라 가정에서 선택된다. 가정이 맞지 않으면 모델을 바꾼다. 그것이 v0.1부터 v1.3까지의 모든 자기비판이 따른 길이다.

4.7 코드와 그림의 결합

이 장의 그림으로는 다음을 준비한다 (그림 4.2.1은 위에 이미 등장):

- ρ 에 따른 이변량 정규 산점도 4패널 (위 그림 4.2.1) — 공분산의 직관
- 지수 분포 vs 정규분포의 1차원 함수 그래프 — 디스카운트의 차이가 함수 모양으로 드러남
- 포아송 분포의 막대 그래프, 평균이 다른 여러 λ 비교
- 이변량 정규의 등고선 — ρ 가 변하면 타원이 어떻게 회전하고 찌그러지는가
- 거듭제곱 감쇠 vs 지수 감쇠 비교 — 꼬리 무게의 차이 (긴 꼬리가 필요할 때 거듭제곱)

이런 그림과 짧은 코드가 같이 오면, 독자는 이후 본문에서 등장하는 식들을 "갑자기 튀어나온 고급 수학"이 아니라 이미 본 패턴의 변주로 받아들이게 된다.

이 장의 본문 회수 지점. §4의 직관이 본문에서 짧게 참조되는 지점:

- **§3.3 시공간 Hawkes 커널:** "§4.3 지수 + §4.5 가우시안의 결합".
- **§3.7.4 식별 문제:** "§4.2의 ρ 직관 — μ^0 와 z 의 공간 상관 0.9가 의미하는 것".
- **§II.4 simulation-based recovery:** "§4.4 포아송이 무엇인지 알아야 합성 데이터 생성의 의미가 보임".

- **§IV.3 KM-§IV.7 Cox process:** "§4.3의 기억 없음 가정이 거부됨 → hazard가 시간 함수".
- **§V.3 LGCP:** "§4.5 다변량 정규의 무한차원 일반화. length scale은 §4.2 ρ 를 거리 함수로 만든 것".
- **§VI 엔트로피:** "§4.5 공분산 행렬의 determinant가 다변량 정규 엔트로피".

이 장이 잘 다져지면, 본문 곳곳에서 통계적 직관을 다시 다지지 않아도 됨. 본문이 가벼워지고, 독자의 이해는 깊어진다.

Part I — 1차 라운드: 점과정으로 도시·부동산 현상을 읽기

Part I의 목표는 점과정적 사고를 독자의 몸에 붙이는 것이다. 5단계에 걸쳐 같은 질문을 점점 정교한 도구로 다루며, 각 단계는 앞 단계가 해결하지 못한 구체적 실패를 지적함으로써 다음 단계를 정당화한다. 이 구간을 다 통과한 뒤에야 독자는 Part II의 '과연 이 모델로 충분한가'라는 관문 질문을 진지하게 받을 준비가 된다.

Part I은 v0.9까지의 §3 내용(단계 1~5)을 거의 그대로 사용한다. 각 장의 번호만 책 구조에 맞게 재배치: 단계 1 → 5장, 단계 2 → 6장, 단계 3 → 7장, 단계 4(Blue/Red) → 8장, 단계 5(EM μ) → 9장.

3. 모델의 점진적 확장 — 연구의 중심축

이 절은 이 로드맵의 심장이다. 각 단계는 앞 단계가 해결하지 못한 구체적 실패에서 정당화되며, 새로 도입하는 수학적 장치가 해석적으로 무엇을 가능하게 하는지를 명시한다.

3.0 한눈에 보기

단계	모델	데이터/사례	극복 한계	새로운 개념
1	H3 heatmap + KDE + 버거지수	복수 프랜차이즈 × 전국 × 시계열	baseline: 시간·상호작용 없음	H3 격자, 시공간 슬라이더, Poisson 검정
2	지역 간 부동산 전파 Hawkes	자치구·생활권 단위 × 상승/하락 거래	KDE: 시간 차원 부재, 단일 단지: 지역간 무시	선행/후행 행렬, 상승·하락 비대칭, 분기비
3	상업 상권 ST-Hawkes — α 행렬 heatmap	LOCALDATA에서 추출한 m개 브랜드 전체	시간 Hawkes: 공간·상호작용 부재	공간 커널, mutually-exciting
4	네트워크 커널 ST-Hawkes	가로수길 상권 전환 이벤트	유클리드 거리의 부적절성	도로망 그래프, 측지 거리
5	잠재 $\mu(x)$ ST-Hawkes + EM	스타벅스 revisited (1번 재분석)	상수 배경율 μ 의 편향	EM, 배경율의 공간 함수화

주목할 것: 5단계는 1단계의 데이터를 다시 다룬다. 여정은 끝으로 가는 것이 아니라 처음으로 돌아온다. 이 회귀가 이 연구의 서사적 형태다.

3.1 단계 1 — H3 Heatmap + 버거지수: 독립 산출물로서의 정적·시계열 분포

v0.4 개정: 단계 1은 방법론 준비운동이 아니라 그 자체로 독립된 가시화·분석 산출물로 재정의된다. 후속 단계(2~5)와 별개로 완결되며, 단독으로 발표 가능한 결과물을 목표로 한다.

3.1.1 설계 의도

원래 구상의 뿌리는 2010년대 중반 유행했던 **버거지수(Burger Index)**다. 맥도날드·버거킹·KFC·롯데리아의 점포 수 비율을 도시·지자체 단위로 계산해 *구매력·도시화* 수준을 순위화하려 한 대중적 지표였다. 재밌는 발상이었지만, (i) 행정구역 단위 집계 → 경계효과, (ii) 단순 비율 → 절대 규모 정보 소실, (iii) 정적 스냅샷 → 시계열 공백 세 가지 한계가 있었다. 본 단계는 이 한계를 한 번에 극복한다.

3.1.2 목표 산출물

세 층위의 분석·가시화를 단계적으로 제공한다.

- ① **전통적 버거지수의 재구성**. 맥도날드·버거킹·KFC·롯데리아 네 개 고정 브랜드로 전국 H3 r9(edge $\approx 174\text{m}$, 면적 $\approx 0.105\text{ km}^2$) 셀별 집계. 서울 주요 권역과 지방 주요 도시를 동일 격자에서 직접 비교.
- ② **Poisson 기반 클러스터링 검정**. 각 브랜드별로 '전국 H3 셀들 중 점포 수가 Poisson 기대치 대비 유의하게 많은 셀'을 식별. 단순히 많은 곳이 아니라 *통계적으로 군집된* 곳을 구별. Complete Spatial Randomness(CSR) 기각 검정의 격자화된 버전.
- ③ **자유 조합 pseudo 상권·구매력 지수**. 사용자가 관심 브랜드 집합 $S = \{\text{스타벅스, 다이소, 올리브영, GS25, ...}\}$ 를 선택하면, 각 H3 셀에서 S의 공동 집적도(joint concentration)를 계산해 동적 지수 생성. 버거지수를 *네 개 고정 브랜드의 단일 비율*에서 *임의 브랜드 집합의 다차원 밀도 텐서*로 일반화.

3.1.3 기술적 설계

공간 격자. H3 r9를 기본 해상도로 사용. 광역 비교(시·구 단위)에는 r9가 적절하고, 가로수길·경리단길 같은 좁은 상권 내부 해상도가 필요할 때는 r10(edge $\approx 66\text{m}$)으로 확대. 사용자가 UI에서 해상도를 토글.

KDE와 H3의 결합. 두 방식을 병렬로 쓴다:

- KDE $\hat{p}(x) = (1/n \cdot h^2) \sum_i K((x - x_i) / h)$ — 연속 공간의 매끈한 밀도 표면. *경계 없는 시각적 연속성*.

- H3 셀별 점포 수 N_c — 행정구역과 무관한 균일 격자 위의 이산 집계. *비교·검정·색상 매핑에 용이.*

KDE는 탐색적 시각화, H3는 정량적 비교·검정의 역할로 분담.

시간축 — 슬라이더·애니메이션. LOCALDATA 시계열을 활용해 월 또는 분기 단위 스냅샷 시퀀스 생성. 사용자는 두 가지 인터랙션 모드를 선택:

- **슬라이더 모드:** 시점 t 를 드래그하며 정적으로 관찰. 특정 시점 비교·스크린샷·프리젠테이션에 적합.
- **애니메이션 모드:** 자동 재생으로 시점 연쇄를 통째로 보기. 스타벅스가 강남에서 홍대·성수로 번지는 경로, 올리브영이 대학가를 점령하는 속도 같은 *공간의 역사*가 한눈에 드러난다.

3.1.4 대상 브랜드 (확장 가능)

카테고리	브랜드	의미·가설
버거지수 원형	맥도날드, 버거킹, KFC, 롯데리아	전통적 구매력·도시화 지표. 기준선 역할
프리미엄 커피	스타벅스, 블루보틀, 커피빈	중산층·사무지구 지표. 앵커 효과의 전형적 주체
저가 커피	이디야, 메가커피, 컴포즈, 뽕다방	유동인구·상권 성숙도 지표. 스타벅스의 '그림자 지역' 가설 검정
편의점	GS25, CU, 세븐일레븐, 이마트24	주거지 밀도·유동인구 복합 지표. 포화 상태의 공간 탐색
생활 필수	다이소, 올리브영	MZ 상권·젊은 인구 지표. 올리브영 집적은 '상권의 여성화' 가설과 연결 가능
베이커리	파리바게뜨, 뚜레쥬르	주거·상업 복합 지표. 전국 커버리지가 높아

카테고리	브랜드	의미·가설
		baseline 비교용

브랜드 리스트는 고정이다. LOCALDATA에서 상호 사전으로 추출 가능한 모든 프랜차이즈를 대상으로 확장 가능. 사용자 선택 UI를 통해 임의 조합 지원.

3.1.5 pseudo 상권 지수의 구성 (아이디어)

사용자가 선택한 브랜드 집합 $S = \{s_1, \dots, s_m\}$ 에 대해, H3 셀 c 의 상권 지수를 다음 중 하나로 정의:

- **단순 합산 지수:** $I(c, S) = \sum_{s \in S} w_s \cdot N_{\{c, s\}}$ — 가중 합. 브랜드별 가중치 w_s 는 해당 브랜드의 전국 평균 매출 등으로 정당화.
- **공동 집적 지수:** $I(c, S) = \prod_{s \in S} (N_{\{c, s\}} + 1)^{1/m}$ — 기하평균. 여러 브랜드가 동시에 집적된 곳만 높게 나옴. 한 브랜드만 지배적인 곳은 낮게 평가 → 실질적 복합상권 식별.
- **편차 기반 지수:** $I(c, S) = \sum_{s \in S} (N_{\{c, s\}} - E[N_{\{c, s\}} | \text{인구}]) / \sigma_s$ — 인구 규모 통제 후 표준화 편차 합. '인구 대비 과잉 집적' 측정.

정리하면: 버거지수의 정신(일상 업소로 도시 공간을 읽는다)은 살리되 방법(단일 비율, 정적, 행정구역 단위)은 완전히 교체한다. 결과물은 격자화·시계열화·복수 브랜드화된 유연한 도구.

3.1.6 구현 스택

- 데이터: LOCALDATA 전체분 + 월변동분 (§5.5 파이프라인 공유)
- 공간 인덱싱: h3-py (Uber H3), geopandas
- KDE: scipy.stats.gaussian_kde 또는 statsmodels
- 웹 가시화: folium + H3 polygon overlay → 시계열은 TimeSliderChoropleth, 또는 kepler.gl(3D·애니메이션 강력), 또는 pydeck(H3 layer 내장)
- 배포: Jupyter notebook 기본, 사용자 인터랙션이 필요하다면 Streamlit app으로 확장

3.1.7 이 단계의 고유한 가치

- **독립 완결성.** 단계 2~5가 기술적으로 무산되어도 단계 1은 그 자체로 발표 가능한 결과. *안전장치 역할의 산출물.*
- **대중적 접근성.** 버거지수라는 익숙한 개념에서 출발 → 비전문가에게도 설명 가능한 결과 → 정책 커뮤니케이션의 입구.
- **후속 단계로의 투영.** H3 격자는 단계 5의 $\mu(x)$ 추정에서 자연스러운 격자가 된다. 단계 1의 Poisson 기대치는 단계 5 EM의 초기값으로 재활용.
- **정책 대화의 자료.** '이 구역의 버거지수가 주변 대비 2σ 이상이다', '올리브영 밀도가 최근 3년간 연 30% 증가' 같은 구체적 수치가 행정·언론과의 대화에서 즉시 사용 가능.

3.1.8 이 단계가 대답할 수 없는 것 (→ 2단계로 가는 이유)

- 시간 축을 추가해도 각 시점은 여전히 '사진의 연속'이다. 사건이 사건을 부르는 동학 자체는 포착되지 않는다.
- 사건 간 인과를 모른다. 점 A가 점 B를 '불렀는지'는 애초에 질문의 범위 밖이다.
- 격자화는 공간을 다루지만, 개별 사건의 연쇄 구조(branching)는 다루지 않는다.
- 결국 H3 heatmap은 '슬라이드 쇼'다. 우리가 알고 싶은 것은 '인과적 영화'다.

3.2 단계 2 — 지역 간 부동산 전파: 독립 산출물로서의 다변량 시간 Hawkes

v0.8 개정: 단계 2는 방법론 학습용 장난감 문제에서 독립적으로 발표 가능한 부동산 분석 산출물로 재정의된다. 단계 1(H3 heatmap)이 이미 독립 완결물이 된 것과 같은 위상으로, 단계 2도 후속 단계와 무관하게 완결되는 결과물을 목표로 한다.

3.2.1 원래 설계의 회복

v0.7까지 단계 2는 '한 아파트 단지 안의 거래를 시간 Hawkes로 분석'하는 형태로 서술되었다. 이는 MLE-edge effect-branching representation 같은 수학적 뼈대를 가장 단순한 설정에서 숙달하기 위한 교육용 환경이었고, 그 자체로는 정책적·학술적 의미가 제한적이다. 본래 연구 의도는 지역 간 부동산 전파 구조의 규명이었다:

- 강남의 상승 거래가 서초의 상승 거래를 얼마나 선행하는가?
- 마포의 하락 거래가 강북 인접 지역의 하락을 촉발하는가?
- 분당의 거래 활성화가 판교·평촌·광명으로 어떤 속도로 퍼지는가?

이 질문들은 단일 단지 분석으로는 원천적으로 답할 수 없다. 지역을 이산 변량으로 놓고 방향(상승/하락)을 교차한 다변량 설계가 필요하다.

3.2.2 설계 — 지역 × 방향 다변량 시간 Hawkes

지역 집합 $L = \{\text{강남, 서초, 송파, 마포, 용산, 성동, 분당, 판교, ...}\}$, 방향 $D = \{\text{상승, 하락}\}$. 각 이벤트는 (t, ℓ, d) 꼴의 triple. 사건 유형 $k \in L \times D$ 로 총 $2|L|$ 개 변량. 강도함수:

$$\lambda_{\{(\ell, d)\}}(t) = \mu_{\{(\ell, d)\}} + \sum_{\{(\ell', d')\}} \sum_{\{t_i < t\}} \alpha_{\{(\ell, d) \leftarrow (\ell', d')\}} \cdot \exp(-\beta(t - t_i))$$

$\alpha_{\{(\ell, d) \leftarrow (\ell', d')\}}$ 는 지역 ℓ' 의 방향 d' 거래가 지역 ℓ 의 방향 d 거래를 얼마나 유발하는지의 강도. 예를 들어 $|L|=10$ 이면 α 는 $20 \times 20 = 400$ 개 계수의 행렬이 된다. 모든 계수를 추정하는 것은 비현실적이므로 구조적 제약이 필요하다 — 예: 같은 지역 내 방향 간 영향만 추정, 지리적으로 인접한 지역 쌍만 추정, 또는 sparse regularization으로 유의한 계수만 살림.

3.2.3 정책적·학술적 의미

- **중심지-주변지 구조의 정량화.** $\alpha_{\{(\text{서초, 상승}) \leftarrow (\text{강남, 상승})\}}$ vs $\alpha_{\{(\text{강남, 상승}) \leftarrow (\text{서초, 상승})\}}$ 의 비대칭이 *어느 지역이 전파의 중심인가*를 수치로 답한다. 부동산 업계의 경험적 통념을 데이터로 검증하거나 반박.
- **상승·하락 전파 비대칭.** 상승은 빠르고 하락은 느리다, 혹은 그 반대의 패턴이 있는가. 정책 개입 시점의 참고자료.
- **지역 간 '거래 전염' 네트워크.** α 행렬을 그래프로 시각화하면 *어느 지역이 어느 지역의 선행 지표인가*를 한 장의 그림으로 제시. 정책·투자·학술 세 방면에 모두 가치 있는 산출물.
- **분기비 n^* 의 해석.** 지역별 분기비가 1에 가까울수록 '자기여기'가 크다 — 한 번의 거래가 다수의 후속 거래를 유발하는 과열 상태. 정상성 경계를 모니터링하는 의미.

3.2.4 예상 산출물

- 2|니 × 2|니 α 행렬 — 지역 간 방향별 전파 강도의 전체 지도
- α 행렬을 축약한 지역 간 전파 네트워크 그래프 (방향성·가중치 포함)
- 시기별(예: 2017-2020 상승기 vs 2022-2024 하락기) α 행렬 비교 — 체제 전환의 정량 지표
- 특정 지역 쌍의 동역학 시뮬레이션 — '강남에서 상승 거래 100건이 발생했을 때 3개월 내 서초·송파의 예상 거래 수'

3.2.5 데이터원

- 국토교통부 실거래가 공개시스템 (아파트 매매 실거래) — 시·군·구 단위 집계 또는 단지 단위 개별 거래
- 상승/하락 방향 분류: 같은 단지·같은 평형의 직전 거래 대비 가격 변화로 이진 분류. 대안으로 연속 변량(가격 변화율)을 유지하고 marked Hawkes로 확장 가능.
- 지역 경계: 행정구 단위(자치구)가 1차 기준. 필요시 생활권 단위(강남3구, 노도강, 마용성 등)로 집계.

3.2.6 선행 연구와의 관계 (v0.9 추가)

v0.9 개정에서 추가. 2단계 설계 공간에 이미 중요한 선행 연구가 존재하며, 본 연구의 위치를 정확히 설정할 필요가 있다.

가장 근접한 선행 연구 — 현대우·Milcheva (2016).

Hyun, D. & Milcheva, S. (2016) *"Conform or Resist? Spatio-Temporal Spillover Effects of Surrounding Apartment Transactions in a Boom and a Recession"* (SSRN 2844268)은 서울 아파트 30,541건 거래 데이터로 **상승장/하락장 비대칭 spillover**를 명시적으로 비교했다. 핵심 결과: 이웃 부동산 가치가 상승장에서는 하락장보다 **약 8배 더 spillover**한다. 사용 도구는 spatio-temporal autoregressive (STAR) 모델.

이 연구는 본 연구 2단계의 **질문·데이터·상승/하락 비대칭 강조** 세 차원에서 사실상 동일하다. 2

단계를 '전인미답의 영역'으로 포지셔닝할 수 없으며, 그렇게 주장해서도 안 된다.

지역 간 contagion 문헌.

- Cotter, J., Gabriel, S., & Roll, R. (2011) *"Integration and Contagion in US Housing Markets"* (SSRN 2017793) — FHFA 가격지수로 384개 MSA의 integration-contagion 분석. 샌프란시스코 가격 return이 주변 커뮤니티를 선행하는 비대칭 구조 식별. 본 연구의 '강남이 서초를 선행하는가'와 동일 형태의 질문.
- Yunus, N. (2013) *"A Closer Look at the U.S. Housing Market"* (Real Estate Economics) — 미국 9개 지역의 multivariate cointegration으로 장기 균형을 이끄는 driver 지역 식별.
- Zhang et al.의 양쯔강 삼각주 연구, Holly-Pesaran-Yamagata(2010, 2011)의 영국·미국 주택가격 시공간 diffusion 연구 등 공간 패널 계량경제 접근이 풍부. 주 도구는 Spatial Durbin, GVAR, cointegration.

Hawkes의 부동산 응용.

금융 contagion에 multivariate Hawkes를 적용한 문헌(Aït-Sahalia et al. 2011, Bacry et al., 등)은 풍부하지만, 부동산 거래·특히 한국 부동산에 multivariate Hawkes를 적용한 선행 연구는 검색 한계 내에서 발견되지 않았다. 국내 도시연구 문헌에서도 Hawkes는 지진학(Kwon et al. 2023) 외에 사회과학 응용 사례가 매우 적다.

차별적 기여 — 세 층위의 원본성.

- ① 분기비 n^* 기반 과열 진단. STAR·VAR·Spatial Durbin은 '가격이 얼마나 연관되어 있나'를 답하지만, Hawkes는 '한 거래가 평균 몇 개의 후속 거래를 유발하나'라는 분기 관점을 제공. $n^* < 1$ 의 정상성 경계는 버블 모니터링의 직접적 정량 지표다.
- ② Rolling window $\alpha(t)$ — 연속적 체제 변화 추적. 현대우·Milcheva(2016)는 상승장과 하락장을 두 시기로 나누어 각각 별도 회귀했다. 본 연구의 rolling window 설계는 2010-2024 전체 기간에서 매월 갱신되는 α 궤적을 얻는다. 체제 전환 시점 자체가 데이터로 식별됨.

- ③ **이벤트 수준 해상도**. 선행 연구 다수가 월별·분기별 집계 지수(FHFA index, 가격 변화율 시계열)에서 출발. 본 연구는 *개별 거래 타임스탬프*를 그대로 사용. 시간 커널 $g(t - t_i)$ 의 미세 동학(초기 급증 후 감쇠)을 포착.

요약하면: 본 연구의 *질문*은 기존 연구와 공유되지만, *도구*(Hawkes), *체제 변화 추적 방식* (rolling window $\alpha(t)$), *분석 해상도*(이벤트 스트림) 세 층위에서 차별적 기여가 있다. 기존 연구를 대체하지 않으며 **같은 현상을 보는 보완적 렌즈**로 포지셔닝된다. 특히 현대우·Milcheva가 "8배"로 요약한 결과가 본 연구의 분기비 n^* 과 어떻게 대응되는지, rolling $\alpha(t)$ 가 그들의 두 시기 비교를 어떻게 세분화하는지를 검증하는 것이 2단계의 결과 해석에서 핵심.

3.2.7 이 단계가 대답할 수 없는 것 (→ 3단계로)

- 공간이 지역 단위로 이산화되어 있다. 연속 공간의 커널 구조(거리에 따른 영향 감쇠)는 표현하지 못한다.
- 사건 유형이 '거래'뿐이다. 서로 다른 업종·브랜드가 상호작용하는 상업 상권의 구조는 다룰 수 없다.
- 지역 간 전파의 배경 — 왜 강남이 서초를 선행하는지의 구조적 이유는 α 에 흡수되어 있을 뿐 설명되지 않음. §3.7의 공변량 조건부 확장이 이를 보완할 수 있음.

3.3 단계 3 — 상업 상권 α 행렬: 시공간 Hawkes의 킬러 페이지

v0.8 개정: 단계 3도 독립 산출물로 격상된다. 이 단계의 최종 결과물은 브랜드 간 상호작용 α 행렬을 한 장의 heatmap으로 시각화하는 것이며, 이 한 장이 상권 동학의 전체 지도를 담는다. 이 그림을 단계 3의 킬러 페이지로 지정한다.

3.3.1 모형

m개 브랜드·업종에 대한 다변량 시공간 Hawkes 강도:

$$\lambda_k(t, x) = \mu_k(x) + \sum_j \sum_{\{t_i < t, \text{type}=j\}} \alpha_{\{k \leftarrow j\}} \cdot g(t - t_i; \beta) \cdot f(x - x_i; \sigma)$$


$\alpha_{\{k \leftarrow j\}}$ 는 유형 j의 사건이 유형 k의 사건을 얼마나 유발하는가를 나타내는 **m×m 비대칭 행렬**.

이 행렬이 단계 3의 핵심 해석 자원이며, 최종 산출물의 형태를 결정한다.

3.3.2 킬러 페이지 — α 행렬 Heatmap

단계 3의 최종 결과물은 단 한 장의 그림으로 요약된다: m×m 격자 위에서 행 k, 열 j의 색상이 $\alpha_{\{k \leftarrow j\}}$ 의 크기를 나타내는 **heatmap**. 아래는 m = 12 브랜드를 상정한 예시 (placeholder 값)로, 실제 데이터 추정 전 단계 3 산출물이 어떤 형태로 발표될지 보여주는 template.

그림을 읽는 규칙은 단순하다. **행 k는 유발받는 쪽, 열 j는 유발하는 쪽**. 셀 (k, j)의 색상이 '브랜드 j의 입점이 브랜드 k의 입점을 얼마나 유발하는가'의 강도. 빨강이 유발(+), 파랑이 억제(-), 흰색이 무관(0 근방). 브랜드는 카테고리별(프리미엄 커피·저가 커피·편의점·생활필수·베이커리)로 묶어 배치하여 **블록 구조**가 드러나도록 했다. 대각선은 자기-자기 관계로 자기 클러스터링의 정도를 보인다.



해석 예시: 스타벅스 → 올리브영 +0.45 (앵커 효과) · 스타벅스 → 이디야 -0.18 (포지셔닝 회피) · 블루보틀 ↔ 스타벅스 상호 음성 (차별화)

그림 3.3.1 — α 행렬 heatmap의 예시 (placeholder 값). 행 k는 유발받는 쪽, 열 j는 유발하는 쪽. 빨강은 유발(+), 파랑은 억제(-). 검은 테두리는 브랜드 카테고리(프리미엄 커피·저가 커피·편의점·생활필수·베이커리) 경계. 이 한 장이 단계 3의 컬러 페이지다.

그림에서 즉시 보이는 구조.

- **1행 1열 (스타벅스 → 올리브영) = +0.45.** 가장 진한 빨강. 앵커 효과의 시각적 정점. 스타벅스 입점 후 MZ 상권이 끌려오는 구조를 단일 셀이 담음.
- **스타벅스 → 이디야 = -0.18.** 진한 파랑. 포지셔닝 회피 — 이디야는 스타벅스의 '그림자 지역'에 입지.

- **블루보틀 ↔ 스타벅스 = (-0.24, -0.21).** 양방향 모두 음성. 프리미엄 포지셔닝의 상호 차별화.
- **저가커피 3×3 블록 (이디야·메가커피·컴포즈).** 블록 내부가 +0.17~+0.28로 전반적 양성. 자기 카테고리 클러스터링.
- **비대칭의 가시성.** 스타벅스→올리브영(+0.45)과 올리브영→스타벅스(+0.08)의 색상 대비가 앵커 효과의 *단방향성*을 즉시 전달. 숫자 표보다 한 차원 빠른 해석.
- **0 근방 셀의 분포.** 다이소·GS25처럼 다른 카테고리과 독립적으로 작동하는 브랜드는 대부분의 셀이 흰색 — 고유 상권 논리.

주요 셀의 수치 해석 (표 보조 참조). 예시로 본 α 값의 의미:

영향 관계	α 값의 예상 크기	해석
스타벅스 → 스타벅스	중~큼 (양성)	자기 클러스터링. 스타벅스가 또 다른 스타벅스를 부르는 앵커 확산
스타벅스 → 올리브영	큼 (양성)	앵커 효과. 스타벅스 입점 후 MZ 상권이 따라옴
스타벅스 → 이디야	작음 또는 음성	포지셔닝 가설. 이디야는 스타벅스의 '그림자 지역'에 입지
올리브영 → 스타벅스	작음	역방향 비대칭. 올리브영이 스타벅스를 부르지는 않음 — 앵커 효과의 단방향성
다이소 → 스타벅스	거의 0	상관 없음. 두 브랜드는 다른 상권 논리를 따름
GS25 → 모든 것	전반적으로 작음	편의점은 포화 상태 — 유발 주체가 아니라 수동적 추종 업종
블루보틀 → 스타벅스	음성 가능	프리미엄 포지셔닝 차별화. 블루보틀은 스타벅스와 떨어지려는 경향
대각선 전체	양성 (크기는 브랜드별)	자기 클러스터링의 정도 — 어느 브랜드가 뭉쳐

영향 관계	α 값의 예상 크기	해석
		서 입지하는 경향이 강한가

3.3.3 왜 이 한 장이 킬러 페이지인가

- **전체성.** 이 그림 한 장에 *모든 브랜드 쌍의 영향 관계*가 담긴다. 12 브랜드이면 144개 셀, 각 셀이 하나의 가설에 대응. 기존 도시연구가 브랜드 쌍 하나씩 개별 분석으로 다루던 것을 한 번에 본다.
- **비대칭 가독성.** 행렬이 대칭이 아니라는 점이 시각적으로 즉시 보인다. 셀 ($j \rightarrow k$)와 셀 ($k \rightarrow j$)의 색상 차이가 *영향의 방향성*을 드러냄. 상관분석이나 공간통계로는 불가능한 해상도.
- **클러스터 구조.** 행렬을 브랜드 카테고리별로 정렬(커피끼리, 편의점끼리, 생활필수끼리)하면 블록 구조가 드러남. '같은 카테고리 내 강한 양성, 카테고리 간 약한 상호작용' 같은 구조 자체가 결과.
- **정책 대화용 도구.** 정량적 배경 없이도 '빨간 셀은 강한 영향, 파란 셀은 음의 영향'이라는 직관으로 해석 가능. 행정·언론과의 대화에서 즉시 활용.
- **비교의 기준.** 서울 전체 α 행렬, 강남 국한 α 행렬, 성수 국한 α 행렬을 나란히 놓으면 *지역별 상권 논리의 차이*가 한눈에 드러남. 세 장의 heatmap으로 세 동네를 비교하는 그림 — 학술적으로도 정책적으로도 강력.

3.3.4 주의 — Markov 전이와 Hawkes α 는 다르다

이 heatmap의 색상을 'Markov 전이 확률'로 해석하면 안 된다. 둘은 형식은 비슷하지만 의미가 다르다:

- **Markov 전이:** 현재 상태가 X일 때 다음 시점에 상태가 Y가 될 조건부 확률. *상태 전이*.
- **Hawkes α :** 유형 j의 사건이 한 번 발생한 뒤, 그것이 향후 유형 k의 사건 강도를 얼마나 증폭시키는가. *사건 자극*.

Markov는 *상태에 있다가 다른 상태로 건너감*을 다루고, Hawkes는 *사건이 일어났을 때 다른 사*

건의 발생률이 얼마나 뛰는가를 다룬다. 동일 지점에서 스타벅스가 올리브영으로 바뀌는 전환도 물론 있지만, 본 연구의 α 는 공간적으로 떨어진 새 입점에 미치는 영향까지 포함한다. 시각화 형식이 유사하다고 해서 해석을 혼동하면 결론이 크게 달라진다.

3.3.5 추가 산출물

- 브랜드 카테고리별 블록 구조 분석 — 프리미엄 커피 vs 저가 커피, 편의점 내부, 생활필수 내부의 α 하위행렬
- 주요 앵커 브랜드의 '중력권' 시각화 — $\alpha_{\{k \leftarrow \text{스타벅스}\}}$ 가 큰 k 들의 분포, 공간 커널 f 와 결합해 '스타벅스 영향권 지도' 생성
- 분기비 $n^*_k = \sum_j \alpha_{\{k \leftarrow j\}} / \beta$ — 각 브랜드 입점의 '자극 다중효과'. 1에 가까운 브랜드가 상권 확산의 진원지
- 시기별 α 행렬 변화 — 2015·2020·2024 세 시점의 heatmap 비교로 상권 논리 변화 추적

3.3.6 공간 커널의 선택

두 후보를 비교한다:

- **지수 커널:** $f(r) \propto \exp(-r/\sigma)$ — 수학적으로 깔끔, 국소적 영향 강조.
- **거듭제곱 커널:** $f(r) \propto (r_0+r)^{-p}$ — 두꺼운 꼬리, 원거리 영향 허용. 실제 상권 전이가 이쪽에 가까울 것으로 추측.

AIC/BIC와 QQ 잔차분석으로 선택한다.

3.3.7 이 단계가 대답할 수 없는 것 (→ 4단계로)

- 유클리드 거리의 암묵적 가정. 강남역과 신논현역은 직선으로 500m지만, 가로수길과 도산대로는 직선으로 200m인데도 상권은 완전히 분리된다. 유클리드는 틀렸다.
- 브랜드 이분법의 부재. 스타벅스·이디야·다이소는 모두 체인이다. 소규모 로컬 자영업자와 대형 프랜차이즈의 구별이 없어 젠트리피케이션 핵심 동학(축출)을 다루지 못함. 4단계의 Blue/Red 설계가 이를 보완.

3.4 단계 4 — 네트워크 커널: 도시의 실제 기하

모형

공간을 2D 평면이 아니라 도로 네트워크 $G = (V, E)$ 로 본다. 커널의 거리 인수를 유클리드 거리 $\|x-y\|$ 대신 네트워크 측지거리 $d_G(x,y)$ 로 대체한다:

$$f_{\text{network}}(x, y) \propto \exp(-d_G(x,y) / \sigma)$$

왜 가로수길인가

가로수길은 지하철역(신사역)으로부터 '하나의 축'이 뻗어 있는 선형 상권이다. 이 구조를 유클리드 커널은 원으로 이해하고, 네트워크 커널은 축으로 이해한다. 두 커널의 예측 차이가 **가장 선명하게 드러날 수 있는 전범**이다.

기술적 난점

- 네트워크 커널이 공간에 대해 적절히 정규화되어야 한다(경로 밀도에 따른 편향 보정). Okabe & Sugihara(2012)의 network KDE 방법론 참고.
- 측지거리 계산의 $O(N^2 \log N)$ 비용. 사전 Dijkstra 테이블을 캐시해 적합 시 재사용.
- 데이터: OpenStreetMap 서울 도로망 → OSMnx로 그래프화. 보도·이면도로 포함 여부는 민감도 분석.

3.5 단계 5 — 잠재 $\mu(x)$: 배경율의 해방

지금까지 μ 를 상수로 둔 것이 왜 문제인가

1~4단계 내내 배경율 μ (혹은 μ_k)는 공간에 대해 상수였다. 그러나 실제로 스타벅스가 자발적으로 생길 확률은 '기본적으로 그 지점이 얼마나 입지가 좋은가'에 크게 의존한다. 인구밀도, 유동인구, 임대료, 교통 접근성 — 이런 공간적 이질성을 μ 가 담아내야 한다.

μ 를 상수로 두면 어떤 일이 벌어지나? **자기여기 α 가 과대추정된다**. 입지가 좋아 자생적으로 발생한 사건이 '이전 사건에 의해 유발된 것'으로 잘못 귀속되기 때문이다. 이것이 Mohler 연구의 핵심 통찰이다.

모형

$$\lambda(t, x) = \mu(x) + \sum_{\{t_i < t\}} \alpha \cdot g(t-t_i) \cdot f(x-x_i)$$

$\mu(x)$ 는 비모수 공간 함수. Mohler(2011)의 접근을 따라 Gaussian smoothing으로 표현한다:

$$\mu(x) = \sum_i (1-p_{ii}) \cdot K_{\sigma}(x - x_i) / T$$

여기서 p_{ii} 는 사건 i 가 '배경 사건일 확률'로, E-step에서 얻는다.

EM 절차

E-step: 각 사건 쌍 $(i, j), j < i$ 에 대해

$$p_{ij} = \alpha \cdot g(t_i - t_j) \cdot f(x_i - x_j) / \lambda(t_i, x_i)$$

그리고 $p_{ii} = \mu(x_i) / \lambda(t_i, x_i)$. 직관: 사건 i 의 '부모'가 누구인가에 대한 사후분포. 이것이 이 모델의 잠재변수.

M-step: p_{ij} 를 가중치로 써서 α, g 의 모수, 그리고 $\mu(x)$ 를 업데이트.

왜 스타벅스 revisited인가

1단계에서 KDE로 봤을 때 '핫스팟'이었던 지역이, 5단계에서 $\mu(x)$ 로 분리해 보면 두 가지로 갈라진다.

- $\mu(x)$ 가 높은 곳 — 본래부터 입지가 좋은 지역. 스타벅스가 앵커 효과로 온 게 아니라 '올 수밖에 없던' 곳.
- $\mu(x)$ 는 낮는데 매장이 많은 곳 — 앵커 효과가 실제로 작동한 지역. 즉 '한 매장이 다른 매장을 부른' 지역. 정책적으로도, 학술적으로도 훨씬 흥미로운 영역.

이 분해가 5단계의 기여다. 처음에는 단일 핫스팟이었던 것이, 단계를 거치며 '자생형 스타벅스'와 '연쇄형 스타벅스'로 나뉜다. 같은 데이터, 더 나은 렌즈.

실행상 주의점 (자신에게 남기는 메모)

- EM은 β 를 고정한 채 먼저 돌린다. β 까지 동시에 업데이트하려 들면 identifiability 문제로 수렴이 이상해진다. 단계적으로: 우선 μ, α 만 업데이트 → 안정화되면 β 포함.
- EM의 초기값 민감도. 여러 초기값으로 돌려 수렴 지점 비교 필수.
- Gaussian bandwidth σ 선택: Silverman's rule 또는 교차검증.
- 수렴 진단: 로그우도 변화 $< \epsilon$, 모수 변화 $< \epsilon$, 둘 다 만족할 때 멈춤.

이 단계가 대답할 수 없는 것 (→ §3.7로)

v0.6에서 추가된 자기비판. 5단계로 μ 를 공간 함수로 해방하는 것만으로는 여전히 부족하다.

- **이벤트 유형별 독립 $\mu_k(x)$ 의 논리적 부자연스러움.** 4단계(§3.6)에서 $\mu_{\{B^*\}}(x)$, $\mu_{\{B^-\}}(x)$, $\mu_{\{R^*\}}(x)$, $\mu_{\{R^-\}}(x)$ 를 독립 추정했다. 그러나 *폐점 배경을* $\mu_{\{B^-\}}(x)$ 는 공간의 함수가 아니라 **그 지점의 현재 Blue 점포 수의 함수**여야 한다. 폐점하려면 먼저 점포가 존재해야 한다. $\mu_{\{B^-\}}(x)$ 가 단순히 공간 x 의 함수로 추정되면, 실제로는 '점포가 많아서 폐점 사건이 많이 관측된다'를 '이 지점은 원래 폐점이 잘 나는 곳이다'로 잘못 해석한다. 이는 모델의 상태 공간이 확장되어야 함을 시사한다 — 순수 Hawkes 프레임의 구조적 한계.
- **시간적 비정상성(non-stationarity)의 공백.** $\mu(x)$ 는 공간 함수이지만 시간에는 상수다. 그렇다면 젠트리피케이션 4기 공동화 — '아무도 점포를 새로 열지 않는 시기' — 는 모델이 어떻게 설명할 것인가? α 계수에 억제(inhibition) 효과를 넣거나, 배경율이 시간에 따라 변한다는 것을 *명시적으로 모델에 포함*해야 한다. 전자는 선형 Hawkes의 $\alpha \geq 0$ 제약과 충돌하고, 후자는 $\mu(x, t)$ 로의 확장을 요구한다.
- **인과가 아닌 시간 의존성.** $\mu(x, t)$ 로 만들면 '시간에 따라 배경율이 바뀐다'를 서술할 수는 있지만 *왜 바뀌는지*는 모델 안에 없다. 비정상성을 설명 없이 서술만 한다. 이를 해소하려면 μ 를 *외생 공변량* — 임대료, 유동인구, 지하철 이용, 주변 오피스 공실 — 의 함수로 조건화해야 한다. §3.7에서 다룬다.

3.6 단계 4 심화 — Blue/Red 2×2 이벤트 설계

이 절은 v0.2에서 신설되었다. 다섯 단계 중 4단계(가로수길)가 가장 큰 공공적 파급력을 가진다는 판단에 따라, 해당 단계를 독립된 장으로 확장한다. 이 설계는 젠트리피케이션 문제에 직접 조준된, 이 로드맵에서 가장 응용적 기여를 목표로 하는 부분이다.

3.6.1 핵심 아이디어: 자영업의 두 세계

젠트리피케이션의 본질은 지역 특색의 생성·유지·상실이라는 과정이다. 이 과정의 행위자는 크게 두 부류로 나뉜다.

- **Blue** — 소규모 자본의 로컬 자영업자. 독립 카페, 편집숍, 작가·장인의 공방, 오너 셰프의 식당. 이 지역만의 질감을 만드는 주체. 공간에 대한 애착이 사업모델의 일부.
- **Red** — 대규모 자본의 프랜차이즈. 본사 결정으로 입점하는 체인 카페, 글로벌 브랜드 매장, 대형 F&B 기업. 지역 특색을 소멸/하되 그 유지에 기여하지 않는 주체. 높은 임대료 수용 능력으로 Blue를 밀어내는 효과까지 가진다.

두 부류에 입점/폐점의 축을 교차하면 4개의 이벤트 유형이 생긴다:

- **B⁺** — Blue 입점 (지역 특색 생성)
- **B⁻** — Blue 폐점 (지역 특색 소실)
- **R⁺** — Red 입점 (동질화 가속)
- **R⁻** — Red 폐점 (공동화 또는 전략적 후퇴)

3.6.2 수리 모델

4-변량 시공간 Hawkes 과정. 유형 $k \in \{B^+, B^-, R^+, R^-\}$ 의 조건부 강도는:

$$\lambda_k(t, x) = \mu_k(x) + \sum_{j \in \{4\text{유형}\}} \sum_{i: \text{type}_i=j, t_i < t} \alpha_{\{k \leftarrow j\}} \cdot g(t-t_i) \cdot f_G(x, x_i)$$

여기서 $\alpha_{\{k \leftarrow j\}}$ 는 유형 j 의 과거 사건이 유형 k 의 미래 사건을 유발하는 강도. $4 \times 4 = 16$ 개의 계수가 추정 대상이며, 이 행렬 전체가 해당 지역의 젠트리피케이션 메커니즘 지문이다. f_G 는 3.4 절에서 도입한 네트워크 커널을 쓴다(도로망 측지거리 기반).

3.6.3 16개 계수의 정책적 의미

이 표가 이 방법론의 해석 자원의 전부다. 각 계수는 하나의 가설 또는 정책 질문에 대응한다.

계수	가설 / 현상	정책적 함의
$\alpha(B^* \leftarrow B^*)$	크리에이티브 클러스터링: Blue가 Blue를 부른다	1기(태동)의 주된 동학. 이 계수가 지배적일 때는 개입 불필요·오히려 지원
$\alpha(R^* \leftarrow B^*)$	파도타기: Blue가 깔아둔 매력을 Red가 추격 진입	2→3기 전환의 조기 신호. 이 계수가 상승하면 경고 등
$\alpha(B^- \leftarrow R^*)$	직접 축출: Red 진입이 Blue를 밀어낸다	인과 해석에 가장 근접한 계수. 정책 개입의 근거로 가장 강력
$\alpha(R^* \leftarrow R^*)$	앵커 효과: Red가 Red를 부른다	동질화의 가속 단계. 이 시점에는 이미 개입의 창이 좁음
$\alpha(B^- \leftarrow B^-)$	도미노 폐점: Blue 폐점이 다른 Blue를 데려간다	클러스터 붕괴 단계. 상권 공동체의 네트워크 효과 소멸
$\alpha(R^- \leftarrow R^-)$	연쇄 철수: Red가 Red를 따라 나간다	4기(쇠퇴)의 지표. 가로수길 최근 공실률 급증에 대응
$\alpha(R^* \leftarrow B^-)$	공백 대체: Blue가 떠난 자리를 Red가 채운다	기존 '지대격차론'이 예측하는 경로의 직접적 검증
$\alpha(B^* \leftarrow R^-)$	재생: Red가 빠진 자리를 Blue가 회복	정책적으로 가장 바람직한 계수. 자연적으로는 작을 것으로 예상
나머지 8개	여러 혼합 경로 ($B^- \leftarrow B^*$, $R^- \leftarrow R^*$ 등)	계수값이 작을 것으로 예상되지만, 0이 아니라면 중요한 기전 시사

3.6.4 Rolling window 추정: $\alpha(t)$ 의 궤적

이 방법론의 결정적 강점은 α 행렬을 시간의 함수로 풀어내는 데 있다. 전 기간을 한 번에 적합

하면 '평균적 구조'만 나온다. 그러나 젠트리피케이션은 본질적으로 **단계 전이(regime transition)**의 현상이다. 1기의 가로수길과 3기의 가로수길은 근본적으로 다른 체제다.

방법. 창 크기 Δ (예: 24개월), 이동 간격 δ (예: 3개월)로 부분 데이터를 잘라 각 창마다 MLE로 $\alpha_{\{k \leftarrow j\}}(t)$ 를 추정한다. 결과는 16개의 시계열 곡선.

$$\alpha_{\{k \leftarrow j\}}(t) = \operatorname{argmax}_{\alpha} \ell([t-\Delta, t] \text{ 구간 데이터}; \alpha, \dots)$$

왜 이것이 중요한가

- **단계 전이의 조기 탐지.** $\alpha(R^* \leftarrow B^*)$ 이 완만하게 증가하다 특정 시점에 급등하는 패턴이 반복적으로 관측된다면, 이것은 '개입의 골든타임이 닫히는 신호'다. 정적 분석으로는 절대 보이지 않는다.
- **구조 변화(structural break) 검정.** $\alpha(B^* \leftarrow R^*)(t)$ 의 궤적에서 Chow test 유사 절차로 전환점 식별. 이것이 젠트리피케이션의 '단계 경계'의 *모델 기반 정의*가 된다.
- **후보 지역 예측.** 현재 성수동·연남동의 $\alpha(t)$ 궤적이 2010년대 가로수길 궤적의 어느 시점과 가장 유사한지 매칭. *공간이 아닌 '진행도'로 비교*하는 새로운 방법.

Rolling window 크기의 민감도

Δ 가 너무 작으면 추정 분산이 크고, 너무 크면 체제 변화가 평활된다. 해결: 여러 Δ (12, 24, 36개월)로 동시에 돌려 '일치하는 신호'만 채택. 실무적으로는 다중 대역폭(multi-bandwidth) 앙상블에 해당.

3.6.5 예상 산출물

- 16개 $\alpha_{\{k \leftarrow j\}}(t)$ 곡선 + 신뢰구간 (bootstrap)
- 행렬 시계열의 구조변화 시점 — '단계 경계'의 정량적 정의
- 인접 지역 확산의 공간 궤적 — Red 영향권의 팽창 반경 $\sigma_G(t)$
- 개입 시나리오 시뮬레이션 — '만약 t^* 시점에 Red 진입을 12개월 지연시켰다면 Blue의 폐점 사건은 N건 감소'

3.6.6 표본 부족 대응 — 시기별 2변량 분해 (Phase-Specific Decomposition)

v0.4 신설. v0.3까지는 4-변량 16계수를 한꺼번에 추정하는 것을 전제로 했으나, 현실적으로 좁은 지역·짧은 기간에서 16개 계수 동시 추정에 필요한 표본이 확보되지 않을 가능성이 있다. 이 소절은 그 경우의 우아한 fallback을 제시한다.

핵심 아이디어

젠트리피케이션의 시기(phase)마다 실제로 활성화되는 이벤트 유형은 다르다. 1기(태동)에는 B⁻과 R⁻가 거의 없고, 4기(공동화)에는 B⁺가 거의 없다. 그렇다면 전 기간에 대해 4×4=16개 계수를 푸는 대신, 각 시기의 지배적 2개 이벤트 유형만 뽑아 2×2=4개 계수를 집중 추정한다.

이렇게 하면 (i) 표본 효율이 4배 증가, (ii) 관심 계수가 분석 프레임 내에서 선명해지고, (iii) 시기 자체가 분석 단위가 된다는 이론적 선명성까지 덤으로 얻는다.

시기별 설계

시기	활성 이벤트 집합	핵심 2×2 계수	검정 가설
1~2기: 태동·편승	{B ⁺ , R ⁺ }	$\alpha(B^+ \leftarrow B^+)$, $\alpha(R^+ \leftarrow B^+)$, $\alpha(B^+ \leftarrow R^+)$, $\alpha(R^+ \leftarrow R^+)$	Blue 클러스터가 먼저 형성되는가? Red 파도타기의 시간 지연은?
2~3기: 자본교차·축출	{B ⁻ , R ⁺ }	$\alpha(B^- \leftarrow B^-)$, $\alpha(B^- \leftarrow R^+)$, $\alpha(R^+ \leftarrow B^-)$, $\alpha(R^+ \leftarrow R^+)$	이 시기의 연구 핵심. $\alpha(B^- \leftarrow R^+)$ 가 유의하게 양수인가? — 축출 가설의 직접 검정
4기: 쇠퇴·공동화	{B ⁻ , R ⁻ } 또는 {R ⁺ , R ⁻ }	$\alpha(R^- \leftarrow R^-)$, $\alpha(R^- \leftarrow B^-)$, $\alpha(B^- \leftarrow R^-)$, $\alpha(R^+ \leftarrow R^-)$	연쇄 철수가 존재하는가? 상권 공동 화의 속도는?

시기 경계의 결정

시기(phase)를 연구자가 임의로 자르지 않고 두 가지 방법 중 하나로 식별:

- **(a) 문헌 근거.** 허자연 등(2015), 이인성·배재흠(2013) 등 가로수길·경리단길 단계 연구의 합의된 시기 구분을 1차 근거로 사용. 예: 가로수길 1기 ≈ 2005-2008, 2기 ≈ 2009-2012, 3기 ≈ 2013-2017, 4기 ≈ 2018-현재.

- **(b) 데이터 기반.** 전 기간 $\alpha(t)$ 궤적(\$3.6.4)에서 구조변화점(change point)을 통계적으로 식별 후, 그 경계로 시기를 분할. *방법이 자신의 시기 정의를 만들어낸다는 점에서 더 엄격한 접근.*

두 접근을 모두 보고하고, 경계 차이가 결과에 미치는 민감도를 명시한다.

분해의 수학적 정당성

엄밀히 말하면 '시기별로 다른 이벤트 유형만 활성화'는 근사이며, 실제로는 1기에도 B가 드물게 발생한다. 이 근사를 사용하는 근거는:

- 드문 이벤트는 표본이 적어 해당 α 계수의 *추정 분산이 크고* 어차피 유의성을 얻기 어렵다. 모델에서 제외하는 것이 정보 손실 없이 노이즈를 줄인다.
- 분해된 각 2변량 모델은 독립적으로 적합·해석 가능하다. 시기별 결과를 *나열*하는 것이 16계수 추정 실패보다 낫다.
- 전 기간 통합 4변량 모델이 표본 확보 후 성공한다면 분해 모델은 *검증용 baseline*으로 재활용. 통합 모델의 계수가 시기별 분해 계수와 일관된지 교차 확인.

판단 기준 — 언제 분해를 선택하는가

다음 조건이 만족되면 통합 4변량 시도, 미달이면 분해로 전환:

- **표본 크기.** 각 이벤트 유형별 $N_k \geq 50$ (16계수 추정의 대략적 하한). *하나라도* 미달이면 분해.
- **수렴 안정성.** 통합 MLE의 bootstrap 추정에서 α 계수 신뢰구간이 $(-\infty, +\infty)$ 를 포함하거나 부호가 불안정하면 분해.
- **해석 우선순위.** 정책적 관심이 특정 시기(예: 2~3기 축출)에 집중되어 있다면, 통합 모델이 기술적으로 가능해도 *의도적으로* 해당 시기 2변량 모델을 별도 발표.

데이터 기반 Reduced Set 선택 (v0.5 보완)

v0.4에서는 시기별로 활성 이벤트 집합을 *선택적으로* (문헌에 따라) 고정했다. 그러나 선택적 가정은 *가로수길에 맞춘 것*이며, 다른 지역이나 예상치 못한 동학을 놓칠 수 있다. v0.5는 선택적

틀과 데이터 관측을 교차검증하는 2단계 절차로 보완한다.

절차.

- ① **선행적 시기 분할**. §3.6.6 상단의 시기 구분(문헌 또는 $\alpha(t)$ 구조변화점)을 1차 기준으로 적용. 각 시기 τ 에 대한 부분 데이터셋 D_τ 를 추출.
- ② **이벤트 분포 관찰**. 시기 τ 안에서 네 이벤트 유형별 표본 수 $\{N_k(\tau) : k \in \{B^+, B^-, R^+, R^-\}\}$ 를 관측. *어떤 유형이 얼마나 드문지 데이터가 직접 말하게 한다.*
- ③ **Reduced set 결정**. 다음 criterion 중 선택:
 - **Criterion A (threshold)**. $N_k(\tau) \geq N_{\min}$ (예: 20 이벤트)인 유형들만 모델에 포함. 희소 유형은 배경 소음으로 무시.
 - **Criterion B (information)**. 전체 4변량 모델과 후보 reduced 모델들(3변량, 2변량)을 AIC/BIC로 비교해 자동 선택.
 - **Criterion C (hybrid)**. A로 1차 필터 → B로 최종 선택. 본 연구의 기본 경로.
- ④ **선행적 가정과의 대조**. 데이터가 선택한 active set이 §3.6.6 표의 선행적 set과 *일치하는가* 명시적으로 보고. 불일치는 **발견(finding)**으로 다룬다 — 예: '가로수길 1~2기에 R^+ 가 예상보다 많았고, 이는 선행 연구가 놓친 조기 철수 현상을 시사'.

이 보완이 주는 것

- **지역 이식성**. 성수동이나 홍대에 동일한 파이프라인을 적용할 때, 그 지역의 시기별 활성 이벤트는 *가로수길과 다를 수 있다*. 데이터 기반 선택은 이 차이를 자동으로 수용한다.
- **가설 검정 장치**. 선행적 active set과 데이터 기반 active set의 불일치는 그 자체로 학술적 발견이 된다. '어느 시기의 어떤 이벤트가 의외로 많다/적다'라는 질문은 *v0.4의 선행적 틀로는 제기조차 불가능했던* 질문이다.
- **과적합 방지**. AIC/BIC 기반 선택은 필요 이상의 계수 추정을 자동 억제. 특히 4기 데이터가 풍부해 보여도 실제로는 R^+R^- 쌍만 유의미하다면, 2×2 로 과감히 줄여 해석 선명성을 지킨다.

3.6.7 공간 표본 확장 — 지역 위계 fallback

v0.4 신설. 가로수길만으로 표본이 부족할 경우의 공간적 확장 전략.

세 층위의 지역 위계

계층	범위	예상 이벤트 규모 (2010-2024)	사용 시점
T1 (우선)	신사동 가로수길 500m 반경	수백 건 규모 추정	T1으로 충분하면 T1만 사용. 단일 지역 모델의 선명성
T2 (확장)	신사동 전체 (가로수길 + 세로수길 + 도산대로 + 압구정 인접부)	천~수천 건 추정	T1 표본 부족, 그러나 공간적으로 연속된 동일 상권 내 확장
T3 (비교)	홍대/연남동, 성수동, 경리단길, 익선동 등 유사 상권	지역당 수백~천 건	T2도 부족하거나 '가로수길 특이성 검증'이 목적일 때

Multi-site Hawkes 모델

T3를 사용할 때의 통계적 설계. 각 지역 $\ell \in \{\text{가로수길, 홍대, 연남, 성수, 경리단, ...}\}$ 마다:

$$\lambda^{(\ell)}_k(t, x) = \mu^{(\ell)}_k(x) + \sum_j \sum_i \alpha^{(\ell)}_{\{k \leftarrow j\}} \cdot g(t-t_i; \theta_g) \cdot f(x-x_i; \theta_f)$$

핵심 선택: 커널 모수 (θ_g, θ_f)는 지역 간 **공유**하되, 배경율 $\mu^{(\ell)}$ 와 상호작용 계수 $\alpha^{(\ell)}$ 는 지역별로 독립 추정. 이것이 **지역 특수성**($\alpha^{(\ell)}$ 의 차이)과 **통계적 검출력**(g·f 공유로 유효 표본 배가) 사이의 절충점이다.

지역 간 비교가 만들어내는 새로운 질문들:

- 가로수길의 $\alpha(B^* \leftarrow R^*)$ 와 홍대의 같은 계수가 다른가? 다르다면 왜?
- 이미 쇠퇴가 완료된 경리단길의 $\alpha(R^* \leftarrow R^*)$ 가 현재 성수동의 예측 궤적이 될 수 있는가?
- 지역별 커널 대역폭 σ_G 의 차이가 '상권의 크기' 자체를 정량화하는가?

구현 우선순위 fallback

Multi-site 구현이 기술적으로 난항을 겪을 경우의 fallback의 fallback:

- ① **Multi-site (커널 공유)** — 최선의 통계적 설계
- ② **Sequential** — 가로수길 T2까지 단독 완료 후, T3 지역들을 독립 복제로 적합.
비교는 결과 수준에서
- ③ **가로수길 단독 + T3 시각화** — α 추정은 가로수길에서만, 다른 지역은 §3.1의 H3 heatmap으로만 비교

판단 기준: T1 표본이 §3.6.6 기준으로 충분하면 거기서 멈춘다. 과도한 확장은 연구의 초점을 흐린다. 공공성 큰 4단계의 핵심 메시지는 '가로수길 한 곳에 무엇이 일어났는가'이며, 다수 지역 비교는 이 메시지의 보강 도구이지 대체물이 아니다.

3.6.8 파라미터 전이 전략 — 외적 타당성과 Transfer Learning

v0.5 신설. §3.6.7의 multi-site 설계를 외적 타당성(external validity) 관점에서 체계화한다. 한 지역에서 추정한 파라미터를 다른 지역에 어떻게 쓸 것인가 — 그리고 쓰지 말아야 할 때는 언제인가.

대전제: Blind Transfer는 금지

가로수길에서 추정한 전체 파라미터 집합을 성수동·홍대에 그대로 복사해 적용하는 것은 금지한다. 지역 특수성(임대료 수준, 상권 역사, 도시 형태, 소비자 구성) 차이로 인해 체계적 편향이 발생하며, 정책 판단에 잘못 쓰이면 실재하지 않는 위험을 경고하거나 실재하는 위험을 놓치는 반대 방향 오류를 낳는다. 이는 공공성을 가진 연구에서 가장 피해야 할 결과다.

그러나 blind transfer 금지가 어떤 형태의 전이도 불가를 뜻하지는 않는다. 파라미터의 성격에 따라 전이 가능성이 다르며, 용도에 따라 전이가 유익한 경우도 있다. 아래에서 파라미터를 세 층위로 분해해 차별적으로 다룬다.

3층위 전이 가능성

파라미터	전이 가능성	근거 및 처리 원칙

파라미터	전이 가능성	근거 및 처리 원칙
$\mu(x)$ — 배경율	불가	지역의 자생적 입지력. 유동인구·지하철 접근성·상가 구획·원주민 구성의 함수. 가로수길의 $\mu(x)$ 는 가로수길 데이터로만 추정한다. 다른 지역에 이식 시 모델의 기초가 무너진다.
$g(t; \beta), f_G(x; \sigma_G)$ — 커널	조건부 가능	시간 감쇠 속도(β)와 공간 파급 반경(σ_G)은 <i>물리적 전파 구조</i> 를 나타낸다. 두 지역의 도시 형태가 유사하다면(예: 둘 다 선형 상권) 공유 가능. 형태가 다르면(가로수길 선형 vs 홍대 격자 vs 성수 공장 재생) 공유 불가. §3.6.7의 multi-site 설계에서 유사도 검증 후 조건부 공유 .
$\alpha_{\{k \leftarrow j\}}$ — 상호작용	용도 의존	'메커니즘 지문'. 지역 특수성이 가장 강하게 반영되는 파라미터. 점 추정값 복사는 금지 하되 아래 세 가지 용도로 활용 가능 (다음 소절).

α 행렬의 세 가지 활용

α 를 다른 지역에 '값으로 이식'하는 것은 금지되지만, *구조 안에서 재활용*하는 것은 가능하고 유익하다.

용도 ① — 비교 연구 (독립 추정).

두 지역 각각에서 독립적으로 α 를 추정한 뒤, **계수 차이**를 분석 대상으로 삼는다. 예: 가로수길의 $\alpha(B \leftarrow R^*)$ 는 0.42, 성수동은 0.18이라면 '성수동의 직접 축출 강도는 가로수길의 절반 이하'라는 구체적 진술이 가능. *이식하지 않기 때문에* 얻어지는 결과다. 본 연구의 기본 경로.

용도 ② — 베이지안 Prior / Warm-start 초기값.

표본이 극도로 적은 지역(신흥 상권, 짧은 관측 기간)에서 MLE가 수렴하지 않거나 계수 부호가 불안정할 때. 가로수길의 α 추정값을 **초기값**(warm start)으로 주거나, 가로수길 bootstrap 분포를 **약한 prior**로 부여하여 최적화 공간을 좁힌다. 중요한 차이:

- **Warm start:** 점 추정값 복사, 그 후 자유롭게 이동. 데이터가 충분하면 흔적 없이 지워짐.
- **Bayesian prior:** 가로수길 사후분포를 새 지역의 사전분포로 사용. 데이터가 부족한 방향의 추정은 prior에 끌리고, 데이터가 풍부한 방향은 자유롭게 이동. 수학적으로 더 원리적이며, 불확실성을 명시적으로 전파.

두 방법 모두 *최종 추정값은 새 지역의 데이터가 지배하며*, prior의 영향력은 *보고서에 명시*한다(예: '성수동 $\alpha(B^* \leftarrow R^*)$ 의 사후분포 중 prior 기여도 약 15%').

용도 ③ — 정책 시뮬레이션의 '거울'.

이 용도는 방법론적 보강을 넘어 이 연구의 정책적 기여를 한 단계 끌어올리는 독립적 발상이다.

쇠퇴기가 이미 완료된 지역(예: 가로수길 2018~2024)의 α 궤적은 **젠트리피케이션의 완성된 각본**이다. 이 각본을 현재진행형인 신흥 상권(예: 2024년 성수동, 익선동)에 **강제 주입**하여 what-if 시뮬레이션을 돌린다:

$\lambda^{\wedge}(\text{성수}, \text{sim})_k(t, x) = \mu^{\wedge}(\text{성수})_k(x) + \text{가로수길의 } \alpha_{\{k \leftarrow j\}}(t) \cdot g(t - t_i) \cdot f(x - x_i)$
 성수동의 현재 배경을 $\mu(x)$ 와 과거 사건들은 그대로 유지한 채, **상호작용 계수만 가로수길의 쇠퇴기 궤적으로 대체**. 시뮬레이션 결과로 '만약 성수동이 가로수길과 같은 메커니즘으로 전개된다면 향후 N개월간 B* 사건은 k건 발생'이라는 **조건부 예측**을 얻는다.

이 시뮬레이션의 해석상 유의점:

- **예측이 아닌 조건부 예측.** '만약 ~라면 ~일 것이다'의 형식. 무조건 예측이 아님을 항상 명시.
- **결정론이 아니다.** 성수동이 가로수길을 반드시 따른다는 뜻이 아니라, '따랐을 경우의 결과'를 수치화한 것. 두 지역의 α 궤적이 실제로 닮아가는지는 별개로 모니터링.
- **정책 대화의 도구.** '지금 개입하지 않으면 3년 뒤 무슨 일이 벌어질 수 있는가'를 구체적 수치로 제시. 행정·언론·상인에게 골든타임 개념이 체화 가능.

- **다중 거울 비교.** 가로수길만이 아니라 경리단길·홍대 각각의 쇠퇴기 α 를 주입해 *세 개의 가능한 미래*를 제시. 어느 각본에 가장 근접한지는 성수동 자체의 이후 데이터가 판정.

전이 가능성 판정 절차

파라미터를 새 지역에 쓰기 전 다음 점검을 통과해야 한다:

- ① **지역 유사도 검증** — 도시 형태(선형 vs 격자 vs 공장재생), 상권 성격(관광 vs 주거 vs 사무), 상권 성숙도(태동/번영/쇠퇴)를 정성적 체크리스트로 평가.
- ② **커널 공유 검정** — multi-site MLE에서 커널 공유 모델과 지역별 독립 모델의 likelihood ratio test. 공유가 기각되면 이식 포기.
- ③ **α 사용 용도 명시** — 비교/Prior/시뮬레이션 중 어느 용도인지 선언. Prior나 시뮬레이션의 경우 결과에 '전이 가정이 반영됨'을 명시적으로 표기.
- ④ **민감도 보고** — Prior 강도나 시뮬레이션 주입 계수를 여러 값으로 돌려 결과의 의존도 제시.

이 설계가 기존 비판을 해소하는 방식

'한 지역의 결과를 다른 지역에 쓰는 것은 위험하다'는 비판은 옳지만, 비판이 겨냥하는 것은 *blind transfer*이지 *구조화된 재활용*이 아니다. 본 연구는:

- $\mu(x)$ 는 절대 공유하지 않음 — 기초가 된다.
- 커널은 유사도 검정 후에만 공유 — 조건부다.
- α 는 값이 아닌 구조로 활용 — 비교/prior/시뮬레이션의 세 용도 각각이 blind transfer가 아니다.

이로써 '가로수길에 과적합된 모델'이라는 우려는 제거된다. 가로수길 결과는 **다른 지역 분석의 재료**이지 **결론**이 아니다.

Part II — 관문: 과연 이 모델로 충분한가

v1.0 신설. Part I에서 세운 1~5단계 모델들이 서울의 상권과 부동산 동학을 정말 설명하는가? 더 복잡한 모델이 필요한가? 이 질문에 답해야 Part III의 2차 라운드로 넘어갈 정당한 이유가 생긴다. Part II는 부록성 검증 챕터가 아니라 다음 라운드를 부르는 관문이다.

Part II의 관심사는 Part IV의 관심사와 다르다. Part IV는 '더 복잡한 모델을 어떻게 식별 가능하게 세울 것인가'를 묻는다. Part II는 '더 복잡한 모델이 정말 필요한가'를 묻는다. 순서는 중요하다 — 필요성이 먼저, 식별이 나중이다.

§II.1 모델 적합도와 복잡성의 정당화

오캄의 면도날은 본 연구의 동반자다. 단계를 올리며 모수가 늘어나는데, 그 확장이 실제 데이터로 정당화되지 않으면 *과적합된 서사*에 불과하다. Part II의 4차에 걸친 심판이 각 단계의 존재 이유를 데이터에 근거해 평가한다.

네 심판관은 서로 다른 각도에서 모델을 본다:

- AIC-BIC — 정보 기준: '복잡성 대비 설명력'의 기계적 비교
- Ogata residuals — 잔차 진단: '시간 재척도 후 Poisson이 되는가'
- out-of-sample predictive likelihood — 홀드아웃 예측력: '훈련하지 않은 데이터에서도 잘 작동하는가'
- simulation-based recovery — 합성 데이터 복원: '내가 만든 진짜 답을 내 방법이 찾아내는가'

네 심판관이 한목소리로 같은 결론을 내면 그 결론을 믿는다. 엇갈리면 그 엇갈림 자체가 다음 라운드의 과제다.

§II.2 1차 심판관 — 정보 기준: AIC, BIC

$AIC = -2\ell + 2k$, $BIC = -2\ell + k \log N$. 두 지수 모두 로그우도가 좋을수록 좋고, 모수 수가 많

올수록 나쁘다'는 판단. 1단계(KDE) → 2단계(시간 Hawkes) → 3단계(ST-Hawkes) → 4단계(네트워크 커널) → 5단계(EM μ)로 올라갈수록 모수가 늘어난다. 각 단계의 AIC/BIC가 **단조 감소**하는가?

- 단조 감소하면: 모든 단계의 복잡성 추가가 정당화됨.
- 중간에 증가 구간이 있으면: 그 지점에서 '모델이 과적합을 시작했다'는 신호. Part III에서 그 단계를 재검토할 대상.
- BIC가 더 보수적(큰 k 벌칙)이므로 AIC와 BIC 결론이 다르면 '표본 크기 대비 복잡성'의 문제.

§II.3 2차 심판관 — residual diagnostics: Ogata residuals와 시공간 잔차

Ogata(1988)의 시간 재척도 정리: 적합된 Hawkes 과정에서 $\tau_i = \int_0^{\tau_i} \lambda(s) ds$ 로 정의한 τ_i 들은 **단위율 Poisson 과정**을 이뤄야 한다. 즉 $\{\tau_i - \tau_{i-1}\}$ 은 독립 $\exp(1)$ 분포.

- QQ 플롯: τ_i 의 경험 분포 vs 이론 $\exp(1)$. 직선에서 벗어나면 모델이 사건 집단성을 설명 못함.
- Kolmogorov–Smirnov 검정: 정량적 p-값.
- 공간 잔차 — Pearson residual: 격자 셀 c별로 (관측 - 기대) / $\sqrt{\text{기대}}$. 특정 지역이 지속적으로 underfit/overfit인지 지도로 시각화.

잔차가 Poisson에서 체계적으로 이탈하는 방향이 **다음 라운드의 진단 신호**. 예: 잔차가 시간 뒤쪽에 몰려 있다면 비정상성(μ 가 시간에 따라 변함) → Part III 5-1단계의 근거.

§II.4 3차 심판관 — out-of-sample predictive likelihood

시간 축 기준 **마지막 20%**를 테스트셋으로 분리. 앞 80%로 모델 적합 후 뒤 20%에서의 $\log p(\text{data} \mid \theta^*)$ 계산. 단계별 비교.

- in-sample 우도는 모수가 늘수록 무조건 좋아진다 — 과적합 가능. 홀드아웃 우도는 과적합을 직접 드러냄.

- rolling window 검증: 1년씩 밀어가며 여러 기간에서 홀드아웃 평가. 결론이 기간별로 달라지면 모델이 시기에 따라 다르게 작동함 — 또 하나의 비정상성 신호.
- 실무적 의미: 본 연구의 $\alpha(t)$ rolling window가 실제 예측에 유용한지를 직접 검증.

§II.5 4차 심판관 — simulation-based recovery

가장 엄격한 심판. 알려진 모수 ($\mu^*, \alpha^*, \beta^*, \sigma^*$)로 Hawkes 과정을 **인공 생성** 후, 그 합성 데이터에 내 MLE/EM을 적용하여 모수를 추정. 복원 오차:

$$\text{recovery_error} = \|\hat{\theta} - \theta^*\| / \|\theta^*\|$$

- 오차 < 10%: 방법이 올바르게 작동함. 실제 데이터 결과를 믿을 수 있음.
- 오차 $\geq$ 30%: 방법 자체가 문제. 실제 데이터 결과 해석 주의.
- 특히 중요한 테스트: *identifiability 실험* — 서로 다른 (μ, α) 조합이 비슷한 우도를 내지 않는지. 만약 $\mu \uparrow \cdot \alpha \downarrow$ 와 $\mu \downarrow \cdot \alpha \uparrow$ 가 거의 같은 우도를 낸다면 두 모수가 구별 불가.

§II.6 심판관의 도구별 확장 — Part IV-V로 가는 진단 어휘 (v1.3 추가)

v1.2까지 §II의 4대 심판관(AIC/BIC, Ogata residuals, OOS likelihood, simulation recovery)은 v1.0 시점의 점과정 모델만 염두에 둔 것이었다. 이후 Part IV(생존분석)와 Part V(Cox-Hawkes)가 추가되면서 추가 진단 도구가 필요해졌다. v1.3에서 이를 명시한다.

문제 진단.

Part IV-V의 모델들은 §II의 4대 심판관만으로는 충분히 진단되지 않는다 — 각 도구가 자기 분야의 표준 진단을 가짐.

근거.

- **§II.3 Ogata residuals** 는 점과정의 시간 재척도 정리에 기반. Cox 회귀에는 적용 불가.
- **Cox 회귀의 표준 진단** 는 Schoenfeld residuals(비례위험 가정 검정), martingale residuals(공변량 함수형 검증), deviance residuals(개체별 적합도). §II에 부재.
- **Cox-Hawkes의 베이지안 추정** 는 또 다른 진단 도구를 요구 — posterior predictive check, WAIC, LOO-CV, R-hat 등 Bayesian 모델 평가 도구. §II에 부재.

도구별 진단의 확장 매핑.

도구	§II 표준 심판관	도구별 추가 진단	적용 위치
Hawkes (Part I~III)	AIC/BIC, Ogata, OOS, simulation	(이미 §II에서 다룸)	§II.1~5
Cox 회귀 (§IV.4)	AIC/BIC, OOS likelihood	Schoenfeld residuals (PH 가정), martingale residuals (공변량 함수형), deviance residuals (개체별 적합도)	§IV.4 본문 + §II.6 정의
Andersen-Gill (§IV.5)	AIC/BIC	Cox 회귀 진단 + 클러스터 robust SE (Lin-Wei sandwich)	§IV.5 본문 + §II.6 정의
Frailty (§IV.6)	AIC/BIC	Frailty variance 신뢰구간, frailty 분포 sensitivity (gamma vs lognormal)	§IV.6 본문
Cox process (§IV.7)	Posterior predictive check	R-hat (chain convergence), WAIC, LOO-CV, GP hyperparameter prior sensitivity	§IV.7 본문 + §II.6 정의
Cox-Hawkes (Part V)	위 모든 도구 통합	§II 4대 심판관 + Cox 회귀 진단 + Bayesian 진단 + 식별 진단(VIF, 다중 시작 점, prior sensitivity)	§V.3-§3.7.4 + §II.6 정의

Part II에 통합하는 방식.

- **(a) §II 도입에 "4대 심판관 + 도구별 확장"을 명시.** §II.1~5는 점과정 모델의 공통 심판관, §II.6은 도구별 추가 진단의 매핑 안내.
- **(b) 각 Part 본문에 도구별 진단 절을 둬.** §IV.4 Cox에 Schoenfeld residuals 절, §IV.7 Cox process에 posterior check 절, §V Cox-Hawkes에 식별 진단 절 등.
- **(c) 두 결과의 통합 보고.** 결합 모델인 Cox-Hawkes의 진단은 "Hawkes 진단 + Cox 진단 + 베이지안 진단"의 합집합으로 보고. 단일 통계량으로 환원하지 않음.

실무 우선순위.

- **최소 필수:** §IV.4의 PH 가정 검정(Schoenfeld), §IV.7의 chain convergence(R-hat), §V의 식별 진단(VIF + multiple starts). 이 셋이 빠지면 결과 발표 시 학술 청중에게 즉각 문제 제기될 위험.
- **권장:** 위 + frailty 분포 sensitivity, GP prior sensitivity. 표준이 아닌 "신중한" 분석.
- **이상적:** 위 + WAIC/LOO-CV로 Cox-Hawkes의 "증거의 무게"를 단순 Hawkes 대비 정량 비교. 이는 박사과정 본 연구 수준.

실무 결과: §II.6은 진단 도구의 매핑 카탈로그로 작동한다. 각 Part 본문은 자기 도구의 진단을 자체적으로 다루되, 매핑은 §II.6에서 통합 참조. 이는 책의 "진단 어휘 사전"으로 기능.

Part II의 결론 — Part III로 가는 다리

네 심판관이 드러낼 가능성이 높은 실패 지점들:

- 1-1로 가는 신호 (*단일 브랜드 → 복수 브랜드*): 1단계 단일 스타벅스 분포로는 설명되지 않는 공간 패턴이 남을 것 — 다른 브랜드를 함께 봐야 함.
- 2-1로 가는 신호 (*marked Hawkes*): 2단계의 이진 상승/하락 라벨이 실제 가격 변화율의 정보를 버리고 있을 것 — 연속 marker 필요.
- 3-1로 가는 신호 (*stochastic declustering*): 3단계 α 행렬이 커진 정확한 이유가 '상호작용 때문'인지 '배경 이질성 때문'인지 Part II만으로는 답 못함 — 사건별 부모 확률 할당 필요.
- 4-1로 가는 신호 (*비/모수 background*): 공간 잔차가 지도상 특정 패턴으로 남을 것 — μ 의 모수적 형식이 부족함.
- 5-1로 가는 신호 (*nonstationary μ*): Part I 5단계 EM의 $\mu(x)$ 가 시간에 대해 상수라는 가정이 잔차의 시간 추세로 드러남 — $\mu(x, t)$ 필요.

Part III — 2차 라운드: 같은 문제를 더 나은 렌즈로 다시 보기

v1.0 신설. Part II의 심판을 통과하지 못한 지점들로 돌아가, 더 정교한 도구로 같은 문제를 다시 본다. **중요한 점:** 15~19장(1-1 ~ 5-1)은 서로 분리된 기술 목록이 아니라, *background*와 *triggered event*를 점점 정교하게 분리해 가는 하나의 연속된 흐름이다.

연속된 흐름:

- 3-1단계: 먼저 '어떤 사건이 background이고 어떤 사건이 triggered인가'를 확률적으로 나눈다.
- 4-1단계: 그다음 'background로 보이는 사건들'로부터 배경율의 공간 구조를 유연하게 추정한다.
- 5-1단계: 마지막으로 그 배경율 자체가 시간에 따라 변할 수 있음을 인정한다.

1-1과 2-1은 각 1단계와 2단계의 revisit로 독립적이지만, Part III 전체의 정신은 '같은 현상을 더 나은 렌즈로 다시 본다'로 일관된다.

§III.1 1-1단계 — 버거지수 revisited: 복수 브랜드 H3 Heatmap과 pseudo 상권 지수

1단계가 *스타벅스 하나로 공간적 집중을 읽는 입문*이었다면, 1-1단계는 이를 **복수 브랜드 비교**와 **pseudo 상권 지수**로 확장하는 첫 revisit다.

- 단일 브랜드의 hotspot을 복수 브랜드의 상대적 배치와 공동 집적으로 확장.
- 이후 α 행렬과 상권 상호작용(Part I 3단계)으로 넘어가기 위한 중간 다리 역할.

구체 내용은 v0.4의 §3.1(버거지수 재구성, H3 r9 격자, 다중 브랜드 카테고리)에서 이미 설계되었다. 책 구조에서 이 내용은 **1차 라운드(Part I 5장)의 스타벅스 단일 분석** 다음의 1-1 revisit 위치에서 사용된다. 이는 outline의 원칙 — '1단계 초반에 복수 브랜드와 pseudo 상권 지수까지 한꺼번에 열면 초반 밀도가 너무 높아진다'에 부합.

§III.2 2-1단계 — 지역 간 부동산 전파 revisited: marked Hawkes process

2단계에서는 거래를 *상승/하락 이진 라벨*로 다뤘다. 이는 정보 손실이 크다. 2-1단계에서는 **marked Hawkes process**로 확장하여 각 거래에 *연속 marker*(가격 변화율, 거래량, 평당가 등)를 부여한다. 강도함수:

$$\lambda_{\ell}(t, m) = \mu_{\ell}(m) + \sum_{\ell'} \sum_i \alpha_{\{\ell \leftarrow \ell'\}}(m, m_i) \cdot g(t-t_i)$$

- m: marker (가격 변화율, 거래 규모 등). α 가 marker의 함수가 되어 '큰 상승 거래가 작은 상승 거래보다 더 강한 spillover를 일으키는가?'를 직접 검정.
- 현대우·Milcheva(2016)의 결과 — 상승장이 하락장보다 8배 강한 spillover — 가 marker로 연속화되면 '상승 규모의 어느 임계치부터 spillover가 가파르게 올라가는가?'라는 비선형 질문이 가능.
- 이론적 기반: Daley & Vere-Jones(2003)의 marked point process 장, Rasmussen(2013)의 marked Hawkes 추정.

§III.3 3-1단계 — stochastic declustering: background와 triggered event의 확률적 분리

핵심 질문은 단순하다.

- 이 사건은 원래 외생적으로 발생한 사건인가
- 아니면 이전 사건에 의해 유발된 사건인가

Hawkes 과정에서는 각 사건이 두 경로 중 하나로 발생한다고 본다.

- **background event:** 외생적으로, 자생적으로 발생한 사건.
- **triggered event:** 이전 사건의 excitation에 의해 발생한 사건.

문제는 현실 데이터에서 그 구분을 직접 관측할 수 *없다*는 점이다. 따라서 deterministic하게 자르지 않고 **확률적으로 배분**한다. 이것이 stochastic declustering (Zhuang-Ogata-Vere-Jones 2002).

각 사건 i에 대해 계산되는 것은 대체로 두 종류다.

- p_{ii} — 사건 i 가 background일 확률.
- p_{ij} — 사건 i 가 과거 사건 j 에 의해 유발되었을 확률.

모든 가능한 부모 후보의 확률 합은 1이 된다: $p_{ii} + \sum_{\{j < i\}} p_{ij} = 1$. 직관적으로는 사건의 '가계도'를 복원한다기보다, 각 사건의 '출생 경로'를 사후확률로 나누는 것이다.

왜 중요한가.

- 관측된 군집을 곧바로 self-excitation으로 읽으면 오독 가능성이 크다 — 강남의 거래 집중이 '강남이 강남을 부른 것'일 수도 있고 '강남이 원래 배경율이 높은 것'일 수도 있다.
- p_{ii} 를 추정하면 각 사건이 어느 경로로 왔는지 확률적으로 할당 $\rightarrow \alpha$ 와 μ 의 분리가 사건 수준에서 이뤄짐.
- 이는 Part I 5단계 EM의 $p_{ii} \cdot p_{ij}$ 와 같은 개념이지만, 여기서는 stochastic declustering을 독립된 도구로 전면에 세운다. Part I 5단계에서는 $\mu(x)$ 추정의 부산물로 p_{ii} 가 계산되었다면, 3-1에서는 p_{ii} 자체가 분석의 대상이다 — 어느 지역·어느 시기에 background 비율이 높은가, 그 비율이 시간에 따라 어떻게 변하는가.

§III.4 4-1단계 — background rate의 비모수 추정

3-1단계에서 p_{ii} 로 background 사건들을 분리했다면, 이제 그 background 사건들의 공간 분포를 **모수 가정 없이** 추정한다:

$$\mu(x) \approx \sum_i p_{ii} \cdot K_{\sigma}(x - x_i) / T$$

- Gaussian smoothing K_{σ} 의 bandwidth σ 는 cross-validation 또는 Silverman's rule.
- Part I 5단계가 이미 이 형식을 썼지만, 그때는 모델 수렴의 부산물이었다. 여기서는 declustering 결과를 입력으로 받아 $\mu(x)$ 의 형태·peak·ridge를 적극적으로 해석.
- 4-1의 기여: Part I 5단계의 $\mu(x)$ 추정이 p_{ii} 로 가중된 '진짜 background'에서 나오는지, 아니면 모든 사건의 혼합에서 편향되어 나오는지를 명시적으로 분리.

§III.5 5-1단계 — nonstationary background: 시간에 따라 변하는 배경율

지금까지 배경율은 $\mu(x)$ — 공간 함수지만 시간 상수. 5-1단계는 이를 $\mu(x, t)$ 로 확장한다. 모수화 선택지:

- **스플라인:** $\mu(x, t) = \sum_j \beta_j B_j(x) \cdot \sum_k \gamma_k S_k(t)$. 공간·시간 basis를 분리 가능.
- **roughness penalty:** $\mu(x, t)$ 의 공간·시간 smoothness를 penalized likelihood로 제어.
- **time-varying kernel:** $\mu(x, t) = \mu^0(x) \cdot (1 + f(t))$ 형태로 공간과 시간을 곱셈적으로 분리.

왜 여기가 아직 Part IV가 아닌가. 5-1은 '배경율이 시간에 따라 변한다'는 서술을 허용한다. 그러나 *왜 변하는지*는 여전히 모델 밖에 있다. 그 '왜'에 공변량으로 답하는 것이 Part IV의 과제.

Part III의 전체 흐름

15~19장을 하나로 꿰면:

- 1-1: 관측 해상도(단일 → 복수 브랜드)를 올렸다.
- 2-1: 사건 정보(이진 → 연속 marker)를 늘렸다.
- 3-1: 사건을 background/triggered로 확률적으로 분해했다.
- 4-1: background 분포를 비모수로 유연하게 추정했다.
- 5-1: background가 시간에 따라 변할 수 있음을 인정했다.

독자는 이제 '배경율을 제대로 다루는 것이 이토록 어렵다'는 감각을 갖춘 채 다음 파트로 진입한다. 그러나 Part I~III 전체가 사건이 *일어난* 시점·장소만 본 것이라는 사실을 기억해야 한다. **무소식이 희소식**이라는 말이 있듯, 사건이 일어나지 *않은* 것 — 점포가 5년 동안 폐업하지 않았다는 사실, 어떤 자치구에서 3개월간 거래가 없었다는 사실 — 자체가 정보이고, 점과정의 우도 함수에는 그 정보가 흐릿하게만 들어간다.

v1.1~v1.2에서는 그 다음이 두 단계로 나뉜다 — Part IV에서 *같은 데이터를 점포 수명·비사건의 관점에서* 다시 보고 (생존분석: life table → KM → Cox → Andersen-Gill → Frailty → Cox process의 도구 시퀀스로 1-2 ~ 5-2의 다섯 사례를 다룸), 그 다음 Part V에서 두 시각을 결합한 *Cox-Hawkes*로 공변량 조건부 μ 와 식별 문제를 정면으로 다룬다.

Part IV — 생존분석으로 젠트리피케이션 읽기

v1.1 신설, v1.2 재설계. Part I~III에서는 사건이 일어난 시점·장소만 봤다. 그러나 무소식이 희소식이라는 말이 있듯, 사건이 일어나지 않은 것 자체가 정보다. 점포가 5년 동안 폐업하지 않았다는 사실, 어떤 자치구에서 3개월간 거래가 없었다는 사실 — Hawkes의 우도함수에는 이 정보가 흐릿하게만 들어가고, 개체 수준의 생존 정보는 모형 안에 들어가지 않는다. Part IV는 이 비사건의 정보를 정면으로 다룬다.

점과정과 생존분석은 같은 데이터를 다른 분석 단위로 본다:

- **점과정:** '공간 x 에서 시간 t 까지 어떤 사건들이 발생했는가'를 본다. 점포는 강도함수가 만드는 사건 흐름의 한 점일 뿐, 개체로서의 정체성이 없다.
- **생존분석:** '개체 i 가 시점 t 에 아직 살아있는가'를 본다. 개체가 분석 단위이고, 비사건(생존)이 risk set의 핵심 정보다.

이 파트는 책에서 네 번째 독립 산출물을 제공한다. 단계 1(H3 heatmap), 단계 2(지역 간 부동산 전파 행렬), 단계 3(상업 상권 α heatmap)에 이어, §IV.4의 1-2 살아남은 스타벅스 KM 곡선과 §IV.7의 5-2 버티는 힘 $\lambda_{\text{survive}}(x)$ 지도가 그것이다. 두 그림이 정책·언론과의 대화에 즉시 활용된다.

Part IV의 또 다른 의미는 **Part V Cox-Hawkes의 사전 준비**다. 독자가 Cox process(Part IV §IV.7)와 Hawkes(Part I~III)를 각각 단독으로 만난 뒤에야 두 도구의 결합 형태(Cox-Hawkes)를 진정으로 이해할 수 있다. 한 번도 hazard intensity의 stochastic random field를 본 적이 없는 독자에게 'Cox-Hawkes는 Cox process + self-excitation'이라고 말하는 것은 두 도구 모두 어렵듯하게 둔 채 결합형만 보여주는 셈이다.

§IV.0 파트 구성 — 도구 시퀀스와 사례 매핑

Part IV는 도구의 점진적 확장을 척추로 삼되, 각 도구를 Part I/III의 다섯 사례에 응답하는 1-2 ~ 5-2 형태로 살린다. 도구 시퀀스는 한 단계씩 가정을 풀어가는 사고의 행진이고, 사례는 그

행진을 살아있게 한다.

챕터	도구	응답하는 사례 (Part I/III 대응)	핵심 요약
§IV.2	Life table	(도입용 — 본 연구 데이터의 첫 인상)	이산시간 비모수 출발점
§IV.3	Kaplan–Meier	1-2 살아남은 스타벅스	→ 연속시간 비모수
§IV.4	Cox 비례위험	3-2 스타벅스가 폐점했을 때 다른 프랜차이즈는?	→ 공변량·시변 공변량
§IV.5	Andersen–Gill	2-2 아파트 거래가 조용할 때	→ 단일 사건 → 반복 사건
§IV.6	Frailty model	4-2 옆 점포가 살아남으면 나도 살아남는다	→ 공유 random effect
§IV.7	Cox process	5-2 버티는 힘 $\lambda_{\text{survive}}(x)$	→ random scalar → random field
§IV.8	(다리)	Part V Cox-Hawkes로 — Cox process + self-excitation	→ doubly stochastic + Hawkes

이 시퀀스의 미덕: 각 단계가 앞 단계의 가정 하나를 풀어준다. life table은 이산시간을 가정하고, KM은 그것을 푼다. KM은 공변량을 무시하고, Cox는 그것을 푼다. Cox는 단일 사건만 보고, AG는 반복 사건을 받아들인다. AG는 개체 독립을 가정하고, frailty는 클러스터 의존을 받아들인다. frailty는 random scalar를, Cox process는 random field를 도입한다. 그리고 Cox process는 자기여기 항을 받아들이는 순간 Cox-Hawkes가 된다 — Part V로의 다리.

§IV.1 도입 — 무소식이 희소식: 비사건의 정보

Hawkes의 우도함수는 두 항으로 구성된다:

$$\ell(\theta) = \sum_i \log \lambda(t_i) - \int_0^T \lambda(s) ds$$

첫 항은 사건이 발생한 시점들의 강도. 두 번째 항(compensator)은 사실 *사건이 없었던 시간 구간*의 정보를 담고 있다 — 강도가 큰데 사건이 없었다면 우도가 낮아짐. 그러나 이는 **집계 수준**의 정보일 뿐, 개체별 생존 정보는 들어가지 않는다.

구체 예시.

- 점포 A는 2010년 입점, 2024년에도 영업 중 — 14년 생존
- 점포 B는 2018년 입점, 2020년 폐업 — 2년 생존

Hawkes 모형에서 두 점포는 *입점 사건 두 개와 폐업 사건 한 개*로만 인지된다. 점포 A가 14년 동안 *매일 폐업하지 않고 살아남았다*는 사실은 — 압도적으로 많은 정보임에도 — 모형에 명시적으로 들어가지 않는다. 점포 B의 짧은 수명도 마찬가지로 단순히 두 시점 간 차이로만 처리됨.

생존분석은 정반대다.

- 개체별 risk set 추적: 시점 t에 살아있는 점포들의 집합이 매 순간 갱신됨
- censoring 처리: 관측 종료 시점에 살아있는 점포는 'censored'로 표시되어 부분 정보를 기여
- partial likelihood: '실제 폐업한 점포 vs 그 시점의 risk set'의 상대 비교만 사용 — baseline hazard의 형태에 의존하지 않음

이 차이가 본 연구에 가져오는 것: **Part I~III가 본 사건 동학과 직교하는 새로운 정보 채널**. 같은 LOCALDATA를 다른 단위에서 다시 읽음으로써 — Part I/III의 다섯 사례를 비사건 관점에서 1-2 ~ 5-2로 다시 보는 것이 Part IV의 본체다.

△ Timestamp 보정의 결정적 중요성 (v1.3 추가)

v1.2까지 §IV는 LOCALDATA의 timestamp 문제를 §5.5에서 다룬다고 암시만 했다. v1.3에서 이를 §IV 도입에 명시한다 — 생존분석에서는 timestamp 정확도가 점과정보다 훨씬 더 결정적이기 때문이다.

문제 진단.

LOCALDATA의 두 timestamp 문제(인허가일 $\neq$ 실제 개점일, 폐업신고 지연)가 점과정과 생존분석에서 결과에 미치는 영향이 다르다.

근거.

- **점과정에서:** timestamp가 며칠 어긋나도 강도 추정에 미치는 영향이 작다. α 행렬은 *사건들 사이의 상대적 시점 패턴*을 보므로, 모든 timestamp가 비슷한 방향으로 어긋나면 추정값에 큰 편향이 없다.
- **생존분석에서:** timestamp가 며칠 어긋나면 *수명 변수 자체가 어긋난다*. 인허가일이 실제 개점보다 평균 30일 앞서면, 모든 점포의 영업 기간이 30일 길게 추정된다. 폐업신고 지연이 평균 60일이면, 추가로 60일 더 길게. 합쳐서 **모든 영업 기간이 평균 90일 길게 체계적 편향**.
- **정책 진술의 민감성:** "서울 자영업 5년 생존율 X%" 같은 진술에서 X가 timestamp 보정 전후로 $\pm 5 \sim 10\%$ 차이가 날 수 있다. 이는 정책 결정에서 큰 차이.

두 대안 비교.

- **(a) 보정 없이 진행, 결과에 단서 표시.** 간단하나 모든 결과가 "timestamp 미보정 가정 하에서 잠정적"이라는 단서가 따라다님. 정책 인용 시 위험.
- **(b) §5.5의 보정 절차를 §IV 모든 분석에 일관 적용.** 실제 개점일 보정(Δ_{open} 추정), 실제 폐업일 보정(Δ_{close} 추정), 결과의 sensitivity 분석. 작업 비용 크지만 신뢰도 확보.

채택 이유 — (b).

- 생존분석 결과의 정책적 활용을 진지하게 고려한다면 보정은 선택이 아닌 필수.
- §5.5에서 이미 $\Delta_{open} \cdot \Delta_{close}$ 분포 추정 절차를 설계했으므로 추가 작업이 적음.
- Sensitivity 분석을 §IV.3 KM 곡선 결과에 부속 산출물로 포함 — "*보정 전 5년 생존율 vs 보정 후 5년 생존율*"의 두 곡선을 함께 보임으로써 보정의 영향 자체를 투명하게 공개.

실무 결과: §IV의 모든 KM·Cox·AG·Frailty·Cox process 분석은 §5.5의 보정된 timestamp를 사용한다. "보정 전" 결과는 sensitivity 비교용으로만 유지하며, 보고 시 두 결과를 함께 제시한다.

§IV.2 Life table — 가장 단순한 출발: 점포 영업 기간의 이산 표

도구 시퀀스의 미니멀한 첫 단계. life table은 보험계리에서 17세기에 시작되어 의학으로 옮겨 온 가장 오래된 생존분석 도구다. 학부 통계 교과서적이지만 본 연구 데이터의 첫 인상으로 매우 효과적이다.

기본 아이디어

시간을 이산 구간으로 나누고(예: 1년 단위), 각 구간 j 에서 다음을 계산:

- n_j — 구간 시작 시점에 살아있는 점포 수
- d_j — 구간 안에서 폐업한 점포 수
- $q_j = d_j / n_j$ — 구간 폐업률 (조건부)
- $s(t_j) = \prod_{k \leq j} (1 - q_k)$ — 누적 생존률

본 연구 데이터에 적용

LOCALDATA에서 추출한 자영업 점포 전수 데이터로 life table 구성. 1년·5년·10년 생존을 계산.

예상 산출물 (가설적 수치, 실제 데이터 적용 전):

- 서울 자영업 1년 생존율: ~80%
- 5년 생존율: ~30%
- 10년 생존율: ~12%
- 자치구별 비교 표 — 강남/서초 vs 노원/도봉의 5년 생존율 비교
- 업종별 비교 — 음식점 vs 카페 vs 편의점의 5년 생존율

이 표 자체가 정책 대화에서 가장 자주 인용될 한 줄을 만든다 — "서울 자영업 5년 생존율 $X\%$ ".

학술적 정교함은 KM·Cox 이후에 더해지지만, 본 연구의 첫 정책적 진입점으로서 life table은 무시할 수 없는 가치가 있다.

이 도구가 대답할 수 없는 것 (→ §IV.3 KM)

- 이산 시간 가정. 폐업이 어느 날에 일어났는지 정확히 알아도 1년 단위로 묶임 — 정보 손실.
- censoring 처리가 거칠다. 표준 life table에서 censoring된 점포는 risk set에 절반만 기여하는 등의 임시 보정이 필요함.
- 공변량 비교가 불가능. '강남이 5년 생존율 35%, 노원이 25%'까지는 가능하지만, '왜 그런가'를 설명할 hazard ratio 분석은 불가능.

§IV.3 Kaplan-Meier — 1-2 살아남은 스타벅스

*life table*의 이산 가정을 푼 연속시간 비모수 추정. *Kaplan & Meier(1958)*의 *product-limit estimator*는 단순하면서 가장 자주 인용되는 생존분석 도구다.

KM estimator

$$\hat{S}(t) = \prod_{t_i \leq t} (1 - d_i / n_i)$$

폐업이 일어난 시점들 t_i 에서만 곱이 갱신됨. 이산 life table과 같은 형식이지만 시간 격자가 사건 시점 자체로 정의됨 — 정보 손실 없음. censoring은 '죽지 않고 risk set에서 빠짐'으로 자연스럽게 처리.

1-2 살아남은 스타벅스에 적용

Part I 1단계가 스타벅스 입점 분포를 봤다면, 1-2는 **각 스타벅스 매장의 영업 기간**을 본다. 가설:

- 어디서 살아남고 어디서 망하는가? 입지 조건이 생존에 미치는 영향.
- 스타벅스 본사의 직영 폐점 결정과 자영업 폐업의 동학은 다를 것 — 스타벅스는 본사가 임대료·매출을 모니터링하다 적극적으로 정리하므로 hazard 함수의 형태가 자영업과 다를 가능성.
- 리뉴얼·재오픈 처리 — 같은 자리에서 인테리어 후 재개점한 매장을 동일 매장으로 볼 것인지의 정의 결정이 결과를 좌우함.

§IV.3 킬러 그림 — 스타벅스 매장 생존지도

서울 지도 위에 각 스타벅스 매장을 점으로 표시. **색상으로 영업 기간을 표시** — 일부 매장은 5년, 일부는 15년. 이 지도가 답하는 질문:

- 강남대로의 매장과 변두리의 매장이 어떻게 다른가?
- '장수 매장'의 공간적 패턴 — 핵심 입지 vs 실험적 입지의 구분이 가시화됨.
- Part I 1단계가 보여준 입점 분포와 비교 — 스타벅스가 어디에 들어왔는가(입점) ≠ 어디에서 오래 살아남는가(생존). 두 지도의 차이가 발견.

부가 산출물.

- 자치구별 KM 곡선 비교 — 가로수길·한남동·홍대·성수동 4개 동네의 곡선이 한 그림에
- log-rank test — 동네 간 생존 분포 차이의 통계적 유의성
- 연도별 stratification — 2010년 이전 입점 매장 vs 이후 매장의 생존 비교

이 도구가 대답할 수 없는 것 (→ §IV.4 Cox)

- '왜' 어떤 매장이 더 오래 사는가는 답하지 못함. KM은 그룹 간 비교까지만, 공변량의 정량 효과는 Cox 회귀가 답함.
- 연속 공변량(임대료·유동인구의 정확한 수치)은 KM에 들어가지 않음 — 이산 그룹화로만 비교 가능.

§IV.4 Cox 비례위험 — 3-2 스타벅스가 폐점했을 때 다른 프랜차이즈는?

KM의 비모수 가정을 유지하면서 공변량을 도입. Cox(1972)의 *partial likelihood*는 *baseline hazard* $h_0(t)$ 의 형태에 의존하지 않고 β 만 추정하는 것이 핵심 성과.

Cox 모형

$$h(t | z) = h_0(t) \cdot \exp(\beta^T z)$$

- $h(t|z)$: 공변량 z 를 가진 점포의 시점 t hazard rate
- $h_0(t)$: baseline hazard (모수 가정 없음)
- $\exp(\beta)$: hazard ratio — '공변량 1 단위 변화가 폐업 위험을 $\exp(\beta)$ 배 한다'

3-2 스타벅스가 폐점했을 때 다른 프랜차이즈는?

Part I 3단계가 입점 → 입점의 양성 α 를 봤다면, 3-2는 **폐점이 주변에 미치는 효과**를 hazard 관점에서 본다. 핵심 가설:

- **앵커 폐점의 두 시나리오.** 앵커 브랜드(스타벅스)의 폐점이 (a) 클러스터 붕괴의 신호인가, (b) 새 임차인을 위한 공간 정리인가? Cox 회귀의 시변 공변량으로 두 시나리오를 정량 구분.

모형 설계

주변 점포 i 의 hazard에 시변 공변량 $z_i(t)$ 를 도입:

$$h_i(t | z_i(t)) = h_0(t) \cdot \exp(\beta \cdot z_i(t))$$

여기서 $z_i(t)$ 후보:

- $z_1(t)$ = 점포 i 200m 반경 내에 스타벅스가 있는가 (이진)
- $z_2(t)$ = 점포 i 200m 반경 내 가장 가까운 스타벅스의 영업 상태 (영업 중 / 최근 폐점 / 장기 폐점)
- $z_3(t)$ = 점포 i 자체의 공변량 (평당 임대료, 업종 카테고리, 영업 시작 후 경과 시간)

§IV.4 킬러 그림 — 폐점 spillover 곡선

"스타벅스 폐점 후 1년간 200m 반경 내 점포의 폐업률 변화" — 폐점 충격의 spillover 곡선. 가설적 결과:

- 폐점 직후 6개월: hazard ratio ≈ 1.4 (40% 위험 증가) — '클러스터 붕괴' 시나리오
- 폐점 후 6~12개월: hazard ratio ≈ 1.1 (안정화) — '신규 임차인 진입'
- 자영업 vs 다른 프랜차이즈로 분층 — 자영업이 더 큰 충격

partial likelihood 추정

$h_0(t)$ 를 추정하지 않고 β 만 추정하는 것이 Cox 회귀의 핵심 성과. 사건 발생 시점에 '누가 위험에 노출되어 있었나'와 '실제 누가 폐업했나'의 상대 비교만 사용:

$$L(\beta) = \prod_{\{\text{events}\}} \exp(\beta \cdot z_i) / \sum_{\{j \in R(t_i)\}} \exp(\beta \cdot z_j)$$

$R(t_i)$ = 시점 t_i 에 살아있는 점포의 risk set. Cox 회귀의 baseline-free 성격이 여기에 응축됨.

이 도구가 대답할 수 없는 것 (→ §IV.5 Andersen-Gill)

- Cox는 '한 점포의 첫 폐업'만 본다. 그러나 같은 자리에서 폐업 → 신규 입점 → 폐업이 반복되는 거리도 많다 — recurrent events.
- 아파트 거래는 '거래'라는 사건이 한 단지에서 수십 번 반복됨 — 단일 사건 Cox로는 본질적으로 부적합.

📦 박스 — Cox 회귀의 다른 도메인 응용: 영화 흥행 (v1.5 추가)

이 박스는 Cox 회귀가 도시 점포 폐업을 넘어 일반적임을 시연한다. 본문 전체 사례는 부동산 점포로 유지하되, 영화 흥행이 같은 도구로 분석 가능함을 한 그림과 두 가설 hazard ratio로 짧게 보인다. 자세한 설계와 두 생존분석(강도 생존 + 공급 생존), 4사분면 분류, 다변량 cannibalization은 부록 A에서 다룬다.

문제의식 — 누적 관객 수 보도의 사각지대.

한국 영화 흥행은 보통 "누적 관객 수"로 보도된다 — "천만 영화", "개봉 4주차 800만 돌파" 등. 그러나 이 지표는 스크린 수라는 자원 입력을 통제하지 않는다. 같은 1,000만 관객이라도:

- 2,500개 스크린에서 4주간 누적 → 스크린당 4,000명


- 1,200개 스크린에서 8주간 누적 → 스크린당 8,333명

후자가 **2배 더 흥행한 영화**다 — 적은 자원으로 더 많은 관객을 모았으니까. 그런데 보도에서는 둘 다 "천만 영화"로 묶인다.

해결 — 두 축으로 분해하기.

- **X축:** 스크린 수 (자원 입력)
- **Y축:** 스크린당 관객 수 (흥행 강도)

이 두 축으로 흥행을 분해하면 4사분면이 자연스럽게 나타난다:



관습적인 "누적 관객 수" 보도는 ①과 ②를 같은 "천만 영화"로 묶지만, ②는 자원 입력 대비 실패 사례. ②와 ③의 흥행 강도는 같아도 서사가 다름 — 한 편은 마케팅 실패, 다른 한 편은 작은 영화의 큰 성공.

그림 IV.4.1 — 한국 영화 흥행의 4사분면 분류 (예시, placeholder 데이터). 누적 관객 수 보도는 ①과 ②를 같은 "천만 영화"로 묶지만, ②는 자원 입력 대비 실패 사례. ②와 ③의 누적 관객은 다를 수 있어도 흥행 강도(스크린당 관객)는 ③이 더 높을 수 있다 — 한 편은 마케팅 실패, 다른 한 편은 작은 영화의 큰 성공.

Cox 회귀의 자연스러운 적용.

영화관 사업자는 매주 영화의 성과(스크린당 관객 수)를 보고 다음 주 스크린 배정을 결정한다. 성과가 임계 아래로 떨어지면 스크린 수를 줄이고, 결국 0이 되면 상영 종료. **이 결정 과정이 곧**

hazard rate:

$$h(t \mid z) = h_0(t) \cdot \exp(\beta^T z)$$

- $h(t \mid z)$: 시점 t 까지 상영을 유지한 영화의 다음 순간 상영 종료 hazard.
- **공변량 z 후보:** 스크린당 관객 수, 같은 주 개봉 경쟁작 수, 평론가·관객 평점, 장르·등급, 배급사 규모.

가설적 hazard ratio 해석.

- $\beta(\text{스크린당 관객 수}) = -0.3/1000\text{명}$ 이면 $\exp(-0.3) \approx 0.74$ — "스크린당 1,000명 더 많을 때 다음 주 상영 종료 위험이 26% 낮아진다".
- $\beta(\text{같은 주 경쟁작 수}) = +0.4/\text{편}$ 이면 $\exp(0.4) \approx 1.49$ — "같은 주에 새 영화가 한 편 더 개봉할 때 본 영화의 종료 위험이 49% 올라간다" (관객 풀 cannibalization).

이 박스가 시사하는 것.

- **도구의 일반성.** §IV.4 Cox 회귀는 도시 부동산 점포 폐업에만 한정된 도구가 아니다. 사건이 시간 위에 흩어진 모든 현상에 적용 가능.
- **기존 지표의 한계.** 누적 관객 수 보도가 가리는 흥행 구조를 두 축 분해 + Cox 회귀로 드러낼 수 있음. 마케팅 실패와 작은 영화의 성공이 같은 "천만"으로 묶이는 착시가 해소됨.
- **다변량 Hawkes로의 확장.** 같은 주 개봉작끼리의 cannibalization은 marked Hawkes 또는 다변량 Hawkes로 더 정밀히 분석 가능. §3.3 α 행렬과 동일한 도구.

한정. 본 연구의 본문은 도시 부동산을 다룬다. 영화 흥행은 본 연구의 도구가 다른 도메인에도 적용 가능함을 시사하는 보조 자료로서만 등장. 본격 분석은 별도 페이퍼 또는 책 출판 후속 작업으로 분리. 부록 A에 더 풍부한 설계 (두 가지 생존분석·4사분면 동학·KOFIC 데이터·향후 계획) 이 있음.

§IV.5 Andersen-Gill — 2-2 아파트 거래가 조용할 때

Cox의 단일 사건 가정을 풀어 반복 사건(recurrent events)을 받아들인다. Andersen & Gill(1982)의 multiplicative intensity model은 counting process 이론에 기반해 Cox를 반복 사건으로 일관화한 정식 프레임이다.

Andersen-Gill 모형

$$\lambda_i(t \mid \text{history}) = Y_i(t) \cdot \alpha_0(t) \cdot \exp(\beta^T z_i(t))$$

- $Y_i(t)$: risk indicator — 개체 i 가 시점 t 에 위험에 노출되어 있는가 (0/1)
- $\alpha_0(t)$: baseline intensity — Cox의 $h_0(t)$ 와 동일한 객체
- **history**: 과거 사건 이력 — 여기서 self-exciting 항이 추가되면 그게 정확히 Cox-Hawkes

이 식이 책의 핵심 다리다. **Cox 회귀(history 없음)**와 **Hawkes($Y=1$, $\exp(\beta^T z)=1$, $\alpha_0=\mu+\Sigma\alpha\cdot g$)**의 공통 지붕. Part V에서 다시 만난다.

2-2 아파트 거래가 조용할 때

Part I 2단계가 거래 발생을 봤다면, 2-2는 거래가 일어나지 않는 침묵의 기간을 본다. 핵심 통찰: "강남에서 3개월 동안 거래가 없었다"는 것은 단순히 데이터가 비어있는 것이 아니라 **시장의 특정 상태**에 대한 정보다 — 침체기, 관망기, 또는 가격 발견 실패의 신호.

inter-arrival time을 생존변수로

같은 단지·같은 평형에서 연속된 두 거래 사이의 시간 간격을 "수명"으로 모델링:

- 거래 i 와 $i+1$ 사이 기간을 T_i 로 둬
- T_i 의 분포가 자치구·시기·시장 상태에 따라 어떻게 변하는가
- recurrent events 프레임 — 같은 단지에서 거래가 반복되므로 Andersen-Gill이 자연스러움

△ 적용 단위의 정밀화 (v1.3 추가)

v1.2까지 §IV.5는 'AG로 거래 침묵을 본다'고만 적고 적용 단위가 모호했다. v1.3에서 이를 명시한다.

문제 진단.

Andersen-Gill 모형의 정통적 적용은 **같은 개체에서 반복 발생하는 사건**이다 — 한 환자의 재입원, 한 기계의 반복 고장. 그런데 "강남구의 거래"를 다루려면 두 가지 단위 정의가 가능한데, 둘이 다른 결과를 낸다.

근거.

- AG의 partial likelihood는 risk set 정의에 의존. 같은 개체의 반복 사건이면 risk set은 그 개체의 사건 사이 시간만 포함.
- 개체 정의가 달라지면 risk set 구조가 달라지고, 추정된 baseline intensity $\alpha_0(t)$ 와 공변량 효과 β 의 의미도 달라진다.
- Therneau & Hamilton(1997), Lin & Wei(1989) 등이 recurrent events에서 robust standard error의 클러스터링 처리가 결과에 결정적이라고 지적.

두 대안 비교.

개체 정의	(a) 자치구를 개체로	(b) 단지를 개체로
개체 수	25개 (서울 자치구)	수천~수만 (서울 아파트 단지)
개체별 사건 수	수천~수만 (자치구별 거래)	수~수십 (단지별 거래)
baseline intensity의 의미	자치구가 평균적으로 거래를 일으키는 율	단지가 평균적으로 거래를 일으키는 율
자치구 비교	자연스러움 (개체 간 비교)	단지 frailty의 자치구별 분포로 간접 비교
표본 충분성	자치구당 사건 수 충분 → 안정적 추정	단지당 거래 부족 시 추정 불안정 → frailty term 필요

개체 정의	(a) 자치구를 개체로	(b) 단지를 개체로
정통성	AG의 본 의도(개별 개체의 반복 사건)와 다소 거리	AG의 본 의도에 더 부합

채택 이유.

본 연구는 (a) 자치구를 개체로 정의 하는 방식을 1차로 채택하고, 후속 분석에서 (b)로 확장한다. 채택 이유:

- **연구 질문과의 정합성.** 2-2 사례의 핵심은 "강남이 조용해지면 무슨 일이 일어났는가" — 자치구 간 비교가 본 분석의 직접 목표. (a)에서 자치구 간 baseline intensity의 직접 비교가 가능.
- **표본 충분성.** 자치구당 거래 수가 충분히 많아 baseline intensity의 형태가 안정적으로 추정됨. (b)는 단지당 거래가 적어 frailty 가정에 강하게 의존.
- **Part I 2단계와의 일관성.** Part I 2단계가 자치구 단위 다변량 시간 Hawkes로 설계됨. 같은 단위로 2-2 분석을 진행하면 두 결과가 직접 비교 가능.
- **(b)는 §IV.6 frailty의 자연스러운 자리.** 단지 단위 분석은 frailty와 결합될 때 가장 강력 — "같은 자치구의 단지들은 공통 frailty를 공유"라는 multilevel 구조. 이는 §IV.6 4-2 사례에서 본격적으로 다룸.

정정 결과: §IV.5는 자치구를 개체로 한 AG 분석으로 명시되며, 단지 수준 분석은 §IV.6의 frailty model에서 multilevel 구조로 자연스럽게 통합된다. 이로써 §IV.5 → §IV.6의 다리가 단지 단위 정밀화로 명확해진다.

§IV.5 킬러 그림 — 자치구별 inter-arrival time 분포

가설적 결과:

- 강남: 평균 inter-arrival time 3일, 중위값 2일 (활발한 거래)
- 노원: 평균 30일, 중위값 14일 (느린 거래)

- 이 비대칭이 시기에 따라 어떻게 변하는가 — 2017~2020 상승기와 2022~2024 하락기 비교
- **핵심 발견 후보:** '침묵의 길이' 자체가 시장 체제를 식별하는 지표. 평소보다 훨씬 긴 inter-arrival이 관측되면 시장이 '얼어붙음' 상태에 진입한 신호.

Andersen-Gill의 강점 — counting process 어휘

AG의 진짜 가치는 추정 결과의 단순함이 아니라 **counting process 어휘**를 도입한다는 점. martingale CLT 기반 점근 추론이 가능해지고, 이게 그대로 Hawkes 추정 이론과 연결됨. Reinhart(2018) 리뷰가 강조하듯 점과정과 생존분석은 counting process라는 같은 언어를 공유.

이 도구가 대답할 수 없는 것 (→ §IV.6 Frailty)

- AG는 개체 독립을 가정. 그러나 같은 골목 점포들의 hazard는 분명히 상관됨 — 공유된 임대인, 공유된 거리 매력도, 공유된 미관측 환경 요인.
- 이 상관을 무시하면 표준오차가 과소추정됨 — Type I error 부풀림.
- 개체별 random effect를 도입하는 것이 frailty model.

§IV.6 Frailty model — 4-2 옆 점포가 살아남으면 나도 살아남는다

AG의 개체 독립 가정을 풀어 클러스터 의존을 받아들인다. Vaupel·Manton·Stallard(1979)에서 시작된 frailty model은 hazard 함수에 unobserved heterogeneity 항(random effect)을 추가하는 형태.

Frailty model

$$h_{ij}(t \mid z_{ij}, u_j) = h_0(t) \cdot u_j \cdot \exp(\beta^T z_{ij})$$

- j : 클러스터 인덱스 (예: 같은 골목, 같은 블록)
- i : 클러스터 j 안의 점포 인덱스
- u_j : 클러스터 j 의 frailty — 클러스터 모든 점포의 hazard에 곱셈적 영향. 보통 $\text{Gamma}(\theta, \theta)$ 분포 가정 (평균 1, 분산 $1/\theta$). $u_j > 1$ 이면 클러스터 j 점포들의 hazard가 평균보다 높음.

4-2 옆 점포가 살아남으면 나도 살아남는다

Part I 4단계 가로수길 Blue/Red가 입·폐점의 4가지 사건 유형을 봤다면, 4-2는 **공동 생존(joint survival)** 패턴을 본다. 핵심 가설:

- 자영업 클러스터에서 점포들의 생존이 독립인가, 양의 상관인가, 음의 상관인가?
- 같은 골목 점포들이 함께 버티거나 함께 무너지는 동학
- frailty의 분산 $1/\theta$ 가 그 상관의 강도 — θ 가 크면(분산 작으면) 클러스터 간 차이 작음, θ 가 작으면(분산 큼) 클러스터별 매우 다름

클러스터 정의

frailty의 효력은 클러스터 정의에 강하게 의존. 후보:

- 같은 골목 (도로 세그먼트 단위) — 가장 미시적, 표본 수 많음
- 같은 블록 (4개 도로로 둘러싸인 지역) — 중간
- 같은 H3 셀 (r_9 , ~150m) — 격자 기반

- 같은 임대인/건물 (식별 가능하다면) — 가장 강한 frailty 예상

여러 정의로 frailty 분산을 비교하면 '어느 수준의 공간 단위에서 hazard 상관이 가장 강인가'가 답해짐.

§IV.6 킬러 그림 — 공간적 frailty 지도

두 그림:

- (a) 인접 점포 쌍의 생존시간 산점도. x축은 점포 A의 영업 기간, y축은 같은 골목 점포 B의 영업 기간. 양의 상관이면 점들이 우상향 패턴.
- (b) 추정된 frailty 값의 공간 지도. $u_j > 1.2$ 인 클러스터는 빨강, $u_j < 0.8$ 은 파랑. 빨강 지역은 '폐업이 잦은 동네', 파랑은 '안정 지역' — 그 자체로 정책 자료.

frailty의 두 가지 해석

- (i) 미관측 이질성. 관측된 공변량으로 다 설명하지 못하는 클러스터별 잔여 차이 — 임대인의 임대 정책, 건물 노후도, 거리 분위기 같은 모형에 들어가지 않은 요인.
- (ii) 진짜 dependence. 같은 골목 점포들이 실제로 서로 영향을 주고받음 — 옆 점포가 폐업하면 거리 활력 감소 → 본 점포 hazard 증가. 이게 의미상 자기여기와 가깝다.

frailty 모형은 이 둘을 분리하지 못한다. (i)이든 (ii)이든 같은 u_j 로 흡수됨. 진짜 분리는 Cox-Hawkes(Part V)에서 self-excitation 항을 명시적으로 도입할 때 가능. **frailty가 그쪽으로 가는** 다리다.

이 도구가 대답할 수 없는 것 (→ §IV.7 Cox process)

- frailty u_j 는 클러스터별 random scalar — 한 클러스터 안에서는 모든 점포가 같은 u_j 를 공유.
- 그러나 hazard는 공간상 연속적으로 변할 가능성. 같은 골목 안에서도 도로변 점포와 안쪽 점포가 다를 것 — random scalar 대신 random field가 필요.
- Cox process가 그 일반화.

△ frailty 분포 식별성 (v1.3 추가)

문제 진단.

frailty u_j 의 분포 가정(보통 gamma 또는 lognormal)이 데이터로부터 강하게 식별되지 않는다.

근거.

- Hougaard(1995): 동일한 marginal hazard 패턴이 매우 다른 frailty 분포(gamma, lognormal, positive stable, inverse Gaussian)로 설명될 수 있음. *관측되는 marginal로는 분포 형태를 구별 불가.*
- 클러스터 크기가 작을수록 식별성 악화. 본 연구에서 "한 골목 안 점포 5~10개" 수준의 클러스터는 식별성이 매우 낮음.
- 결과적으로 frailty 분포 가정 자체가 추정 결과를 좌우할 위험. "클러스터 의존성이 크다"는 결론이 데이터의 실증인지 분포 가정의 결과인지 구별 어려움.

세 대안 비교.

- (a) 표준 gamma frailty 채택, 분포 가정 명시. 가장 단순. parsimony principle. 그러나 분포 가정의 결과 의존성이 결과에 따라다님.
- (b) 다중 분포로 sensitivity 분석. gamma-lognormal-positive stable 세 분포로 결과 비교. 분포 가정의 영향력을 정량화.
- (c) 비모수 frailty (NPMLE). Heckman & Singer(1984)의 비모수 mixing distribution. 분포 가정 자체를 제거하지만 추정 복잡도 급증, 작은 클러스터에서 수렴 불안정.

채택 이유 — (b).

- (a)는 결과에 분포 가정의 흔적이 그대로 남음 — "gamma 가정 하에서"라는 단서가 따라다님.
- (c)는 본 연구의 클러스터 크기로는 추정 안정성 문제.
- (b)는 절충 — 두~세 분포로 sensitivity 분석을 §IV.6의 부속 산출물로 둬. 결과가 분포에 따라 크게 바뀌면 "*frailty 효과 자체의 신뢰도를 낮춰 보고*"하고, 일관되면 "*결과가 분포 가정에 robust*"라고 보고. 정직성 확보.

실무 결과: §IV.6의 frailty 분석은 gamma-lognormal 두 분포로 병행 추정. 결과를 부속 표로 비

교. 클러스터 크기가 작을 때(예: 한 골목 5~10개)는 *frailty* 효과의 점추정값보다 "분포 가정 간 변동 범위"를 신뢰 가능 범위로 보고.

§IV.7 Cox process — 5-2 버티는 힘 $\lambda_{\text{survive}}(x)$

*frailty*의 *random scalar*를 *random field*로 일반화. *Cox process*(Cox 1955)는 *doubly stochastic Poisson process*라고도 불리며, 강도함수 자체가 *stochastic process*다 — 여기서는 *hazard intensity field*.

△ 두 'Cox'의 구분 (v1.3 추가)

v1.2까지 §IV.4 Cox 비례위험과 §IV.7 Cox process를 자연스러운 도구 시퀀스로 묶었지만, 두 모델이 별개임을 명시하지 않았다. v1.3에서 이를 정정한다.

문제 진단.

"Cox"라는 용어가 통계학에서 두 가지 다른 모델을 가리킨다 — 둘 다 David Cox가 도입했지만 수학적으로 별개:

- **Cox process (Cox 1955) = doubly stochastic Poisson process.** 점과정의 강도함수 $\Lambda(t, x)$ 가 random field. LGCP가 대표 사례.
- **Cox proportional hazards (Cox 1972).** 생존분석의 비례위험 회귀. $h(t|z) = h_0(t) \exp(\beta^T z)$.

근거.

- 두 모델은 분석 단위가 다름 — 전자는 점과정의 점, 후자는 개체의 hazard.
- 두 모델은 추정 방법이 다름 — 전자는 Bayesian + GP / 후자는 partial likelihood.
- 도구 시퀀스의 자연스러움이 이름의 우연한 일치에 일부 기댐 — 사용자가 "Cox에서 Cox로 간다"고 받아들일 위험.

frailty → Cox process로 가는 정확한 다리.

§IV.6 frailty와 §IV.7 Cox process 사이에 사실 한 단계가 더 있다 — spatial frailty:

- **frailty u_j :** 클러스터 j 당 random scalar (예: 한 골목 안 모든 점포가 공유하는 미관측 hazard 가중치).

- **spatial frailty $u(x)$** : 공간 위치 x 에 따라 부드럽게 변하는 random function. 같은 골목 안에서도 도로변과 안쪽이 다른 frailty.
- **Cox process $\Lambda(t, x)$** : hazard intensity 자체가 random field. spatial frailty의 자연스러운 일반화.

즉 시퀀스는 정확히 **scalar frailty $\rightarrow$ spatial frailty $\rightarrow$ random hazard field**. §IV.6과 §IV.7 사이에 spatial frailty가 미명시 단계로 들어 있는 셈. 본 연구는 §IV.6에서 scalar frailty를, §IV.7에서 random field를 다루고, 그 사이의 spatial frailty는 두 절의 가교로 짧게 언급한다.

채택한 표기 방침.

- §IV.7 모형 식에서 hazard intensity를 $\Lambda(t, x)$ 로 쓰되, 이것이 Cox(1955)의 doubly stochastic 의미임을 모형 도입부에서 명시.
- §IV.4의 Cox 비례위험과 §IV.7의 Cox process가 별개임을 "두 'Cox'의 구분" 박스로 책한 곳(여기)에서 명시.
- 향후 발표·면접에서 청중에게 동일한 구분을 전달하는 것을 권장 — 이름의 우연한 일치를 활용하되 그 일치가 본질이 아님을 분명히.

Cox process로서의 hazard

$$h(t, x \mid \Lambda) = \Lambda(t, x), \quad \Lambda(\cdot) \sim \text{Stochastic process}$$

$\Lambda(t, x)$ 가 결정론적이 아니라 그 자체가 무작위 객체. 가장 자주 쓰이는 형태는 log-Gaussian Cox process (LGCP):

$$\log \Lambda(t, x) = m(t, x) + G(t, x), \quad G \sim \text{Gaussian Process}(\theta, K)$$

$m(\cdot)$ 은 결정론적 평균(공변량 효과), $G(\cdot)$ 는 공간·시간 공분산 K 로 정의되는 Gaussian field.

hazard의 공간 분포 자체가 부드럽게 변하는 random field로 모델링됨.

5-2 버티는 힘 $\lambda_{\text{survive}}(x)$

Part I 5단계가 잠재 배경을 $\mu(x)$ 로 "어디에 점포가 자생적으로 생기는가"를 봤다면, 5-2는 **잠재 생존력 $\lambda_{\text{survive}}(x)$** — "어디에 있으면 점포가 자연스럽게 오래 사는가"를 본다.

△ "버티는 힘"의 정확한 정의 (v1.3 추가)

문제 진단.

v1.2까지 " $1/\lambda_{\text{survive}}(x)$ 가 평균 영업 기간"이라고 적었다. 이는 **hazard가 시간 상수일 때만 성립하는 식**. 일반적으로 hazard는 시간의 함수이고, 평균 수명은 hazard의 단순 역수가 아니다.

근거.

survival function $S(t)$ 와 hazard function $\lambda(t)$ 의 관계:

$$S(t) = \exp(-\int_0^t \lambda(s) ds), \quad \text{평균 수명} = \int_0^\infty S(t) dt$$

- hazard가 시간 상수 λ 일 때만 $S(t) = \exp(-\lambda t)$, 평균 수명 = $1/\lambda$.
- 일반 hazard에서는 평균 수명을 $1/\lambda$ 로 환산할 수 없음.
- 점포의 hazard는 거의 확실히 시간 상수가 아님 — 개점 직후 위험(초기 폐업률), 안정기 위험, 임대료 인상기 위험이 다 다름.

정정된 정의.

"버티는 힘"의 정확한 의미를 두 층위로 분리:

- **(a) 좁은 의미 — 위치 x 의 instantaneous hazard.** $\lambda_{\text{survive}}(x)$ 가 작으면 "이 위치에서 지금 살아있는 점포가 다음 순간 폐업할 위험이 작다". 시점·공변량에 의존하지 않는 단순 척도가 필요할 때만 유효.
- **(b) 넓은 의미 — 위치 x 의 hazard 함수 전체.** $\lambda_{\text{survive}}(x, t, z)$ 가 시간과 공변량의 함수. 책의 정식 정의는 이쪽. 정책 대화에서 "이 위치에서 점포가 평균 X 년 산다"라고 환산하려면 $S(t|x, z)$ 의 적분이 필요하며, 그 적분은 임대료 z 등 공변량의 미래 경로에 의존.

§IV.7 본문에서 $\lambda_{\text{survive}}(x)$ 는 일반적으로 (b)의 의미로 쓰되, "*이 지역의 평균 영업 기간이 X 년*"

이라는 정책 대화용 진술을 할 때는 다음 두 단계를 명시:

- (1) 공변량을 표본 평균값에 고정
- (2) 추정된 hazard 함수의 survival function 적분으로 평균 수명 계산

이 두 단계 없이 " $1/\lambda_{\text{survive}}(x)$ "를 평균 수명으로 발표하는 것은 hazard의 시변성을 무시한 **부정확한 진술**.

채택 이유.

- 정책 대화의 직관성과 통계적 정확성 사이의 균형. "버티는 힘"이라는 작명은 그대로 유지(직관적이고 한국어 친화적)하되 정의의 두 층위를 명시(통계적 정확성).
- 좁은 의미는 면적·짧은 발표에서, 넓은 의미는 본격 분석에서 쓴다.
- $S(t)$ 적분으로 평균 수명을 환산하는 절차는 §IV.3 KM 곡선의 자연스러운 연장이라 본문 흐름에 부합.

§IV.7 킬러 페이지 — $\mu(x)$ 와 $\lambda_{\text{survive}}(x)$ 의 두 지도 비교

두 장의 서울 지도를 나란히:

- (왼쪽) $\mu(x)$ — 입점 강도 지도. Part I 5단계의 결과. "어디에 점포가 자생적으로 들어오는가"
- (오른쪽) $\lambda_{\text{survive}}(x)$ — 버티는 힘 지도. §IV.7의 결과. "어디에서 점포가 오래 사는가".
(공변량을 표본 평균값에 고정한 평균 수명 $1/\lambda(x)$ 로 시각화. 정확한 환산은 위 "넓은 의미" 참조.)

핵심 발견 후보: 두 지도가 같지 않다.

- 입점이 잘 되는 곳 $\neq$ 생존이 잘 되는 곳.
- 강남대로는 $\mu(x)$ 큼(많이 들어옴) + $\lambda_{\text{survive}}(x)$ 작음(오래 버팀) — 강력 입지
- 성수동은 $\mu(x)$ 빠르게 증가(태동) + $\lambda_{\text{survive}}(x)$ 큼(짧은 수명) — 회전이 많은 신흥 상권
- 종로 일부는 $\mu(x)$ 작음(들어가지 않음) + $\lambda_{\text{survive}}(x)$ 작음(들어가면 오래) — 진입 장벽 + 안정
- 이 4사분면 분류가 §VI.6 엔트로피 기반 분류와 결합되면 매우 풍부한 도시 진단 도구가 됨

LGCP 추정

Bayesian inference: Gaussian process prior + 점과정 likelihood + MCMC 또는 variational inference. 계산 비용이 크다 — Miskouridou et al.(2022) Cox-Hawkes 논문이 π VAE 기반 GP 근사로 이를 해결.

이 단계의 의미

- **점과정과 생존분석의 융합점.** Cox process는 생존분석의 끝이자 점과정의 시작. hazard intensity가 random field가 되는 순간 우리는 이미 점과정의 영토에 있다.
- **$\mu(x)$ 와 $\lambda_{\text{survive}}(x)$ 의 통합.** 두 지도는 "태어남"과 "생존"의 두 차원. Part V Cox-Hawkes가 여기에 "전파"($\alpha(x \rightarrow \cdot)$)를 더해 세 차원으로 도시를 읽게 한다.
- **Part V로의 마지막 다리.** Cox process는 자기여기 항을 받아들이는 순간 Cox-Hawkes가 된다. §IV.8에서 그 다리를 명시한다.

§IV.8 이 단계가 대답할 수 없는 것 (→ Part V로)

Part IV의 한계는 명확하고, 그 한계가 정확히 Part V Cox-Hawkes를 부른다.

- **점포 간 상호작용의 부재.** Cox 회귀와 그 일반화들은 각 점포(또는 클러스터)를 독립/단위로 본다. '이웃 점포의 폐업이 본 점포의 hazard를 올리는가' — 폐업이 폐업을 부르는 연쇄 — 는 frailty의 미관측 이질성으로 흐릿하게만 흡수된다. 명시적 self-excitation이 필요.
- **자기여기와 외생 효과의 식별.** Cox process의 random field $G(t, x)$ 에는 두 가지가 섞여 있다 — (i) 진짜 외생적 공간 이질성(임대료·유동인구의 평균 수준), (ii) 점포 간 자기여기의 누적 효과. Cox process만으로는 분리 불가. Cox-Hawkes에서 비로소 분리됨.
- **입점 사건의 부재.** 생존분석은 폐업이라는 한 종류의 사건만 다룬다. 본 연구의 4유형($B^+B^-R^+R^-$) 중 폐업 두 유형(B^-R^-)만 분석 대상. 입점 사건의 시공간 동학은 점과정 시각이 필요.
- **censoring과 Hawkes의 history dependence의 충돌.** Hawkes에서는 모든 과거 사건이 현재 강도에 영향. 그러나 right censoring으로 잘린 점포의 history는 부분적으로만 관측됨. 이 mismatch를 Cox-Hawkes에서 어떻게 처리할 것인지는 비자명한 문제 — Part V §3.7.4 식별 전략과 직접 연결.

이 네 한계가 모두 한 방향을 가리킨다 — **Cox process의 random hazard field에 Hawkes의 자기여기 항을 더하는 결합 모형이 필요.** 이것이 Cox-Hawkes이고, Part V의 본체다.

도구 시퀀스의 종착점.

- life table → KM → Cox → Andersen-Gill → Frailty → Cox process까지 왔다.
- 각 단계가 앞 단계의 가정 하나를 풀었다.
- 마지막으로 "개체 독립" 가정 — 사건들이 서로를 유발하지 않는다는 가정 — 을 풀면 Cox-Hawkes.
- Part V는 이 마지막 도약을 다룬다.

Part V — Cox-Hawkes: 외생적 배경과 내생적 자기여기의 결합

v1.1에서 이 파트는 기존 v1.0 Part IV(공변량 조건부 background)를 **Cox-Hawkes**라는 정식 이름으로 격상한 것. 본문은 v0.6~v0.7의 §3.7 내용을 그대로 사용하되, 도입부에서 Cox-Hawkes의 학술적 위치와 Mohler(2013) 계보, Andersen-Gill multiplicative intensity model로의 등치를 명시한다.

§V.0 도입 — Cox와 Hawkes는 어떻게 만나는가

Part IV에서 Cox 회귀를 단독으로 만났고, Part I~III에서 Hawkes를 단독으로 만났다. 이제 두 도구의 결합 형태가 자연스럽다. 결합의 핵심 통찰:

두 모형은 같은 수학적 객체를 다룬다 — **conditional intensity function**.

- **Cox의 hazard:** $h(t \mid \text{history}, z) = h_0(t) \cdot \exp(\beta^T z)$ — '시점 t 까지 살아남은 개체가 다음 순간 사건을 일으킬 비율'.
- **Hawkes의 conditional intensity:** $\lambda(t \mid \text{history}) = \mu + \sum \alpha \cdot g(t-t_i)$ — '시점 t 에 사건이 발생할 비율, 과거 사건 history에 조건부'.

두 식은 어휘만 다를 뿐 같은 수학적 객체다. Andersen & Gill(1982)의 **multiplicative intensity model**이 두 분야를 잇는 정식 다리:

$$\lambda(t \mid \text{history}) = Y(t) \cdot \alpha_0(t) \cdot \exp(\beta^T z(t))$$

$Y(t)$ 는 risk indicator (개체가 t 에 위험에 노출되어 있는가), $\alpha_0(t)$ 는 baseline hazard. 이 식이 Cox 회귀(Hawkes 항 없음)와 Hawkes($Y=1$, $\exp(\beta^T z)=1$, $\alpha_0 = \mu + \sum \alpha \cdot g$)의 공통 지붕이다. 두 분야의 추정 이론(partial likelihood, counting process martingale CLT)이 모두 이 틀에서 통합된다.

△ "공통 지붕" 주장의 정확한 강도 (v1.3 추가)

문제 진단.

위 "AG가 Cox와 Hawkes의 공통 지붕" 진술은 수학적으로는 정확하지만 실용적으로는 두 모델을 한 모델처럼 다룰 수 있다는 의미가 아니다. v1.2까지의 표현은 다소 강해서 오해의 여지가

있었다.

근거.

- AG framework는 counting process martingale 이론의 추상적 일반 틀.
- Cox와 Hawkes가 그 안에 특수 경우로 들어가는 것은 사실이지만 분석 단위·추정 절차가 별개.
- AG로 둘을 묶는다고 결합 모형(Cox-Hawkes)이 자동으로 따라오지 않음 — 결합은 별도 모형 설계 작업.

정정된 표현.

- ✓ "AG가 두 모형이 같은 추상 틀에 들어감을 보장한다"
- ✗ "AG로 두 모형이 한 모형처럼 다뤄진다"
- ✓ "Cox-Hawkes는 AG 틀의 한 구체적 결합 인스턴스이며, 별도 모형 설계와 추정 작업을 요구한다"

실무 결과: §V.0의 AG 등치 주장은 "이론적 통합 가능성의 보장" 수준으로 명시. "실용적으로 한 모형이다"는 표현은 피한다. Cox-Hawkes(§V.1 이하)는 이 보장 위에서 별도 작업으로 세워지는 결합 모형으로 위치 짓는다.

§V.1 Mohler(2013)의 계보 — 같은 결합 모델의 직접 선례

Mohler(2013) *"Modeling and estimation of multi-source clustering in crime and security data"* (Annals of Applied Statistics 7(3), 1525–1539)는 본 연구의 §3.7.2와 본질적으로 같은 모델을 범죄 데이터에 적용한 직접 선례다:

$$\lambda(t, x) = \mu_0(x) \cdot \exp(w^T z) + \sum \alpha \cdot \exp(-\beta(t-t_i)) \cdot f(x-x_i)$$

- **Cox 부분 (외생):** $\mu_0(x) \cdot \exp(w^T z)$ — 공변량 z 에 따라 변하는 외생적 배경율. 공간적 입지(μ_0)와 시변 공변량(z)의 결합.
- **Hawkes 부분 (내생):** $\sum \alpha \cdot \exp(-\beta(t-t_i)) \cdot f(x-x_i)$ — 과거 사건들이 현재 강도에 더하는 자기여기. 시간 감쇠와 공간 커널.

Mohler는 이 모델로 시카고 범죄 데이터에서 외생적 패턴(주거지 특성·인구밀도)과 내생적 연쇄(범죄 후 추가 범죄)를 분리했다. 본 연구의 적용 도메인이 다를 뿐 — 도시 상권의 점포 입·폐점 — 모델 구조는 같다. **이로써 본 연구는 Cox-Hawkes의 정통 계보에 명시적으로 위치한다.** v0.6의 자기비판에서 출발한 §3.7의 도달점이 사실 Mohler가 13년 전 동일 분야에서 이미 사용한 도구였음을 인정하는 것이 정확한 위치짓기.

△ Mohler 식 표기의 정확성 (v1.3 추가)

문제 진단.

위 식 $\lambda(t, x) = \mu_0(x) \cdot \exp(w^T z) + \sum \alpha \cdot \exp(-\beta(t - t_i)) \cdot f(x - x_i)$ 는 본 연구가 채택한 결합 모델의 기본 형태이지만, 이를 "Mohler(2013)의 정확한 식"으로 인용하는 것에는 주의가 필요하다.

근거.

- Mohler(2013)은 multi-source clustering의 일반 프레임을 다뤘으며, 본문에 정확히 위 형태 식이 등장하는지는 원본 검증 필요.
- Mohler·Brantingham·Carter·Short(2018) 등 후속 논문에서는 식 형태가 약간씩 변형됨 (예: marked process 확장, 시간 커널을 거듭제곱으로 등).
- Reinhart(2018)의 self-exciting spatio-temporal point process 리뷰에서 이 결합 형태가 "Mohler 계열"로 일반화되어 소개됨 — 정확한 출처는 단일 논문이 아닌 이 계열 전체.

정정된 인용 방식.

위 식은 다음 중 하나로 표기:

- **(a) 보수적 표기:** "Mohler 계열 결합 모델 (Mohler 2013, 2014; Reinhart 2018 리뷰)".
단일 논문에 식을 귀속시키지 않음.
- **(b) 검증 후 정확 인용:** Mohler(2013) 원본을 직접 확인 후 식 형태가 일치하면 그대로 인용, 차이가 있으면 "Mohler(2013)의 일반화"로 표기.

채택 — (a) + 향후 (b).

- 로드맵 단계에서는 (a) 보수적 표기를 채택. "Mohler 계열" 또는 "Mohler 2013 + Reinhart 2018 리뷰의 변형"으로 본문 표기.
- 논문 작성 또는 책 출판 단계에서 Mohler(2013) 원본을 확인하고 (b)로 정확 인용으로 전환.
- 이는 학술적 정확성과 현재 단계의 작업 비용 사이의 절충 — 로드맵 단계에서 원본 검증의 비용은 크지만, 출판 단계에서는 필수.

실무 결과: 본 §V.1 본문은 "Mohler 계열 결합 모델"로 표기 강도를 조정. 식 자체는 본 연구가 채택한 결합 형태로 명시(이는 Mohler 계열의 정신을 따름). 출판 시 정확 인용으로 전환할 항목으로 todo에 등재.

Mohler 모델의 의미 — 본 연구의 차별성과 함께.

- **Mohler가 한 것:** 범죄 데이터, 단변량(범죄 사건 하나의 유형), 모수적 log-linear $h(z) = \exp(w^T z)$.
- **본 연구가 다르게 하는 것:** 도시 상권 데이터, 다변량(입·폐점 4유형 또는 m개 브랜드), §3.7.4 Stage 2~3에서 비선형 $h_k(z)$ 로 확장. 그리고 Part IV 생존분석과 결합한 통합 진단 (Schoenfeld + Ogata residuals).

§V.2 Andersen-Gill counting process로의 등치

두 분야의 어휘 사전:

- **Hawkes 어휘** → **생존분석 어휘**. conditional intensity → hazard rate / branching ratio n^* → reproduction number / parent probability p_{ij} → competing risks의 cause-specific hazard.
- **Cox 어휘** → **Hawkes 어휘**. partial likelihood → 점과정의 marked likelihood / Schoenfeld residuals → Ogata residuals의 자매 / time-varying covariate → exogenous Cox component.

- **Frailty model.** 개체별 random effect를 baseline hazard에 곱한 모형. Hawkes 어휘로는 '개체별 μ_i 가 latent 분포에서 추출됨'. 본 연구의 §3.5 EM이 잠재 $\mu(x)$ 를 추정하는 것과 정확히 같은 정신.

이 사전이 단순한 유식한 척이 아닌 이유: 두 분야의 추정·진단 도구가 서로 빌릴 수 있음을 의미. 본 연구의 §II.3 Ogata 잔차에 §IV.4의 Schoenfeld 잔차를 더하면 잔차 진단의 두 시각이 결합. R의 `survival::coxph + spatstat::Hawkes`가 한 데이터에 동시 적용 가능 — Cox-Hawkes 추정의 sanity check.

§V.3 Cox-Hawkes 고유의 식별 문제 (v1.3 추가)

§3.7.4에서 다룬 식별 문제(μ^0 와 z 의 공간 상관)는 모수적 회귀 형태에 한정됐다. Cox-Hawkes로 모형이 더 풍부해지면 새로운 식별 문제들이 생긴다. v1.3에서 이를 명시한다.

문제 진단.

Cox-Hawkes는 세 종류의 무작위 객체를 동시에 추정한다 — 결정론적 공변량 효과($\beta^T z$), 외생적 random field $G(t, x)$ (LGCP background), 내생적 자기여기 항($\alpha \cdot g \cdot f$). 이 세 항이 모두 "공간·시간상 군집"을 만들 수 있다는 데서 식별 문제가 발생.

근거 — 세 가지 새 식별 문제.

문제 ⑤ background random field와 self-excitation의 분리.

- LGCP의 random field $G(t, x)$ 가 만드는 군집과 Hawkes triggering이 만드는 군집은 형태가 비슷.
- 동일한 데이터를 "random field가 만든 군집" 또는 "self-excitation이 만든 군집"으로 둘 다 설명 가능.
- Bayesian inference의 posterior가 두 해석에 의해 봉우리가 두 개 있을 수 있음 (multimodality).

문제 ⑥ LGCP hyperparameter의 약한 식별성.

- LGCP의 핵심 hyperparameter — GP의 length scale ℓ 과 amplitude σ — 가 데이터로부터 약하게만 식별됨. *Diggle et al.(2013)*, *Møller & Waagepetersen(2003)*의 잘 알려진 문제.
- 관측된 군집 크기는 ℓ 과 σ 의 곱에 주로 의존하므로 둘을 분리 추정 어려움.
- 실용적 결과: 적절한 약한 prior(예: half-normal on ℓ , lognormal on σ)이 거의 필수. prior 의존성이 결과를 좌우.

문제 ⑦ Mohler 모델 분리 가능성의 경계.

- Mohler 본인이 후속 작업(Mohler 2014; Mohler & Carter 2018)에서 짚은 문제 — 충분한 사건 수와 시공간 해상도가 없으면 Cox 부분 $\mu_0(x) \cdot \exp(w^T z)$ 와 Hawkes 부분 $\Sigma \alpha \cdot g \cdot f$ 의 기여도 분리가 어렵다.
- 특히 가로수길처럼 좁은 공간(약 0.5km × 0.5km)에서 사건 수가 수백 이하면 분리가 거의 안 됨. 광역 분석(서울 전체 또는 강남구 전체)에서만 신뢰할 만한 분리가 가능.

세 대안 비교.

- **(a) 식별 가정을 명시적으로 추가.** 예: "length scale $\ell < 100m$ "이라는 prior로 random field를 매우 국소적으로 제약. 이러면 self-excitation이 광역 군집을 담당. 그러나 가정 자체가 결과를 좌우.
- **(b) 광역 분석으로 사건 수 확보.** 강남구 전체-서울 5개 권역으로 확장. 사건 수 충분히 확보 후 식별 가능성 자체가 데이터로부터 검증. 단, 가로수길에 한정한 미세 동학은 포기.
- **(c) 부분 식별 보고.** Cox-Hawkes 추정 후 "식별 가능한 모수"와 "식별 불가능한 모수"를 명시 분리. partial identification literature(Tamer 2010)의 정신 적용.

채택 이유 — (b) 우선, (c) 보완.

- (a)는 사용자가 결과를 사전에 결정하는 위험.
- (b)가 가장 정직한 길 — 분석 단위를 광역으로 잡고 그 안에서 식별 가능성을 데이터로 검증.

- 그러나 가로수길 사례 자체가 본 연구의 핵심이므로 광역만 보면 정책적 호소력이 약화. 따라서 **이중 분석 전략**: 강남구 전체에서 (b) 식별 검증 + 가로수길에서 (c) 부분 식별 보고. 두 결과를 함께 제시.

LGCP hyperparameter 처리.

- Half-normal prior on length scale: $\ell \sim \text{HalfNormal}(\text{scale}=200\text{m})$. *범조/ Hawkes 분석*에서 표준 (Mohler 2014).
- Lognormal prior on amplitude: $\sigma \sim \text{LogNormal}(0, 1)$.
- Sensitivity 분석: 두 prior의 hyperparameter를 $\pm 50\%$ 변경 시 결과 변동 보고.

실무 결과: §V.3은 식별 문제를 "모수 추정값의 신뢰도 구간"으로 환원. 모든 §V 결과는 (a) 강남구 광역 분석의 식별 검증 결과, (b) 가로수길 부분 식별 결과, (c) prior sensitivity의 세 층위로 보고된다.

§V.4 결합 형태의 선택 근거 (v1.3 추가)

Cox-Hawkes는 점과정과 생존분석의 결합 모델 중 하나일 뿐. 다른 결합 형태가 가능하므로 그 선택의 근거를 명시할 필요가 있다.

문제 진단.

점과정의 background와 triggering 두 항 각각이 결정론적이거나 stochastic일 수 있어, 4가지 조합이 가능하다.

결합 형태	Background	Triggering
표준 Hawkes	결정론적 (μ 상수 또는 함수)	결정론적 (α, β, f 가 모수)
Cox-Hawkes (본 연구 채택)	Stochastic (LGCP 또는 GP prior)	결정론적 (α, β, f 가 모수)
Hawkes-Cox	결정론적 (μ 상수 또는 함수)	Stochastic (α 자체가 random field)

결합 형태	Background	Triggering
Doubly random Hawkes	Stochastic	Stochastic

네 형태의 비교.

- **표준 Hawkes (현재의 Part I~III):** 최단순. background와 triggering 모두 결정론적. 이미 본 연구의 출발점.
- **Cox-Hawkes:** background가 stochastic. 외생적 환경(임대료·유동인구·미관측 입지 효과)의 무작위성을 명시적으로 모형화.
- **Hawkes-Cox:** triggering 자체가 stochastic. 같은 점포라도 입점할 때마다 다른 강도로 자기여기를 일으킨다고 가정.
- **Doubly random:** 둘 다 stochastic. 가장 일반적이지만 식별·추정 비용 모두 폭증.

Cox-Hawkes 채택의 근거.

- ① **자기비판의 자연스러운 종착점.** v0.6 §3.7의 자기비판은 "외생적 환경의 무작위성과 미관측 이질성"을 다루기 위해 시작됨. background를 stochastic으로 만드는 것이 정확히 그 답. Hawkes-Cox나 Doubly random은 이 자기비판이 묻는 문제와 다른 문제를 풀게 됨.
- ② **점과정 분야의 학술적 정통성.** Mohler 2013 이래 "외생적 background + 결정론적 triggering"이 도시·범죄 점과정의 표준 결합 형태. Hawkes-Cox는 본 연구가 다루는 도메인에서 거의 사용되지 않음. 학술 대화의 공통 어휘를 유지.
- ③ **식별·추정 가능성.** Cox-Hawkes는 LGCP-Hawkes로 구체화되면 numpyro 등 표준 도구로 추정 가능. Doubly random은 식별 검증조차 어려움.
- ④ **정책적 의미의 명료성.** background가 임대료·유동인구로 변하고 triggering이 일관된 "앵커 효과"라면, 정책 개입은 z 의 변화를 통해 background에 작용하는 형태로 설계 가능. Hawkes-Cox 형태는 "앵커 효과 자체가 무작위"라 정책 시뮬레이션의 의미가 약화.

결론 — Cox-Hawkes(LGCP-Hawkes 구체화)가 본 연구의 자기비판·도메인 정통성·식별 가능성·정책 의미 네 측면 모두에서 다른 결합 형태보다 우위. 이 선택이 자의적이지 않다는 것을 §V.4에서 명시함으로써 "왜 이 형태인가"라는 심사자의 잠재 질문에 선제적으로 답한다.

이하 §3.7 본문 — 본문의 §3.7.1~§3.7.6은 v0.6~v0.7에서 형성된 진단·제안·구현 전략을 그대로 이어간다. §3.7은 위 §V.0~§V.4의 학술적 위치짓기 위에서 본 연구의 구체적 모델 명세·식별 전략·구현 단계로 들어간다.

3.7 Cox-Hawkes 본문 — 공변량 조건부 배경율과 비정상성의 명시화

v0.6 신설. 자기비판에서 출발한 확장 단계. §3.5(5단계)의 EM으로 $\mu(x)$ 를 공간 함수로 풀었지만, 시간적 비정상성과 이벤트 유형 간 구조적 종속성은 여전히 풀리지 않은 채 남아 있다. 이 절은 그 공백을 메우는 후속 단계를 설계한다.

3.7.1 진단 — v0.5까지의 모델이 무엇을 놓치는가

네 가지 구조적 한계 (v0.7에서 한계 ④ 추가).

한계 ① 폐점 배경율의 부자연스러움.

v0.5 §3.6에서 $\mu_{\{B^-\}}(x)$ 를 Blue 입점의 $\mu_{\{B^+\}}(x)$ 와 대등한 공간 함수로 다뤘다. 그러나:

실제 폐점 가능성 $\propto$ 현재 존재하는 점포 수

폐점은 점포가 있어야 일어나는 이벤트이기 때문에, 배경율의 공간 패턴은 본질적으로 기존 점포 분포의 함수이지 공간 자체의 속성이 아니다. 이것을 무시하면 모델은 '점포 밀집 지역 = 자생적 폐점이 잘 일어나는 곳'이라는 왜곡된 해석을 내놓는다.

한계 ② 시간 불변 $\mu(x)$.

$\mu(x)$ 는 공간의 함수이지만 시간에 대해서는 상수다. 그러나 젠트리피케이션 4기(공동화)의 핵심 관측은 동일한 공간에서 시간에 따라 입점 성향이 고갈되는 것. μ 가 시간에 불변이면 이 현상은 α 계수를 통해서만 설명 가능하다. 그러나:

- 표준 선형 Hawkes는 $\alpha \geq 0$ 을 요구 (강도함수가 음수가 되면 안 됨) → 억제 효과를 직접 표현 불가
- 억제를 허용하는 비선형 확장(Nonlinear Hawkes)은 추정 복잡도 급증
- 더 본질적으로, 4기 공동화는 '과거 사건이 미래 사건을 억제해서'가 아니라 '공간 자체의 매력이 식어서' 일어난다 — 인과적으로 전혀 다른 기전

한계 ③ 비정상성의 서술 대 설명.

만약 $\mu(x, t)$ 로 확장해 '시간에 따라 배경율이 바뀐다'고 허용한다면 한계 ②는 해소된다. 그러나

*왜 바뀌는지*는 모델 안에 없다. 비정상성을 **서술만 하고 설명은 하지 않는** 상태. 정책 시뮬레이션이나 미래 예측에는 불충분하다 — '임대료 보조로 배경울을 회복시키면?' 같은 개입 질문이 원천적으로 답할 수 없는 형태가 된다.

한계 ④ 식별 문제 (v0.7 추가).

이 한계는 한계 ①②③을 공변량 조건부 μ 로 해소하려 할 때 **새로 생겨나는 통계적 문제**다. 제안 구조 $\mu_k(x, t) = \mu_k^0(x) \cdot h_k(z(x, t))$ 는 **불변 입지** $\mu_k^0(x)$ 와 **시변 공변량** $z(x, t)$ 를 역할 분리하는 것을 목표로 하지만, 두 항이 실제 데이터에서 **공간적으로 강하게 상관될** 가능성이 크다. 가로수길 예시:

- 임대료 $z_1(x, t)$ 는 지하철역 거리, 대로변 여부, 상권 중심지와와의 거리에 따라 거의 결정론적으로 분포 — 불변 입지 $\mu^0(x)$ 의 공간 패턴과 사실상 겹친다.
- 유동인구 $z_2(x, t)$ 도 같은 공간 구조를 공유.
- 결과: $\mu^0(x)$ 가 z 의 공간적으로 구조화된 부분을 흡수하거나, 반대로 z 가 μ^0 의 시간 평균적 성분을 흡수. 두 방향 모두 편향.

이 식별 문제는 **추정 전략의 선택을 좌우**한다. 구체적 대응은 §3.7.4에서 세 재설계 옵션의 비교로 다룬다. 중요한 것은 이 한계가 *Mohler 의미의 α 과대추정 문제를 한 층 안쪽으로 옮겨서 재현*할 위험이 있다는 점 — μ^0 가 너무 많은 것을 흡수하면 z 가 설명해야 할 효과를 μ^0 가 대신 설명하고, $h_k(z)$ 계수가 과소추정된다.

3.7.2 제안 — 공변량 조건부 배경울

위 세 한계를 한 번에 해소하는 확장은 μ 의 **조건부화(conditioning)**다. 구체적으로:

$$\mu_k(x, t) = \mu_k^{\theta}(x) \cdot h_k(z(x, t); \theta_h)$$

여기서 각 요소의 의미는:

- **$\mu_k^{\theta}(x)$:** 공간의 불변 구조 — 지하철 접근성, 도로 구조, 상가 구획 형태 등 *변하지 않는 입지 조건*. §3.5(5단계)의 EM으로 추정.

- $\mathbf{z}(\mathbf{x}, t)$: 시변 공변량 벡터 — *평당 임대료, 유동인구, 지하철 이용객, 주변 오피스 공실률, 미디어 노출도, 현재 점포 수* 등. 외부 데이터로 관측.
- $\mathbf{h}_k(\mathbf{z}; \boldsymbol{\theta}_h)$: 이벤트 유형 k 별 조건부 반응함수. 예: *임대료가 오르면 B^+ 가 줄고 B^- 가 는다*는 구조를 $\boldsymbol{\theta}_h$ 가 학습.

이 구조가 한계 ①②③을 동시에 해소하는 방식:

- 한계 ①. $\mathbf{z}(\mathbf{x}, t)$ 에 *현재 Blue 점포 수 $N_B(\mathbf{x}, t)$* 를 포함하면, $\mu_{\{B\}}(\mathbf{x}, t) \propto N_B(\mathbf{x}, t)$ 가 자연스럽게 유도된다. 폐점의 '존재 조건부' 의존성이 모델 안에서 표현됨.
- 한계 ②. μ 가 시간의 함수가 되어 4기 공동화를 배경을 감쇠로 설명 가능. α 는 *진짜 자기여기*만 담당하고, 비정상성은 μ 가 담당 — 역할 분리.
- 한계 ③. 임대료·유동인구 등의 공변량으로 배경을 조건화하면 *왜 비정상인지*가 모델 안에서 설명된다. 개입 시뮬레이션이 의미를 갖는다 — '임대료 정책으로 $\mathbf{z}$ 를 바꿨을 때 μ 가 어떻게 움직이고 λ 가 어떻게 변하나'.

3.7.3 Mohler의 지적과 가로수길

Mohler(2014)는 배경을 상수로 두거나 과도하게 단순하게 모델링하면 **자기여기 α 가 실제로 다 크게 추정됨**을 지적했다. 이는 범죄 데이터보다 젠트리피케이션 데이터에서 더 심각하게 적용된다. 가로수길 맥락에서:

- 메인 도로변과 이면도로, 신사역 근접지와 압구정 쪽 끝은 $\mu(\mathbf{x})$ 가 명백히 다르다.
- μ 를 상수로 두면 모델은 '메인 도로변에 점포가 몰려 있는' 현상을 '앞선 입점이 뒤 입점을 불렀다'(α 효과)로 오독한다.
- 결과: $\alpha(B^+ \leftarrow B^+)$ 가 과대추정 → *크리에이티브 클러스터링 효과를 가짜로 부풀림*.

v0.5의 §3.5(5단계 EM)는 이 문제의 **공간적** 부분을 해결한다. §3.7의 공변량 조건부화는 **시간적** 부분을 마저 해결한다. 두 확장이 합쳐져야 Mohler 의미의 편향이 제대로 제거된다.

3.7.4 구현 전략 — 식별 문제에 대응한 재설계 (v0.7)

v0.6에서는 **점진적 확장**(Phase A → B → C)이라는 소프트웨어 엔지니어링 순서를 따랐다. 그러

나 외부 피드백이 지적인 대로 이 순서는 한계 ④(식별 문제)를 해결하지 못하고 오히려 재현한다. v0.7은 세 가지 재설계 옵션을 명시적으로 비교한 뒤 선택 근거와 함께 최종 경로를 확정한다.

v0.6 원안의 문제

v0.6 §3.7.4 Phase A의 설계는 다음과 같았다:

- 1단계: §3.5의 EM으로 $\mu_k^0(x)$ 를 추정 (시변 공변량 z 없이)
- 2단계: 그 $\mu_k^0(x)$ 를 고정한 채 $h_k(z)$ 만 log-linear 회귀로 추정

문제: 1단계에서 z 가 모델 밖에 있으면, z 의 공간 구조가 $\mu_k^0(x)$ 추정값에 흡수된다. EM은 '어느 공간에 사건이 많이 관측되는가'를 보고 배경율을 배분할 뿐, 그 공간 패턴의 *원인*이 불변 입지인지 시변 공변량인지 구별하지 못한다. 결과적으로 $\mu_k^0(x)$ 는 순수 입지가 아니라 **입지 + 누락된 공변량 효과의 혼합물**이 된다. 2단계에서 이 오염된 $\mu_k^0(x)$ 를 고정하면, $h_k(z)$ 의 계수는 z 의 공간 구조를 가진 성분이 이미 μ^0 에 빨려들어간 뒤 잔여분만 설명하게 되어 과소추정된다.

이것은 v0.6 §3.7 전체의 동기였던 'Mohler 의미의 α 과대추정 문제 해소'를 한 층 안쪽으로 옮겨서 재현하는 것에 불과하다. μ 가 너무 단순해서 α 가 과대추정되던 문제가, 이제 μ^0 가 너무 많이 흡수해서 $h(z)$ 가 과소추정되는 문제로 바뀐다.

세 재설계 옵션

옵션	전략	장점	단점·위험
A. 동시 추정	$\mu^0(x)$ 와 $h(z)$ 를 EM 틀 안에서 처음부터 함께 업데이트. E-step에서 branching assignment → M-step에서 μ^0 와 h 를 동시에 최대우도 업데이트.	식별 구조가 원리적. μ^0 와 z 의 공간 상관이 있어도 데이터가 둘을 구별할 여지를 최대한 확보. 편향 방향이 데이터에 의해 결정됨.	수렴 안정성 ·multicollinearity 위험. μ^0 와 z 가 거의 완전 공선이면 추정값이 불안정. 초기값 민감도 큼. 계산 비용 높음.
B. 순서 역전	$h(z)$ 에 대한 회귀를 먼저 추	계산 순서가 깔끔. 각 단	역방향 편향 위험 — z 로

옵션	전략	장점	단점·위험
	정해 강도의 외생 부분을 걸러낸 뒤, 잔차에 대해 $\mu^0(x)$ 를 EM으로 추정.	계가 잘 정의된 통계 문제. 공변량 데이터가 풍부할 때 효과적.	설명할 수 없는 공간 패턴까지 z 에 귀속될 수 있음. 특히 z 가 incomplete 하면 μ^0 가 체계적으로 왜곡됨. 편향 구조가 A 와 정반대 방향이지만 크기는 동등할 수 있음.
C. 도구변수 / 공간 잔차 직교화	$z(x, t)$ 를 시간 평균한 $\bar{z}(x)$ 를 먼저 구하고, $\mu^0(x) \perp \bar{z}(x)$ 직교 제약 하에서 동시 추정. 또는 z 의 공간 성분과 시간 성분을 분해해 시간 성분만 $h(z)$ 에 할당.	이론적으로 가장 깔끔. 불변 입지와 공변량을 개념적으로 완전 분리.	과잉 엔지니어링. 직교 제약이 실제 현상과 맞지 않을 수 있음 — 임대료의 시간 평균이 정말 '불변 입지'와 분리되는 개념인가? 구현 복잡도 급증. 식별 문제를 해결하는 대신 모델러의 추가 가정을 요구.

선택 기준

세 옵션 중 최종 경로를 결정하는 기준은 다음 네 가지:

- ① **원리적 타당성.** 식별 문제를 *해결*하는가, *다른 형태로 이동*시키는가. A 는 해결 방향, B 는 이동 방향, C 는 해결하되 추가 가정 대가.
- ② **데이터가 결정할 여지.** 편향의 방향과 크기가 모델러의 가정이 아니라 데이터의 정보량에 의해 결정되는 것이 바람직. A 가 가장 유리, B 는 z 의 완전성에 의존, C 는 직교 가정에 의존.
- ③ **실무적 검증 가능성.** 추정 결과가 신뢰할 만한지 *사후적으로 점검* 가능한가.
bootstrap·민감도 분석·multicollinearity 진단이 표준화되어 있는가.

- ④ **후속 확장성.** 선택된 전략이 더 복잡한 모델(예: h_k 를 GAM/GP로 비선형화)로 자연스럽게 확장되는가.

최종 결정 — 재설계 A (동시 추정)

네 기준에 대한 평가:

- ① **원리적 타당성: A가 우위.** B는 편향의 방향을 바꿀 뿐이며, 바뀐 편향이 더 작다는 보장이 없다. C는 직교 가정이라는 *새로운 가정*을 요구하며, 그 가정이 가로수길 맥락에서 성립한다고 믿을 근거가 약하다.
- ② **데이터가 결정할 여지: A가 우위.** μ^0 와 h 가 경쟁하는 구도에서 관측 데이터의 공간×시간 변동이 가중치를 결정. B·C는 모델러의 선택이 결과를 좌우한다.
- ③ **검증 가능성: 모든 옵션이 유사.** A는 EM 수렴·초기값 민감도·bootstrap이라는 표준 진단으로 점검 가능. B·C도 고유 진단이 있지만 A만큼 표준화되어 있지 않다.
- ④ **확장성: A가 명확.** 동시 추정 EM에서 h_k 를 log-linear에서 GAM/GP로 바꾸는 것은 M-step의 국소 수정만 요구. B는 h 추정 단계에서 모델 확장이 가능하지만 잔차 모델링이 따라서 바뀌어야 함.

결론: 재설계 A를 기본 경로로 채택한다. 네 기준 중 세 개에서 명확히 우위이고, 나머지 하나 (검증 가능성)에서 열세가 아니다. 다만 A의 주요 단점인 *수렴 불안정성과 multicollinearity 위험*은 경감 전략으로 대응한다:

- **Ridge/L2 regularization.** μ^0 와 h 의 계수에 약한 L2 벌칙을 부여하여 multicollinearity 상황에서 수렴을 안정화. 벌칙 강도는 cross-validation으로 선택.
- **Multiple random starts.** EM 초기값을 10~20회 무작위로 설정하여 여러 수렴점을 확보. 수렴점 분포 자체가 식별 불확실성의 진단.
- **Variance Inflation Factor (VIF) 진단.** $\mu^0(x)$ 의 셀별 추정값과 $z(x, t)$ 의 시간 평균 $\bar{z}(x)$ 의 VIF를 측정. $VIF > 10$ 이면 해당 지역에서 식별이 실패하고 있음을 경고.

Phase A의 재위치 — 진단 도구로

v0.6의 Phase A를 완전히 폐기하는 대신 **재설계 A의 robustness check**로 재위치시킨다. 구체

적으로:

- 재설계 A로 μ^0 와 h 를 동시 추정된 결과의 h 계수 = h^A
- v0.6 Phase A 순차 추정 결과의 h 계수 = h^{seq}
- 두 값의 차이 $|h^A - h^{seq}|$ 가 μ^0 와 z 의 공간 상관 강도 지표. 차이가 작으면 식별 문제가 실질적으로 심각하지 않다는 경험적 증거. 차이가 크면 재설계 A의 결과만 보고하되 식별 불확실성 구간을 넓혀 해석.

즉 원래 Phase A는 '최종 추정의 1차 경로'였지만, v0.7에서는 **재설계 A 결과의 민감도 진단 비교 지점**으로 역할이 전환된다. 완전히 버리기보다는 나은 위치짓기다.

비선형 확장과 완성형

재설계 A를 기본 경로로 한 점진적 확장:

- **Stage 1.** 재설계 A, h_k 를 log-linear 형태로. 동시 EM + L2 regularization + multiple starts. 기본 결과.
- **Stage 2.** h_k 를 GAM(Generalized Additive Model)으로 비선형 확장. 임대료-배경을 관계가 임계치 효과나 포화 효과를 보이는지 검증.
- **Stage 3.** h_k 를 Gaussian Process로 확장해 공변량 상호작용 항까지 학습. 완성형. 이 단계는 박사과정 본 연구에 해당.

공변량 데이터원 (v0.6과 동일).

- 평당 임대료: 소상공인시장진흥공단 상가정보, 국토부 실거래가, 상가건물 임대차 신고제 (2021~)
- 유동인구: SKT Geovision, 서울시 생활인구 데이터 (KT·통신3사 기반)
- 지하철 이용객: 서울교통공사 일별 승하차 데이터
- 주변 오피스 공실률: 쿠시먼앤드웨이크필드, CBRE, 젠스타메이트 분기 리포트
- 현재 점포 수 $N_k(x, t)$: LOCALDATA에서 내생적으로 산출 가능 — 외부 데이터 불필요

3.7.5 이 단계의 의미

- **방법론의 완결.** Hawkes의 자기여기 α 와 외생 조건 z 를 역할 분리함으로써, '*내생적 상호작용*'과 '*외생적 환경 변화*'를 구별 가능. 이것이 진정한 의미의 '메커니즘 지문'이다.
- **정책 도구로서의 승격.** 공변량 조건부 μ 는 개입 시뮬레이션의 신뢰도를 결정적으로 올린다. '임대료 안정화로 $\mu_{\{B\}}$ 이 어떻게 줄어드는가'를 수치로 답할 수 있게 된다.
- **학술적 기여의 확장.** 국내 도시연구 맥락에서 *공변량 조건부 다변량 시공간 Hawkes*는 (검색 한계 내에서) 선행 연구를 찾기 어렵다. v0.5의 Blue/Red 설계보다 한 층 더 전인미답의 영역.

3.7.6 현실적 배치

3.7은 *5단계 이후의 확장*이지 즉시 착수 대상이 아니다. 우선순위:

- 1단계(H3·버거지수) → 2단계(시간 Hawkes) → 3단계(ST-Hawkes) → 4단계(Blue/Red) → 5단계(EM $\mu(x)$)까지는 v0.5 일정대로.
- 3.7(공변량 조건부 μ)은 5단계 완료 후, 즉 M17 이후의 과제. 실질적으로는 박사과정 본 연구나 후속 프로젝트.
- 단, 1~4단계를 돌리는 과정에서 *공변량 데이터를 미리 수집·정비해두면* 3.7 착수 시 즉시 활용 가능. 데이터 파이프라인에서는 미래를 대비.

Part VI — 엔트로피: 복잡성의 해석

v1.0 신설, v1.1에서 Part V→VI로 재라벨. Part V의 Cox-Hawkes 모델이 식별 문제를 통과해 수렴한다고 해도, 그 결과를 해석하는 언어가 부족하다. 추정된 $\mu(x, t)$, α 행렬, p_{ij} 분포, hazard ratio를 앞에 두고 '이 모델이 무엇을 말하는가'를 요약할 도구가 필요하다. 엔트로피가 그 역할을 한다.

중요한 점: 엔트로피는 Part II의 '심판관'이 아니다. Part II의 관심은 '더 복잡한 모델이 필요한가'이고, Part V의 관심은 '결합 모델을 어떻게 식별 가능하게 세울 것인가'다. 엔트로피의 관심은 **복잡한 모델이 드러낸 구조와 불확실성을 어떻게 요약할 것인가**다. 따라서 엔트로피는 Cox-Hawkes 이후의 별도 파트로 두는 편이 자연스럽다.

§VI.1 엔트로피는 왜 여기서 등장하는가

Hawkes 모델의 추정 결과는 세 가지 층위의 불확실성·구조를 담는다:

- 각 사건의 부모가 누구인가 — p_{ii} , p_{ij} 분포 (3-1 단계의 출력)
- 사건 유형 간 상호작용의 집중도 — α 행렬의 분포 (Part I 3단계)
- 시장 상태의 질서·무질서 — 시기별 체제 (Part III 5-1의 시간 변화)

각 층위의 '얼마나 집중되어 있는가' 또는 '얼마나 분산되어 있는가'를 하나의 척도로 요약할 때 엔트로피가 자연스럽다. Shannon entropy $H = -\sum p_i \log p_i$ 의 네 가지 응용을 본다.

§VI.2 Branching uncertainty와 엔트로피

사건 i 의 부모 후보 확률 $\{p_{ii}, p_{i1}, p_{i2}, \dots, p_{i(i-1)}\}$ 에 대한 Shannon entropy:

$$H_i = -p_{ii} \log p_{ii} - \sum_{\{j < i\}} p_{ij} \log p_{ij}$$

- $H_i \approx 0$: 사건 i 의 부모가 거의 확정적 — '이 사건은 명백히 background' 또는 '이 사건은 명백히 사건 j 로부터 유발'.
- H_i 높음: 부모가 불확실 — 여러 과거 사건이 엇비슷한 확률로 부모 후보.

- 지역·시기별 평균 H의 공간 지도는 '모델이 이 지역에서 얼마나 자신 있게 인과 구조를 복원하는가'의 시각화.

§VI.3 Interaction structure의 집중도와 엔트로피

3단계의 α 행렬 $\alpha_{\{k \leftarrow j\}}$ 를 행별로 정규화한 분포 $\pi_k(j) = \alpha_{\{k \leftarrow j\}} / \sum_j \alpha_{\{k \leftarrow j\}}$. 이 분포의 엔트로피:

$$H(\pi_k) = -\sum_j \pi_k(j) \log \pi_k(j)$$

- H 낮음: 브랜드 k가 소수 브랜드에만 영향받음 — '종속적' 브랜드.
- H 높음: 브랜드 k가 다양한 브랜드로부터 영향받음 — '보편적' 브랜드.
- 3단계 α heatmap의 '행별 집중도'를 하나의 숫자로 요약. 12개 브랜드 각각에 H_k 하나씩.

§VI.4 Regime entropy: 시장 상태의 질서와 무질서

5-1단계의 $\mu(x, t)$ 나 $\alpha(t)$ 가 시간에 따라 체제를 바꾸는 경우. 시점 t의 상태 분포(예: HMM 은닉 상태 추론 결과)의 엔트로피가 **시장이 지금 어떤 체제에 명확히 있는가, 아니면 체제 간 전이 중인가**를 알려준다.

- $H_{\text{regime}}(t) \approx 0$: 시장이 한 체제에 안정적으로 놓여 있음.
- $H_{\text{regime}}(t)$ 높음: 체제 전이 중 — 정책 개입의 골든타임 후보 시점.
- 젠트리피케이션의 단계 전환(2기 → 3기)이 H_{regime} 의 스파이크로 나타날 것이라는 가설.

§VI.5 Background entropy: 공간적·시간적 분산도의 요약

추정된 $\mu(x)$ 의 공간 분포(격자 셀 c별 μ_c 를 정규화)의 엔트로피:

$$H(\mu) = -\sum_c (\mu_c / \sum \mu) \cdot \log(\mu_c / \sum \mu)$$

- H 낮음: 배경율이 소수 지역에 집중 — '핫스팟 기반 도시'.
- H 높음: 배경율이 고르게 분산 — '분산형 도시'.

- 서울·성수·홍대를 비교할 때 각 지역의 $H(\mu)$ 가 그 동네의 '상권 분포 성격'을 한 수치로 요약.
- 시간축으로 확장: $H(\mu(\cdot, t))$ 의 궤적이 '상권이 집중되고 있는가, 분산되고 있는가'를 추적.

§VI.6 엔트로피와 지수 구성의 연결 가능성

§6의 젠트리피케이션 진행도 지수(G1~G6)가 '현상의 크기'를 측정한다면, 엔트로피 지수는 '현상의 구조적 복잡성'을 측정한다. 두 차원이 결합된 2D 평면에서 각 지역이 위치한다:

- 크기 낮음 + 엔트로피 낮음: 안정된 소규모 상권 — 개입 불필요
- 크기 높음 + 엔트로피 낮음: 뚜렷한 핫스팟 — 기존 지수가 가장 잘 포착
- 크기 낮음 + 엔트로피 높음: 분산된 태동 상권 — 조기 감시 대상
- 크기 높음 + 엔트로피 높음: 체제 전이 중 — 긴급 개입 시점

이 2차원 분류가 본 연구의 정책적 기여에 **해석 언어**를 더한다. 단순히 '성수동의 진행도가 높다'가 아니라 '성수동은 크기는 중간인데 엔트로피가 높아 체제 전이 중일 가능성이 크다'라는 구조적 진술이 가능해짐.

Part VI의 의미: 복잡한 모델이 만들어낸 추정치들을 한 번 더 요약해 독자에게 이해 가능한 그림으로 돌려주는 언어. 이것이 없으면 Part V까지의 수학적 공력이 정책·학술 대화에서 전달되지 않는다.

Part VII — 뒷부분

v1.1 재라벨. Part VII은 v0.9까지의 §4(방법론 심화), §5(데이터와 실행 가능성), §6(젠트리피케이션 지수), §7(한계), §8(참고문헌)을 담는다. 내용은 그대로 보존되며, 책 구조에서는 outline의 마지막 챕터들(방법론 메모·데이터 메모·한계 자기비판·결론)에 대응한다.

Part VII 구성과 outline 매핑:

- §4 방법론 심화 → '방법론 메모' (Part II의 4대 심판관이 방법론적으로 어떻게 작동하는지의 실행 세부, Part IV 생존분석의 partial likelihood, Part V Cox-Hawkes의 추정 알고리즘)
- §5 데이터와 실행 가능성 (§5.5 LOCALDATA 파이프라인 포함) → '데이터와 구현 메모'
- §6 젠트리피케이션 지수 (G1~G6, 시뮬레이션 거울) → 책에서는 Part VI 엔트로피 뒤의 응용 장
- §7 한계와 열린 문제 → '한계와 자기비판'
- §8 참고문헌 → 책의 뒷부분 참고문헌 섹션

이하 본문은 v0.9의 §4~§8을 그대로 유지한다. 책 출판 시 outline 번호로 재라벨링 예정.

4. 방법론 심화

4.1 MLE의 실제: 3단계까지 공통 프레임

시공간 Hawkes의 로그우도 (사건 집합 $\{(t_i, x_i)\}$, 관측 영역 $[0, T] \times S$):

$$\ell(\theta) = \sum_i \log \lambda(t_i, x_i; \theta) - \int_0^T \int_S \lambda(s, y; \theta) dy ds$$

수치적 쟁점

- 1) 적분항의 엣지 효과. 관측 영역 밖의 사건이 영역 안 강도에 기여하는 부분이 누락되어 모수에 편향을 준다. 보정: (a) 버퍼 영역 기법, (b) 명시적 edge correction factor, (c) 단순히 관측영역 내부로 제한하고 편향은 민감도 분석.
- 2) $O(N^2)$ 비용. $N=10^4$ 이상일 때 매 반복마다 N^2 쌍 계산. 해결: (a) k-최근접이웃 절단(커널이 ϵ 보다 작아지면 무시), (b) KD-tree 기반 공간 인덱싱.
- 3) 프로파일 우도. β 처럼 수렴이 느린 모수는 profile likelihood로 먼저 고정 격자 탐색 후 내부 모수 MLE.

4.2 EM의 실제: 5단계

Branching interpretation이 핵심이다. 각 사건 i 에 대해, 누가 '부모'인가는 알 수 없지만(latent), 관측된 사건들이 주어졌을 때 부모 후보들에 대한 사후분포는 계산할 수 있다. E-step이 그것이다.

의사코드

initialize $\mu(x)$ as KDE of all points, $\alpha = 0.3$, β fixed from stage-3 MLE

repeat:

E-step: for each i , $j \leq i$, compute p_{ij} (parent probability)

M-step:

$\alpha \leftarrow \sum_{i \neq j} p_{ij} / (N \cdot \text{integral of } g \cdot f)$

$\mu(x) \leftarrow \sum_i p_{ii} \cdot K_\sigma(x - x_i) / T$

until log-likelihood change $< \epsilon$

4.3 모형 선택과 검증

- AIC, BIC — 단계 간 모델 비교
- Ogata의 잔차분석 — 적합된 Hawkes 과정을 시간 재척도화하면 단위율 Poisson 과정이 되어야 한다. QQ 플롯과 Kolmogorov-Smirnov로 검증.
- 시뮬레이션 기반 posterior predictive check — 적합된 모수로 합성 데이터 생성, 실제 데이터의 요약통계와 비교.
- 홀드아웃: 시간 축 기준 마지막 20%를 테스트셋으로, 예측 우도 비교.

4.4 Identifiability — 가장 큰 위험

μ 와 α 는 근본적으로 경쟁하는 설명이다. '사건이 많은 이유'는 배경율이 높거나(μ 큼) 연쇄가 강하거나(α 큼) 둘 중 하나다. 데이터만 보고 이 둘을 분리하는 것은 쉽지 않다. 5단계에서 μ 를 공간 함수로 푸는 순간, 이 문제는 더 심해진다.

대응:

- EM의 초기값 민감도를 반드시 보고한다.
- 합성 데이터 실험: 알려진 $\mu(x)$, α 로 Hawkes를 생성 → EM으로 복원 시도 → 얼마나 정확히 복원되는지 정량화.
- bootstrap을 통한 모수 불확실성 구간 제시.

4.5 기존 젠트리피케이션 연구와의 비교

v0.2 신설. 3.6절의 2x2 이벤트 방법론이 기존 방법론과 무엇이 어떻게 다른지, 그리고 어떤 한계를 공유하고 어떤 한계를 새로 만드는지 가감 없이 점검한다.

4.5.1 국내 선행 연구 지형

국내 상업 젠트리피케이션 연구는 2010년대 중반 이후 빠르게 축적되었으며, 크게 네 갈래로 분류할 수 있다.

6. **단계 기술 연구.** 허자연·정연주·정창무(2015)의 경리단길 3단계 모형, 이인성·배재흠(2013)의 가로수길 건축물 용도변화 분석이 대표적. 필드워크·인터뷰·문헌

분석으로 '1기→2기→3기' 서술. 풍부한 맥락을 주지만 *단계의 경계가 연구자의 해석*이며 다른 지역에 이식하기 어렵다.

7. **지수 개발 연구.** 이진희 외(2018), 상업 젠트리피케이션 지수 후속 연구들. 블록 단위로 공실률, 업종 다양성, 임대료 변동 등을 합성 지수화. 행정적 의사결정에 직접 쓸 수 있다는 장점. 한계: *지수가 정적*이며 사건 간 인과적 구조를 담지 않는다.
8. **임대료 영향요인 회귀 연구.** 경리단길 임대료의 영향요인 분석류. 지가, 지하철 거리, 식음시설 비율 등 공변량과 임대료의 선형관계. 계량경제학적으로 엄밀하지만 *'사건이 사건을 부른다'*는 동학을 원천적으로 담을 수 없는 모형.
9. **공간통계 연구.** Moran's I, LISA, 공간군집 분석을 통한 '젠트리피케이션 의심 지역' 탐지. 공간 자기상관을 포착하지만 *시간적 인과 방향을 구별하지 못함*. A가 B를 불렀는지, B가 A를 불렀는지, 둘 다 제3의 원인에서 왔는지 분간 불능.

4.5.2 방법론 비교표

본 연구(3.6절)를 포함한 비교:

방법론	시간 동학	공간 동학	행위자 구별	사건 상호작용	단계 전이 식별	개입 시물
단계 기술 (허자연 등)	서술적	△	○	×	질적	×
지수 개발 (이진희 등)	△	△(블록)	×	×	△	×
임대료 회귀/DID	○	△	△	×	×	○ (처치효과)
Moran's I / LISA	×	○	×	△	×	×
해외 ST-Hawkes (Mohler 범죄, Meyer 질병)	◎	◎	△	◎	△	◎

방법론	시간 동학	공간 동학	행위자 구별	사건 상호작용	단계 전이 식별	개입 시물
본 연구 (3.6 Blue/Red 2×2)	◎	◎(네트워크)	◎(2 class)	◎(4×4)	◎(rollin g)	◎(α 조작)

범례: ◎ 핵심 강점 ○ 가능 △ 제한적 × 원천적으로 불가

4.5.3 본 방법론의 차별적 기여

위 표에서 드러나는 기여를 세 축으로 정리한다.

① '메커니즘 지문'으로서의 16개 계수 행렬.

기존 연구는 젠트리피케이션의 *결과*(임대료 상승, 공실률 증가, 주민 이탈)를 지표로 삼는다. 본 연구는 *과정*을 16개 상호작용 계수의 배열로 표현한다. 결과 지표는 '이 동네가 아프다'만 말해주지만, 계수 배열은 '어떤 기전으로 아픈가'를 말해준다. 이것이 회귀·LISA·지수 연구들이 원천적으로 제공할 수 없는 해상도다.

② 축출의 '방향성'을 처음으로 직접 정량화.

$\alpha(B^* \leftarrow R^*) > \alpha(R^* \leftarrow B^*)$ 라는 비대칭성은 *Red가 Blue를 밀어내는 강도가 그 역보다 크다*는 것을 의미한다. 기존 국내 연구에서는 인터뷰·기술통계로만 주장되어온 축출의 방향성이, 처음으로 비교 가능한 수치가 된다. 정책적으로 가장 중요한 계수. 허자연 등(2015)이 질적으로 밝혀낸 '지대격차에 의한 구축'을 본 연구는 $\alpha(R^* \leftarrow B^*)$ 의 값으로 직접 측정한다.

③ $\alpha(t)$ 궤적을 통한 단계 전이 조기 탐지.

단계 기술 연구는 *사후적*으로 '1기였다, 2기였다'를 말한다. 지수 연구는 특정 시점의 *상태*를 본다. 본 연구는 계수의 *궤적*을 본다. $\alpha(R^* \leftarrow B^*)$ 이 상승하기 시작하는 시점은, 아직 임대료가 오르거나 공실이 늘기 전의 **선행 지표**가 된다. 이것이 개입의 골든타임을 식별하는 기술적 근거다.

4.5.4 해외 Hawkes 도시연구와의 관계

Hawkes 과정을 도시 현상에 적용한 선행 연구는 풍부하다. Mohler et al.(2011, 2014)의 범죄,

Meyer et al.(2014)의 질병 확산, Stomakhin et al.(2011)의 시위·갈등 모델 등. 그러나 **젠트리피케이션에 본격적으로 적용된 사례는 드물다**. 또한 기존 ST-Hawkes 도시연구는 대부분 단일 유형 사건(범죄, 감염) 또는 소수 유형에 한정된다. 본 연구의 4-변량 설계(B^+ , B^- , R^+ , R^-)는 다변량 Hawkes의 도시 응용을 *행위자의 계급 구분으로 의미화*하는 시도로, 방법론적으로도 약간의 신 구성을 갖는다.

4.5.5 방법론의 한계 — 솔직한 점검

이 방법론이 만들어내는 새로운 한계를 숨기지 않는다. 감추면 나중에 발목을 잡힌다.

한계 1 — Blue/Red 분류 기준의 자의성.

'어디까지가 Blue이고 어디부터 Red인가'는 이 연구 전체의 결과를 좌우한다. 가맹점 10호 미만은 Blue? 연매출 기준? 본사 지분 구조? 명확한 정답이 없다. **대응:** (a) 복수의 분류 기준(보수적·중간·관대)으로 동시에 추정해 민감도 분석, (b) 경계 사례(예: 스페셜티 커피 소규모 체인)는 별도 카테고리로 빼서 영향 격리, (c) 분류 기준 자체를 *부록으로 공개*해 재현성·반증가능성을 확보.

한계 2 — 입·폐점 시점 데이터의 체계적 편향.

입·폐점 시점을 직접 기록한 데이터는 존재하지 않는다. 그러나 **지방행정 인허가 데이터 (LOCALDATA, localdata.go.kr)**가 가장 가까운 proxy다. 행안부가 전국 자치단체의 서울행정시스템에서 매일 자동 수집하는 데이터로, *인허가일자*, *영업상태(영업/폐업/휴업)*, *폐업일자*, *사업장명*, *소재지주소*, *관리번호*, *TM 좌표*를 포함한다. 2026년 1월 공공데이터포털과 통합되어 일원화되었으며, 일반음식점·휴게음식점·제과점 등 본 연구 대상 업종이 모두 포함된다.

알려진 편향 두 방향. (i) *인허가일* → *실제 개점*: 공사·내부 인테리어 단계에서 인허가를 먼저 받는 경우가 많아 실제 개점보다 며칠에서 수 주 앞선다. (ii) *폐업신고일* → *실제 폐점*: 폐업신고는 법적 의무지만 실제로는 몇 개월씩 방치되는 경우가 흔하며, 특히 자진 폐업의 경우 지연이 크다. 즉 B^-R^- 사건은 **우측으로 치우친 timestamp**를 갖는다.

대응: (a) 편향의 방향이 *알려져 있으므로* 모델에 명시적 offset 분포로 흡수 가능 — 개점 시점

t_i 를 인허가일자에서 표준적인 '공사→개점' 지연분포(예: exponential with mean 30일)를 빼서 보정, (b) Red 대형 프랜차이즈는 기업 공식 개점일(IR, 보도자료, 공식 매장 페이지)과 크로스체크해 LOCALDATA의 지연 분포를 *실증 추정* 후 Blue에도 동일 분포 적용, (c) 폐업 방치 문제는 카드 매출 데이터(나이스지니·SKT 지오비전)에서 관측되는 매출 급감 시점과 대조해 실제 폐점일 근사, (d) 최종 결과는 항상 *원본 인허가일 기준* 과 *보정 후 기준* 두 가지로 제시해 편향 민감도를 투명하게 공개.

추가 주의점. 한 업소가 업종별로 별개 관리번호를 가질 수 있다(예: 일반음식점 + 담배소매업). 동일 사업장명·주소로 dedup 필요. 또한 업종 변경(예: 카페 → 분식집)은 폐업+신규 인허가로 기록되므로, Blue/Red 분류 기준에 따라 한 쌍이 (B^- , B^+) 또는 (B^- , R^+) 이벤트로 해석된다 — 이것은 *오류가 아니라 실제 신호*로 다룬다.

한계 3 — Rolling window 크기 선택의 민감도.

창 크기 Δ 가 결과를 좌우한다. 너무 작으면 잡음, 너무 크면 체제 변화가 평활된다. **대응:** 3.6.4절에서 다룬 다중 대역폭 앙상블. 여러 Δ 에서 일관된 신호만 결론으로 삼는다. 단일 Δ 로 나온 결과는 절대 단독 결론으로 발표하지 않는다.

한계 4 — 인과가 아닌 시간적 선행.

Hawkes의 α 계수는 '*A 이후에 B가 더 많다*'를 측정할 뿐 '*A가 B를 야기했다*'를 증명하지 않는다. 제3의 교란요인(지하철 개통, 미디어 노출 급증)이 A와 B를 동시에 끌어올렸을 가능성을 Hawkes는 원천적으로 배제하지 못한다. **대응:** (a) 주요 교란사건(지하철 개통, 드라마·예능 배경지 지정 등)을 외생 공변량으로 강도함수에 포함, (b) 자연실험적 상황(예: 임대차보호법 개정 전후)에서 DID와 교차검증, (c) 결론에서 *인과 언어를 쓰지 않는다* — '유발한다' 대신 '뒤따르는 경향이 있다'.

한계 5 — '지역 특색'의 조작적 정의 문제.

Blue를 '지역 특색을 만드는 주체'로 정의하는 순간, 우리는 *특색이 무엇인지*를 암묵적으로 정의한 것이다. 이는 정치적 판단이며, 완전히 가치중립적일 수 없다. 예를 들어 '오래된 분식집'은

Blue인가? 규모로 보면 Blue지만, 새로 등장한 '지역 특색'이 아닐 수도 있다. **대응:** 이 연구의 Blue/Red는 *자본 규모와 의사결정 구조*의 이분법이며, *문화적 가치*의 이분법이 아님을 명시한다. 전자는 비교적 객관적으로 정의 가능하고, 후자는 별도의 질적 연구가 필요하다.

한계 6 — 정책 사용시의 오용 위험.

' $\alpha(R^* \leftarrow B^*)$ '이 높은 지역에 Red 입점을 제한하자'로 직결되면 *영업의 자유 침해, 역차별, 또는 특정 자본의 정치/화* 논란이 발생한다. 본 연구의 계수는 **현상을 이해하는 도구이지 규제의 근거가 아니다**. 정책 입안 시에는 별도의 규범적 논의, 법적 검토, 이해관계자 협의가 필수. 이 경계를 6절(정책적 함의)에서 엄격히 유지한다.

한계 7 — 배경을 μ 의 구조적 한계 (v0.6 추가, v0.7 보강).

이 한계는 모델의 기초를 건드리는 본질적 비판이다. 네 층위로 나뉜다: (i) 이벤트 유형 k 별로 독립 추정되는 $\mu_k(x)$ 는 폐점 이벤트의 경우 *공간이 아니라 기존 점포* 수의 함수여야 자연스럽다. (ii) μ 가 시간에 대해 상수라 4기 공동화 같은 *배경을 자체의 감소*를 모델이 설명하지 못하고 모두 α 에 떠넘긴다. (iii) $\mu(x, t)$ 로 확장해도 *왜 바뀌는지*는 모델 밖에 있어서 인과적 해석이 불완전. **(iv) v0.7 추가:** 공변량 조건부 $\mu_k(x, t) = \mu_k^0(x) \cdot h_k(z(x, t))$ 로 확장해도 **식별 문제**가 남는다. 불변 입지 $\mu^0(x)$ 와 시변 공변량 $z(x, t)$ 가 공간적으로 강하게 상관되기 때문이다 — 임대료와 유동인구는 지하철 접근성과 상권 중심지와 거리 따라 공간적으로 구조화되어 $\mu^0(x)$ 와 사실상 구별이 어렵다. **대응:** §3.7(단계 6 제안)에서 공변량 조건부 μ 확장을 후속 과제로 명시하고, §3.7.4에서 식별 문제에 대응한 재설계 옵션 세 가지(동시 추정·순서 역전·직교화)를 비교한 뒤 재설계 A(동시 추정 + L2 + multiple starts)를 기본 경로로 확정. 현재 v0.6까지의 결과는 이 한계들 아래서 **잠정적임**을 모든 발표에 명기한다. 특히 Mohler(2014)의 지적대로 μ 의 단순화가 α 를 과대추정할 위험은 5단계 EM으로 공간 편향은 완화되지만 시간 편향은 남으며, v0.7의 식별 문제 대응으로 공변량 확장의 편향도 원리적으로 통제한다.

한계 8 — Hazard ratio의 정책적 오용 위험 (v1.3 추가).

문제 진단.

Part IV §IV.4 Cox 회귀의 핵심 결과인 hazard ratio는 정책 대화에서 인과 관계로 오해될 위험이 크다. "임대료 1만원 상승이 폐업 위험을 20% 올린다"는 진술은 직관적이고 인용하기 쉽지만, **hazard ratio는 인과가 아니라 조건부 연관**이다.

근거.

- **교란 변수 위험.** 임대료가 높은 지역은 다른 특성도 다름 — 상권 경쟁 강도, 임차인 구성, 유동인구 등. hazard ratio 0.20이 임대료 자체의 효과인지 동반 변수의 효과인지 구별 불가능.
- **관측 vs 개입의 괴리.** 임대료가 "자연적으로 변한 시점"의 hazard 변화와 "정책으로 임대료를 낮춘 시점"의 hazard 변화는 다를 수 있음. 관측 자료의 hazard ratio를 정책 효과 예측에 직접 쓸 수 없음.
- **선택 편향.** 높은 임대료를 견딘 점포는 견딜 능력이 있는 점포만 남았을 수 있음(survivorship bias). 임대료 인하의 효과를 hazard ratio로 환산하면 편향됨.
- **정책 인용의 위험성.** "임대료 1만원 = 폐업 위험 20% 증가"라는 표현은 정책 보고서에서 정책 효과의 정량 근거로 사용될 가능성이 큼. 그러나 이는 인과적 정책 효과가 아닌 관측된 연관일 뿐.

대안 — 한계의 명시와 인과 추론 도구의 명시.

- **(a) 발표 시 표준 단서 명시.** "hazard ratio는 인과 효과가 아닌 조건부 연관이며, 정책 효과 예측에는 인과 식별 전략(자연실험, IV, DID)이 필요"라는 단서를 모든 hazard ratio 인용에 부착.
- **(b) 정책 문맥 분리.** hazard ratio는 "진단" 도구로 ("이 지역에 특정 위험요인이 강하게 연관되어 있다"), 정책 효과 예측은 별도 인과 분석으로 분리. §4.5.6의 "본 연구는 DID-자연실험을 대체하지 않는다"와 일관.
- **(c) 도구의 적정 활용.** hazard ratio는 "어떤 위험요인이 폐업과 강하게 연관되는가"라는 우선순위 결정에 유용. 정책 자원 배분의 1차 진단 도구로 사용. 효과 크기 예측은 별도 작업.

채택 — (a) + (b) + (c) 모두.

- (a)는 학술적 정직성의 최소 요건.
- (b)는 §4.5.6의 기존 입장과 일관 — "본 연구는 인과 식별 전략을 대체하지 않는다".
- (c)는 hazard ratio가 여전히 가치 있는 도구임을 인정 — 진단 도구로 한정 활용.

실무 결과: §IV.4 Cox 본문에 "hazard ratio 해석의 인과적 한계" 단서 절 추가. 모든 hazard ratio 발표에서 "진단용 연관 통계량"임을 명시. 정책 시뮬레이션에는 §IV.4 결과를 직접 쓰지 않고, §3.6.8의 시뮬레이션 거울 또는 별도 인과 분석으로 환원.

4.5.6 '본 연구는 무엇을 대체하지 않는가'

이 방법론은 기존 연구들을 *대체하지 않으며 대체할 수 없다*. 구체적으로:

- 질적 연구(인터뷰, 참여관찰)를 대체하지 않는다 — 원주민의 경험은 데이터에 없다.
- 임대료 분석을 대체하지 않는다 — 임대료는 본 모형의 결과 변수가 아니라 외생 공변량으로 들어갈 것.
- DID·자연실험을 대체하지 않는다 — 정책효과 평가에는 여전히 인과 식별 전략이 필요.
- 기존 지수 연구를 대체하지 않는다 — 본 연구의 α 행렬은 '기전 지문'이고, 기존 지수는 '현재 증상'. 둘은 상보적.

본 연구의 위치는 *기존 도구들이 접근하지 못하는 동학적·상호작용적 구조를 드러내는 보완적 렌즈*다. 혼자 서지 않으며, 혼자 서려 하지 않는다.

5. 데이터와 실행 가능성

이 절과 다음 절은 힘을 싣기로 한 두 축 중 하나. 데이터가 실제로 확보 가능한지, 실행 순서가 현실적인지를 가감 없이 점검한다.

5.1 단계별 데이터 요구 및 확보 방안

단계	필요 데이터	출처	난이도 / 리스크
1	스타벅스 매장 좌표 (현재 시점)	스타벅스 매장찾기 API, 공공데이터포털 소상공인 상가정보	낮음 — 공개, 지오코딩만 필요
2	자치구·생활권 단위 아파트 거래 (시계열, 방향 라벨)	국토교통부 실거래가 공개 시스템, MOLIT API. 같은 단지·평형의 직전 거래 대비 상승/하락 분류	낮음 — 2006년부터 전수, API 제공. 상승/하락 라벨링은 단순 전처리
3	m개 브랜드·업종 입점 시점·좌표 (LOCALDATA 전체)	LOCALDATA 휴게·일반음식점·제과점·즉석판매 등 전체분, 상호 사전으로 12~30개 브랜드 추출, 기업 공식 IR·보도자료로 Red 크로스체크	중간 — 인허가일 ≠ 실제 개점. 지연분포(평균 30일 정도)로 보정. §5.5 참조
4	가로수길 Blue/Red × 입·폐점 4유형 사건 이력 + 도로 네트워크	LOCALDATA 신사동 관련 업종 일변동분 장기축적, 카드 매출 데이터(나이스지니·지오비전)로 실제 폐점일 보조, OSM 도로망	중간 → 낮음 — LOCALDATA 통합 이후 접근성 개선. 폐업신고 지연이 주된 잔여 과제
5	1단계 데이터 + 입지 공변량(인구, 지하철)	통계청 SGIS, 서울 열린데이터광장, 국가교통DB	중간 — 공변량 자체는 공개. 시점 정합성이 과제

5.2 핵심 리스크와 완화

리스크 1 — 입·폐점 시점의 체계적 편향 (부재가 아닌 편향).

v0.1에서는 '입점 시점 데이터의 부재'로 기술했으나, **지방행정 인허가 데이터(LOCALDATA)**를 활용하면 문제의 성격이 *부재*에서 *알려진 편향의 보정*으로 바뀐다. LOCALDATA는 인허가일자·영업상태·폐업일자·좌표를 모든 업소 단위로 제공하므로, 입·폐점을 전수 이벤트로 추출할 수 있다. 남는 문제는 두 가지 편향: (i) 인허가일은 실제 개점보다 수 주 앞서고, (ii) 폐업신고는 실제 폐점보다 수 개월 늦는다. 완화 방안은 §5.5에 구체적으로 정리.

리스크 2 — '사건'의 정의.

젠트리피케이션 분석에서 '사건'은 입점인가, 폐점인가, 임대료 상승인가? 단일 사건 유형으로는 현상을 포착하기 어렵다. 완화: 4단계를 다변량(multivariate) Hawkes로 설계하여 '신규 입점', '폐점', '업종 고급화 전환'을 별개 유형으로 다룬다.

리스크 3 — 계산 비용.

5단계 EM은 N^2 반복 수. 서울 전체 스타벅스(~600개)는 가능. 전국 수만 건의 사건은 어렵다. 완화: (a) 지역별로 잘라서 병렬, (b) 절단 커널, (c) GPU 가속 우선순위 낮음 — CPU로 충분할 규모부터 시작.

리스크 4 — 학습 곡선.

기억해둘 것: EM은 이번이 첫 구현이다. 개념적으로는 이해했어도 실제로 수렴 안 되거나, 수렴해도 엉뚱한 지점으로 가는 경우가 흔하다. 완화: 합성 데이터로 먼저 '정답을 아는 상황'에서 구현 검증 → 그 다음 실제 데이터. 이 순서를 절대 건너뛰지 않는다.

5.3 도구 스택

- 언어: Python (numpy, scipy, statsmodels, geopandas, networkx, osmnx)
- Hawkes 참고 라이브러리: tick, hawkeslib — 참고용. 5단계는 자체 구현.
- 시각화: matplotlib, folium(지도), seaborn
- 버전 관리: git + GitHub private repo. 데이터는 DVC 또는 별도 스토리지.
- 재현성: 각 단계별 notebook + 산출물 동결. 난수 시드 고정.

5.4 시간 계획 (잠정)

기간	단계	세부 목표 / 중단 조건
M1-M3	1단계 H3 + 버거지수	LOCALDATA 파이프라인 구축(\$5.5) → H3 r9 격자 생성 → 버거지수 재구성 → Poisson 검정 → 시계열 슬라이더 UI. 중단 조건: 최소 4개 브랜드에 대해 CSR 기각 + 시계열 애니메이션 동작. v0.4에서 독립 산출물로 격상되어 기간 2→3개월로 확장.
M3-M6	2단계 지역간 부동산 전파	MOLIT 실거래가 수집·지역별 상승/하락 라벨링 → 다변량 시간 Hawkes MLE 구현·합성 데이터 검증 (복원 오차 <10%) → 자치구 수준 α 행렬 추정 → 선행/후행 네트워크 그래프 산출. 독립 결과물로 완결. v0.8에서 단일 단지 분석에서 지역간 설계로 격상되어 2→3개월로 확장.
M6-M9	3단계 상업 상권 α heatmap	다변량 시공간 확장, 12~30개 브랜드 대상, 커널 선택(지수 vs 거듭제곱). 최종 산출물: α 행렬 heatmap + 앵커 중력권 시각화 + 시기별 비교 (킬러 페이지). 지역별 heatmap 3장(서울전체·강남·성수) 병렬 제시.
M9-M13	4단계 Network ST-Hawkes (Blue/Red 2×2)	가로수길 T1 데이터 정제 → 표본 크기 진단 → 통합 4변량 또는 §3.6.6 시기별 2변량 분해 선택 → 네트워크 커널 구현 → rolling window $\alpha(t)$ 추정. 필요 시 T2/T3로 공간 확장 (§3.6.7). 여기서 정책적 서사가 완성.
M13-M16	5단계 EM $\mu(x)$	합성 데이터 검증 → 스타벅스 재분석. 자생형/연쇄형 분해.
M16-M18	통합·지수 구성	젠트리피케이션 지수 v0.1 제안·가로수길 시범 적용.

각 단계가 그 다음 단계의 입력이 되므로, 선행 단계의 중단조건을 만족하기 전에는 다음 단계로 넘어가지 않는다. 엄격히.

5.5 LOCALDATA 활용 세부 설계

v0.3 신설. 앞선 표와 리스크 논의에서 지방행정 인허가 데이터(LOCALDATA)가 이 연구의 실행 가능성을 크게 끌어올리는 핵심 데이터원으로 확인되었다. 이 절은 그 활용 절차를 구체화한다.

5.5.1 데이터원 개요

LOCALDATA(localdata.go.kr)는 행정안전부가 전국 자치단체의 서울행정시스템에서 매일 자동 수집해 공개하는 인허가 정보 포털이다. 2026년 1월 공공데이터포털과 통합되었으며, 인허가 정보 195종과 생활편의 정보 14종을 제공한다. 다운로드 형식은 전체분(스냅샷)·월 변동분·일 변동분 세 가지이며, API도 제공된다.

본 연구에 직접 관련된 업종 (카테고리: 식품·음식점):

- 일반음식점 — 한식·중식·일식 등, 음주 허용 (가로수길 대부분의 식당)
- 휴게음식점 — 카페·분식·아이스크림 등, 음주 불허 (Blue 독립카페·Red 체인카페 양쪽)
- 제과점영업 — 베이커리
- 즉석판매제조가공업 — 소규모 식품 제조·판매

위 네 업종만으로 본 연구의 주요 이벤트(카페·식당의 입·폐점)가 전수 포착된다. 전국 휴게음식점만 약 20만 개소 규모(2025년 기준).

5.5.2 제공 필드와 활용

필드	내용	본 연구에서의 활용
관리번호	자치단체 고유 인허가번호 (사업자번호와 다름)	이벤트 unique key. 업종별로 별개일 수 있어 dedup 대상
인허가일자	인허가 취득일	B⁺ / R⁺ 이벤트의 1차 timestamp (보정 필요)
영업상태구분코드 / 명칭	영업/폐업/휴업/등록취소 등	폐업 이벤트 여부 판별
폐업일자 / 휴업시작·종료일자	영업상태 전환 일자	B⁻ / R⁻ 이벤트의 1차 timestamp (지연 크므로 보조

필드	내용	본 연구에서의 활용
		데이터로 교정)
사업장명 / 소재지전체주소	업소명·도로명주소·지번주소	Blue/Red 분류의 1차 근거 (상호 기반 매칭)
좌표정보 (X, Y)	TM 중부원점 좌표계 (EPSG:5174 또는 2097)	공간 Hawkes의 x_i . WGS84로 변환 필수
업태구분명 / 업종세분류	카페·한식·중식·커피숍 등	업종 필터링 (카페만 추출 등)

5.5.3 Blue/Red 분류 파이프라인

LOCALDATA 자체에는 '프랜차이즈 여부' 필드가 없다. 따라서 Blue/Red는 **사업장명(상호)**에서 파생해야 한다. 3단계 매칭 절차:

- ① **Red 상호 사전 구축.** 주요 프랜차이즈 본사의 공식 매장 리스트(스타벅스·투썸·이디야·빽다방·메가커피·컴포즈·파리바게뜨·뚜레쥬르·맥도날드·버거킹 등 50~80개 브랜드)를 웹에서 수집. 각 브랜드의 상호 변형(예: '스타벅스 신사점', '스타벅스신사점', 'STARBUCKS 신사')을 정규화해 사전화.
- ② **LOCALDATA 상호 ↔ Red 사전 매칭.** 정확 일치 → fuzzy 매칭(Levenshtein, token sort ratio) 순. 임계치(예: ratio $\geq$ 85) 이상이면 Red로 분류. 임계치 미만은 Blue로 기본 분류.
- ③ **경계 사례의 수동 검수.** 소규모 체인(스페셜티 커피 3~5호점 등)은 '경계 카테고리'로 분리 → 민감도 분석용. 지역 장인·오너셰프 업소는 기본 Blue이나 '프리미엄 Blue'로 별도 태깅 가능.
- ④ **분류 기준의 공개.** 브랜드 사전과 매칭 로그를 저장소에 함께 공개. *같은 데이터로 다른 분류 기준을 적용했을 때 결과가 얼마나 바뀌는지* 독립적으로 검증 가능하게 한다.

5.5.4 Timestamp 보정 절차

B·R* (입점) 보정. 인허가일을 실제 개점일로 보정하는 두 단계 전략:

- **(a) Red로 지연분포 학습.** Red는 기업 공식 보도자료·매장 페이지에서 실제 개점일 확보 가능. $\Delta_{open} = (\text{인허가일} - \text{실제개점일})$ 분포를 Red 표본으로 추정. 예상 분포: 평균 약 -20일 내외의 음수(인허가가 선행), 꼬리가 긴 분포.
- **(b) Blue에 분포 이식.** Blue의 실제 개점일은 관측 불가. 단, Red에서 추정한 Δ_{open} 분포를 Blue에도 동일하게 가정하고 인허가일 + Δ_{open} 으로 보정. 이 가정이 핵심 약점이지만, 보정하지 않을 때의 편향보다 명백히 작다.


B·R⁻ (폐점) 보정. 폐업신고 지연이 더 큰 문제. 두 접근:


- **(a) 카드매출 급감 시점과 대조.** 나이스지니데이터·SKT 지오비전 상권분석에서 매출이 관측 가능한 경우, 매출이 영구적으로 급감한 월 = 실제 폐점월. 이 시점과 LOCALDATA 폐업일자 차이 Δ_{close} 분포 추정 후 B·R⁻ 이벤트 timestamp 교정.
- **(b) 대체 입점 휴리스틱.** 같은 주소에 새 업소의 B⁺ 또는 R⁺가 등록되는 시점은 *이전 업소의 실제 폐점이 이미 지난 뒤*다. 이를 폐점 상한으로 써서 폐업신고일과 대체입점일 사이 중간값을 근사 폐점일로 사용.

5.5.5 업종 전환과 중복 처리

- 한 업소가 복수 업종(일반음식점 + 담배소매업 등)으로 등록된 경우 관리번호가 각각 다름. 사업장명+주소+인허가일 triple로 dedup.
- 같은 주소에서 폐업 → 신규 인허가가 발생하는 경우: 이것은 **오류가 아니라 이벤트 쌍**이다. Blue/Red 분류에 따라 (B⁻, B⁺), (B⁻, R⁺), (R⁻, B⁺), (R⁻, R⁺) 네 가지 전환 패턴 중 하나가 되며, 이 중 (B⁻ → R⁺) *전환의 빈도* 자체가 Red의 Blue 축출을 정량화하는 핵심 지표.
- 상호 변경만 이루어지고 관리번호가 같은 경우(업주 교체 가능성)는 별개 이벤트로 보지 않음. 관리번호 연속성이 판정 기준.

5.5.6 데이터 파이프라인 개념도





5.5.7 이 데이터원 발견이 로드맵에 미치는 영향

- **4단계 난이도 하향.** v0.1 표에서 '높음 — 사건 정의 자체가 연구과제'였던 4단계가 *중간* → *낮음*으로 재평가된다. '사건 정의'는 LOCALDATA 필드 해석과 보정 절차의 문제로 환원된다.
- **3단계가 동시에 강화.** 스타벅스·타 프랜차이즈 입점 시점도 LOCALDATA에서 같은 파이프라인으로 추출되므로, 3단계의 α 행렬 추정이 더 정밀해진다.
- **전국 확장 가능성.** LOCALDATA는 전국 단위이므로 가로수길로 검증된 방법론을 홍대·연남동·익선동·성수동·경리단길·전포동·해방촌 등 다수 지역에 *동일 파이프라인*으로 적용 가능. 지역 간 $\alpha(t)$ 궤적 비교가 현실적 과제가 된다.
- **시계열 깊이.** 과거 폐업 기록도 포함되므로 2010년대 가로수길 전체 궤적을 사후 재구성 가능. Rolling window 추정의 기본 재료.

정리하면, LOCALDATA의 발견은 이 로드맵에서 4단계의 실행 가능성을 결정적으로 개선하고, 방법론적 잔여 과제를 '사건 정의의 부재'에서 '알려진 편향의 보정'으로 옮긴다. 이는 로드맵 v0.1→v0.2→v0.3 개정 과정에서 가장 큰 실질적 진전이다.

6. 젠트리피케이션 진행도 지수 — 정책적 함의

이 연구의 학술적 여정이 향하는 실천적 목적지.

6.1 왜 '지수'인가

정책 결정자에게 '이 동네의 α 행렬이 비대칭이고 n^* 가 0.78이다'는 의미가 없다. 그들은 *이 동네는 몇 단계이고, 얼마나 시간이 남았는가*를 알고 싶다. 연구의 기술적 산출물을 **비전문가가 읽을 수 있는 하나의 수치**로 압축해야 한다.

6.2 지수 구성 (초안)

다섯 구성요소의 가중합을 제안한다. 각 요소는 0-100으로 정규화.

요소	모형 기반 근원	의미	정책적 해석
G ₁	분기비 $n^* = \alpha/\beta$	한 사건당 유발 사건 수. 1에 가까울수록 연쇄 폭발 임박.	>0.8이면 경보. >0.95면 개입 한계.
G ₂	α 행렬의 비대칭성	앵커 브랜드→기타 방향이 역방향보다 강한 정도.	특정 브랜드의 '트리거' 역할 정량화.
G ₃	공간 커널 대역폭 σ 의 시간 변화	영향 범위가 넓어지고 있다면 '번짐' 단계.	인접 동네로의 확산 감시.
G ₄	$\mu(x)$ 와 관측 밀도의 괴리	입지가 예측하는 것보다 실제 사건이 많은 정도.	'자생 이상의 가속'이 있음을 지시.
G ₅	폐점/퇴거 사건의 상대 강도	신규 입점 대비 폐점 비율.	'공동화 단계' 진입 여부.

가중치는 *가로수길의 과거 시계열로 캘리브레이션*한다. 즉 '가로수길이 2기였던 시점, 3기였던 시점'에서 지수가 각 단계에 해당하는 값을 내도록 가중치를 학습. 그 뒤 다른 후보 지역(홍대,

연남동, 익선동, 성수동 등)에 적용.

6.3 지수가 답해야 할 정책 질문

10. 이 동네는 젠트리피케이션의 몇 단계에 있는가? (단계 분류)
11. 앞으로 12개월간 추가로 몇 건의 사건이 예상되는가? (예측)
12. 인접 어느 동네가 다음 타깃인가? (공간적 확산 예측)
13. 만약 앵커 브랜드의 진입을 지연시킨다면, 연쇄는 얼마나 지연되는가? (개입 시나리오)
14. 임대료 상한 같은 정책이 효과를 낼 수 있는 구간(n^* 의 범위)은 어디인가? (정책 효과 한계)

6.4 정책적으로 솔직한 한계

이 지수가 무엇을 할 수 없는지 미리 못 박아둔다.

- **인과가 아닌 연관.** Hawkes 모형은 '사건 A 이후에 사건 B가 더 많다'를 말할 뿐 'A가 B를 야기했다'를 증명하지 않는다. 정책 평가는 반드시 별도의 인과추론(RDD, DID, synthetic control)과 결합되어야 한다.
- **원주민의 목소리는 없다.** 이 모델은 사건의 관측만 다룬다. 누가 떠났고, 어디로 갔으며, 어떤 삶을 잃었는지는 데이터에 없다. 이 지수는 '무엇이 일어났는가'를 측정할 뿐 '누구에게 일어났는가'는 측정하지 않는다. 정책 응용 시 질적 연구와 반드시 결합되어야 한다.
- **가로수길 특이성.** 가로수길을 전범으로 삼은 지수는 가로수길을 닮은 지역에 잘 맞고, 전혀 다른 형태(예: 주거 중심 재개발형 젠트리피케이션)에는 재학습이 필요하다.

6.5 반복적 개선으로서의 지수

완성을 목표로 하지 않는다. v0.1은 최초 프로토타입일 뿐이다. 지자체·활동가·상인과 피드백 루프를 만들어 6개월마다 재조정한다. 이 문서의 서문에서 적은 *수정하고 피드백을 받는다*가 여기서 구체화된다.

6.6 쇠퇴기 α 의 거울 — 신흥 상권의 조기 경고

v0.5 신설. §3.6.8에서 도입한 정책 시뮬레이션의 거울 개념을 지수 설계에 정식으로 편입한다. 이것은 §6.2의 다섯 요소($G_1 \sim G_5$)를 보완하는 여섯 번째 동적 지수로 기능한다.

아이디어

기존 다섯 요소(분기비, α 비대칭, 커널 반경, $\mu(x)$ 괴리, 폐점 강도)는 *현재 관측*에 기반한다. 그러나 신흥 상권의 위험을 가장 필요로 하는 시점은 **관측치가 아직 쌓이기 전**이다. 이미 증상이 나타나면 늦다.

§3.6.8의 시뮬레이션은 이 공백을 메운다. 신흥 상권 L의 *현재까지의 배경율과 초기 이벤트*에, 쇠퇴기가 완료된 참조 상권들의 α 궤적을 주입하여, **조건부 미래를 수치화**한다. 결과는 지수 $G_6(L)$ 로 집약:

$$G_6(L) = \max_{R \in \{\text{가로수길, 경리단, ...}\}} \text{Sim}(\mu^L, \alpha^R, T_{\text{future}})$$

여기서 $\text{Sim}(\cdot)$ 은 해당 조합으로 돌린 시뮬레이션에서 예상되는 *미래 Blue 폐점 사건* 수를 정규화한 값. 여러 참조 상권 중 *가장 불길한 시나리오*를 취함으로써 정책 담당자가 *최악의 경우 계획(worst-case planning)*을 할 수 있게 한다.

활용 예

- **신흥 상권 감시.** 연남동·익선동·망원동 등에 대해 월별 G_6 를 갱신. G_6 가 임계치를 넘으면 현장 실태조사·상인 의견수렴·정책 워크숍을 트리거.
- **다중 시나리오 공개.** 단일 수치가 아니라 '가로수길 각본: N_1건 폐점 예상', '경리단길 각본: N_2건', '홍대 각본: N_3건'을 병렬 제시. 정책 결정자가 각 각본의 가정을 이해한 상태에서 판단.
- **사후 검증 루프.** 예측 시점으로부터 12개월 후, 실제 관측 사건 수와 각 시나리오 예측을 대조. 어느 각본이 가장 근접했는지가 *그 상권이 어느 쇠퇴 궤적에 놓여있는지*를 사후적으로 알려준다. 이는 다시 G_6 의 가중치를 학습하는 데이터가 된다.

조심스러움의 원칙

이 지수는 강력한 만큼 오용 위험이 크다. 자기제한의 원칙 셋을 적어둔다.

- **자기실현 예언 방지.** G₆ 공개 자체가 부동산 투기·언론 과장을 유발해 예측이 실제로 되어버릴 위험. 따라서 G₆는 *공개 대상 제한*(행정·연구 커뮤니티 우선)과 *해석 가이드* *동반* 형태로만 배포.
- **단일 각본 발표 금지.** '성수동은 가로수길이 될 것'이라는 단일 문장은 절대 발표하지 않는다. 항상 복수 각본과 불확실성 구간을 함께.
- **정기 리콜.** 예측이 6개월 내 크게 빗나가면 해당 각본은 일시 철회하고 방법을 재검토. '예측이 맞지 않으면 갱신'이 아니라 '예측이 맞지 않으면 방법을 의심'한다.

7. 한계와 열린 문제

7.1 이 연구가 풀지 못하는 것

- 비정상성(non-stationarity)의 전면적 처리. 2010년의 가로수길과 2020년의 가로수길은 체제가 다르다. Hawkes의 모수 자체가 시간에 따라 변할 수 있으며, 이는 5단계 이후의 주제다.
- 사건 누락. 관측에 잡히지 않은 사건(비공식 임대차 계약 등)이 체계적으로 많으면 추정이 왜곡된다.
- 인과추론의 부재. 앞 절에서 언급.
- 다른 도시·국가로의 일반화. 서울의 토지제도·임대차 제도를 전제로 한 연구. 해외 비교는 별개 과제.
- **다른 도메인으로의 일반화 (v1.5 추가).** 본 연구는 도시 부동산만 다룬다. 그러나 본 연구의 도구가 사건이 시간 위에 흩어진 다른 현상에도 적용 가능성은 §4.4 박스(영화 개봉의 overdispersion)와 §IV.4 박스(영화 흥행 Cox 회귀)에서 시사함. 부록 A에 영화 흥행 사례의 자세한 설계를 두었으며, 본격 적용은 별도 페이퍼 또는 후속 작업으로 분리. 본 연구의 학술적 기여 중 하나는 *도구의 일반성* — 도시 상권 동학에 맞춰 정밀화된 도구가 다른 도메인의 동학 분석에도 출발점이 될 수 있음.

7.2 5단계 이후의 질문들

- 비정상 Hawkes, time-varying $\mu(x,t)$ — μ 를 공간만이 아니라 시공간 함수로 확장.
- 마크(marks) 있는 Hawkes — 각 사건에 '규모', '브랜드 자본' 같은 속성을 붙여 강도에 영향.
- 신경망 기반 커널(Neural Hawkes, Mei & Eisner) — 커널 함수 자체를 유연하게. 다만 해석가능성은 감소. Trade-off 검토 필요.
- Bayesian 접근 — MCMC로 모수 사후분포 전체를 얻어 불확실성 정량화.

7.3 자신에게 남기는 메타 메모

이 로드맵을 작성하는 과정에서 스스로에게 확인한 것들.

- 5번이 정상이 아니라, 5번까지 '모델이 한계를 드러내는 경로'가 본질이다. 이 경로를 잊지 말 것.
- EM이 익숙하지 않다는 점을 기억할 것. 구현은 반드시 합성 데이터 복원 실험부터.
- 정책적 기여와 학술적 기여를 섞지 말 것. 6절에서 명시적으로 분리한 이유가 여기 있다. 섞으면 양쪽 모두 알아진다.
- 6개월에 한 번, 이 문서의 모든 가정과 일정을 재검토한다.

8. 참고문헌 (핵심)

Hawkes 과정의 기초

Hawkes, A. G. (1971). Spectra of some self-exciting and mutually exciting point processes.

Biometrika, 58(1), 83–90.

Ogata, Y. (1978). The asymptotic behaviour of maximum likelihood estimators for stationary point processes. Annals of the Institute of Statistical Mathematics, 30(1), 243–261.

Ogata, Y. (1981). On Lewis' simulation method for point processes. IEEE Transactions on Information Theory, 27(1), 23–31.

Daley, D. J., & Vere-Jones, D. (2003). An Introduction to the Theory of Point Processes, Vol. I–II. Springer.

시공간 Hawkes와 EM 기반 추정 (Mohler 계열)

Mohler, G. O., Short, M. B., Brantingham, P. J., Schoenberg, F. P., & Tita, G. E. (2011). Self-exciting point process modeling of crime. Journal of the American Statistical Association, 106(493), 100–108.

Mohler, G. (2014). Marked point process hotspot maps for homicide and gun crime prediction in Chicago. International Journal of Forecasting, 30(3), 491–497.

Marsan, D., & Lengliné, O. (2008). Extending earthquakes' reach through cascading. Science, 319(5866), 1076–1079.

Veen, A., & Schoenberg, F. P. (2008). Estimation of space-time branching process models in seismology using an EM-type algorithm. Journal of the American Statistical Association, 103(482), 614–624.

Meyer, S., Held, L., & Höhle, M. (2014). Spatio-temporal analysis of epidemic phenomena using the R package surveillance. Journal of Statistical Software, 77(11).

Stomakhin, A., Short, M. B., & Bertozzi, A. L. (2011). Reconstruction of missing data in social networks based on temporal patterns of interactions. Inverse Problems, 27(11), 115013.

네트워크 위의 공간 분석

Okabe, A., & Sugihara, K. (2012). Spatial Analysis Along Networks: Statistical and Computational Methods. Wiley.

Boeing, G. (2017). OSMnx: New methods for acquiring, constructing, analyzing, and visualizing complex street networks. Computers, Environment and Urban Systems, 65, 126–139.

젠트리피케이션과 도시 변화

Smith, N. (1979). Toward a theory of gentrification: A back to the city movement by capital, not people. Journal of the American Planning Association, 45(4), 538–548.

Zukin, S. (2010). Naked City: The Death and Life of Authentic Urban Places. Oxford University Press.

신현방 (2016). 발전주의 도시화와 젠트리피케이션, 그리고 저항. 공간과 사회, 26(3).

최막중·양도식 (2018). 서울 상업젠트리피케이션의 실증 분석. 국토계획.

국내 상업 젠트리피케이션 선행연구 (v0.2에서 4.5절 비교 대상)

이인성·배재흠 (2013). 문화상업가로 활성화 과정에서의 건축물 용도변화: 서울시 가로수길을 대상으로. 한국도시설계학회지 도시설계, 14(5), 127–140.

허자연·정연주·정창무 (2015). 상업공간의 젠트리피케이션 과정 및 사업자 변화에 관한 연구: 경리단길 사례. 서울도시연구, 16(2), 19–33.

김상일·허자연 (2016). 서울시 상업 젠트리피케이션 실태와 정책적 쟁점. 서울연구원.

양희은·손용훈 (2013). 경리단길 창조계급의 유입과정과 문화경관 형성요인. 한국조경학회지, 41(6), 158–170.

이진희 외 (2018). 서울시 상업 젠트리피케이션 관련 연구 및 정책 리뷰 (서울시 젠트리피케이션 종합대책 관련).

상업 젠트리피케이션 지수와 공실률에 대한 탐색적 분석. Journal of Real Estate Analysis, 8(3).
(jrea-8-3-173)

점과정 전산 구현

Bacry, E., Mastromatteo, I., & Muzy, J.-F. (2015). Hawkes processes in finance. Market Microstructure and Liquidity, 1(01), 1550005.

Bacry, E., Bompair, M., Gaïffas, S., & Poulsen, S. (2017). tick: a Python library for statistical learning. arXiv:1707.03003.

Reinhart, A. (2018). A review of self-exciting spatio-temporal point processes and their applications. *Statistical Science*, 33(3), 299–318.

데이터원 (v0.3 §5.5 관련)

행정안전부. 지방행정 인허가 데이터 개방 포털 (LOCALDATA). <https://www.localdata.go.kr>. 2026년 1월 공공데이터포털과 통합.

식품의약품안전처. 식품판매업 인허가 정보 표준데이터. <https://www.data.go.kr>. (일반음식점·휴게음식점·제과점 등)

공간 격자·시각화 (v0.4 §3.1 관련)

Brodsky, I. (2018). H3: Uber's Hexagonal Hierarchical Spatial Index. Uber Engineering. <https://h3geo.org>

Sahr, K., White, D., & Kimerling, A. J. (2003). Geodesic discrete global grid systems. *Cartography and Geographic Information Science*, 30(2), 121–134.

공변량 조건부·비정상 Hawkes (v0.6 §3.7 관련)

Mohler, G. (2014). Marked point process hotspot maps for homicide and gun crime prediction in Chicago. *International Journal of Forecasting*, 30(3), 491–497.

Chiang, W.-H., Liu, X., & Mohler, G. (2022). Hawkes process modeling of COVID-19 with mobility leading indicators and spatial covariates. *International Journal of Forecasting*, 38(2), 505–520.

Meyer, S., & Held, L. (2014). Power-law models for infectious disease spread. *The Annals of Applied Statistics*, 8(3), 1612–1639.

Zhu, S., & Xie, Y. (2022). Spatiotemporal-textual point processes for crime linkage detection. *The Annals of Applied Statistics*, 16(2), 1151–1170.

Reinhart, A. (2018). A review of self-exciting spatio-temporal point processes and their applications. *Statistical Science*, 33(3), 299–318. (§5 covariate-adjusted intensities)

지역 간 부동산 전파 선행 연구 (v0.9 §3.2.6 관련)

- Hyun, D., & Milcheva, S. (2016). Conform or Resist? Spatio-Temporal Spillover Effects of Surrounding Apartment Transactions in a Boom and a Recession. SSRN Working Paper 2844268. <https://ssrn.com/abstract=2844268> [서울 아파트 30,541건, 상승/하락장 spillover 8배 비대칭 — 2단계와 가장 근접한 선행 연구]
- Cotter, J., Gabriel, S. A., & Roll, R. (2011). Integration and Contagion in US Housing Markets. SSRN Working Paper 2017793. <https://ssrn.com/abstract=2017793> [FHFA 지수로 384개 MSA의 contagion — 샌프란시스코가 주변 선행]
- Yunus, N. (2013). A Closer Look at the U.S. Housing Market: Modeling Relationships among Regions. *Real Estate Economics*, 41(3), 542–568.
- Holly, S., Pesaran, M. H., & Yamagata, T. (2010). A spatio-temporal model of house prices in the USA. *Journal of Econometrics*, 158(1), 160–173.
- Holly, S., Pesaran, M. H., & Yamagata, T. (2011). The spatial and temporal diffusion of house prices in the UK. *Journal of Urban Economics*, 69(1), 2–23.
- Pace, R. K., Barry, R., Gilley, O. W., & Sirmans, C. F. (2000). A method for spatial-temporal forecasting with an application to real estate prices. *International Journal of Forecasting*, 16, 229–246. (STAR 모델의 원류)
- Aït-Sahalia, Y., Cacho-Diaz, J., & Laeven, R. J. A. (2015). Modeling financial contagion using mutually exciting jump processes. *Journal of Financial Economics*, 117(3), 585–606. (금융에 multivariate Hawkes 적용)

생존분석·반복 사건·frailty (v1.2 Part IV 관련)

- Kaplan, E. L., & Meier, P. (1958). Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association*, 53(282), 457–481.
- Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society Series B*, 34(2), 187–220.
- Andersen, P. K., & Gill, R. D. (1982). Cox's regression model for counting processes: A large sample study. *The Annals of Statistics*, 10(4), 1100–1120. (Cox 회귀를 반복 사건과 점과정으로 일반화한 정식 프레임 — Part IV §IV.5와 Part V §V.0의 핵심 다리)
- Vaupel, J. W., Manton, K. G., & Stallard, E. (1979). The impact of heterogeneity in individual frailty

- on the dynamics of mortality. *Demography*, 16(3), 439–454. (frailty model의 원류)
- Hougaard, P. (2000). *Analysis of multivariate survival data*. Springer. (frailty와 multivariate survival의 표준 참고서)
- Cox, D. R. (1955). Some statistical methods connected with series of events. *Journal of the Royal Statistical Society Series B*, 17(2), 129–164. (Cox process의 원류 — doubly stochastic Poisson process)
- Møller, J., & Waagepetersen, R. P. (2004). *Statistical inference and simulation for spatial point processes*. Chapman & Hall/CRC. (Cox process와 LGCP의 표준 텍스트)
- Therneau, T. M., & Grambsch, P. M. (2000). *Modeling survival data: Extending the Cox model*. Springer. (Andersen-Gill, frailty, time-varying covariates 등 실무 가이드)

부록 A — 영화 흥행 분석: 도구의 일반성 시연

v1.5 신설. 본 연구의 본문은 도시 부동산을 다룬다. 그러나 본 연구의 도구가 "사건이 시간 위에 흩어진 모든 현상"에 적용 가능하다는 것을 한 도메인 사례로 시연하는 것이 이 부록의 목적. 본격 적용은 별도 페이퍼 또는 후속 작업으로 분리. 이 부록은 §4.4 박스(영화 개봉의 overdispersion)와 §IV.4 박스(영화 흥행 Cox 회귀)를 더 풍부하게 펼친 것.

부록 A의 구성.

- A.1 기존 영화 흥행 통계의 사각지대
- A.2 두 축 분해 — 스크린 수 vs 스크린당 관객 수
- A.3 두 가지 생존분석 — 강도 생존과 공급 생존
- A.4 4사분면 동학 — 진짜 대박 / 와이드 마케팅 실패 / 다양성 영화 성공 / 흥행 실패
- A.5 영화 간 cannibalization과 다변량 Hawkes
- A.6 KOFIC 데이터와 향후 페이퍼 계획

A.1 기존 영화 흥행 통계의 사각지대

관습적 보도 지표.

- 누적 관객 수: "천만 영화", "1,500만 돌파". 가장 흔한 헤드라인.
- 개봉 첫 주말 관객 수: 초기 흥행의 빠른 지표.
- 박스오피스 1위 유지 일수: 경쟁 강도의 간접 지표.

이 지표들의 공통 문제 — 자원 입력 통제 부재.

같은 1,000만 관객이라도 영화 A는 2,500개 스크린에서 4주간 누적, 영화 B는 1,200개 스크린에서 8주간 누적이라면 두 영화의 흥행 강도는 2배 차이:

$$A: 1,000\text{만} / 2,500\text{스크린} = 4,000\text{명/스크린}$$

$$B: 1,000\text{만} / 1,200\text{스크린} = 8,333\text{명/스크린}$$

그러나 보도에서는 둘 다 "천만 영화"로 묶인다. 자원 입력(스크린)이 다른 영화를 같은 기준으

로 비교하는 것 — 이게 누적 관객 수 보도의 사각지대.

정책·산업적 의미.

- 배급사·영화관의 자원 배분 효율성 평가가 누락됨.
- 작은 영화의 스크린당 강한 흥행이 "천만 영화"의 스크린당 약한 흥행보다 폄하되는 착시.
- 정책적으로 "독립영화 지원"의 효과를 측정할 때, 스크린 수가 통제되지 않은 누적 관객 수로는 산업의 다양성을 평가하기 어려움.

A.2 두 축 분해 — 스크린 수 vs 스크린당 관객 수

해결 — 두 축으로 분해.

- **X축:** 스크린 수 (자원 입력 — 배급사·영화관 결정).
- **Y축:** 스크린당 관객 수 (흥행 강도 — 관객 호응의 정량화).

이 두 축으로 모든 영화를 펼쳐 놓으면 **4사분면이 자연스럽게 나타남** — §IV.4 박스의 그림 IV.4.1 참조. 부록에서는 이 분해의 의미를 더 풍부하게 풀어본다.

4사분면의 의미.

- ① **진짜 대박 (와이드 + 강한 흥행)**. <명량>, <극한직업> 등 자원과 호응이 모두 큰 영화. 누적 관객 수 보도가 잘 잡는 영역.
- ② **와이드 마케팅 실패 (와이드인데 약한 흥행)**. 스크린은 많은데 스크린당 관객이 적음. 마케팅 강세 + 입소문 부재. 누적 관객 수로는 "백만 돌파"라고 보도되지만 실제로는 자원 낭비.
- ③ **다양성 영화 성공 (좁은 상영 + 강한 호응)**. 스크린은 적지만 스크린당 관객이 많음. 작은 영화의 큰 성공 — <벌새>, <다음 소희> 같은 사례. 누적 관객 수로는 ②보다 작아 보이지만 실제 흥행 강도는 더 강함.
- ④ **흥행 실패 (좁은 상영 + 약한 호응)**. 자원도 적고 호응도 적음. 시장의 "실패한 영화" 다수가 여기.

②와 ③의 비대칭 — 누적 관객 수가 가리는 것.

②의 누적 관객 수가 ③보다 더 클 수 있다 (스크린 수 차이로). 그러나 흥행 강도(스크린당 관객 수)는 ③이 더 높다. 두 영화의 "성공/실패" 판단이 지표에 따라 정반대:

- 누적 관객 수로 보면: ② > ③ — "②는 백만 돌파 영화, ③은 그저 그런 작은 영화".
- 스크린당 관객 수로 보면: ③ > ② — "③은 작은 영화의 큰 성공, ②는 자원 낭비".
- 정책·산업 평가에서 어느 지표를 쓰느냐가 결정적.

A.3 두 가지 생존분석 — 강도 생존과 공급 생존

두 분석은 서로 다른 질문에 답한다.

(A) 스크린당 관객 수의 생존 — 흥행의 강도가 얼마나 오래 유지되는가.

- "이벤트"의 정의: 스크린당 관객 수가 임계 (예: 1,500명/스크린) 아래로 떨어지는 시점.
- "생존시간"의 정의: 개봉일부터 임계 도달까지의 기간.
- KM 곡선의 의미: "개봉 X주차에 스크린당 관객이 임계 이상으로 유지될 확률". 영화별 비교 가능 — 〈명량〉은 12주차에도 50% 영화가 임계 이상, 평균 영화는 3주차에 50% 떨어짐.
- Cox 회귀: "평론가 평점이 1점 높을 때 임계 도달 위험이 X% 낮아진다" 같은 hazard ratio.

(B) 스크린 수의 생존 — 영화의 공급이 얼마나 오래 유지되는가.

- "이벤트"의 정의: 스크린 수가 0이 되는 시점 (상영 종료).
- "생존시간"의 정의: 개봉일부터 상영 종료까지의 기간.
- KM 곡선의 의미: "개봉 X주차에 영화가 여전히 상영 중일 확률".
- Cox 회귀: "같은 주에 새 영화가 한 편 더 개봉할 때 본 영화의 종료 위험이 49% 올라간다" 같은 cannibalization 효과.

두 분석의 관계.

- **(A)가 (B)를 일으킨다.** 스크린당 관객 수가 임계 아래로 떨어지면 영화관이 다음 주 스크린을 줄임 → (B)의 hazard 증가.
- 그러나 **(A) → (B)의 매핑이 영화관마다 다르다.** 멀티플렉스 체인은 자체 알고리즘으로 결정, 독립 극장은 다른 기준 — frailty term이 자연스러움 (§IV.6).
- **두 분석을 결합하면:** "흥행 강도가 약해진 시점"과 "공급이 끊긴 시점"의 시차가 영화관 결정의 보수성 정도를 보여줌.

A.4 4사분면 동학 — 시간에 따른 위치 이동

§A.2의 4사분면은 *개봉 첫 주말 시점의 정적 분류*. 하지만 영화는 4주, 8주에 걸쳐 4사분면 안을 움직인다. 이 동학이 흥행 분석의 진짜 풍부한 지점.

전형적 궤적.

- ① → ④ 궤적 (정상적 감소): 개봉 첫 주말 ① 진짜 대박 → 시간이 지나며 스크린 수도 줄고 스크린당 관객도 감소 → ④ 영역으로 이동. 모든 영화의 일반적 궤적.
- ② → ④ 궤적 (실패의 가속): 개봉 첫 주말 ② 와이드 마케팅 실패 → 스크린이 빠르게 줄고 ④로 추락. 짧은 상영.
- ③ → ① 궤적 (입소문 성공): 개봉 첫 주말 ③ 다양성 영화 성공 → 입소문으로 스크린 수 증가 → ①로 이동. <벌새>의 일부 사례.
- ③ → ④ 궤적 (소진): 개봉 첫 주말 ③ → 핵심 관객층이 소진되며 ④로 — 작은 영화의 정상 궤적.

궤적 자체가 정보다.

- 두 영화가 같은 누적 관객 수를 기록해도 궤적이 다르면 흥행의 성격이 다름.
- 궤적 분류는 그 자체로 영화 산업 분석의 새 도구.

A.5 영화 간 cannibalization과 다변량 Hawkes

같은 주 개봉작들끼리는 관객 풀을 두고 경쟁한다. 한 영화의 흥행이 다른 영화의 손실을 일으키는 **cannibalization**. 본 연구의 §3.3 다변량 Hawkes α 행렬과 정확히 같은 구조.

영화 cannibalization의 α 행렬.

- 행: 영향받는 쪽 (영화 i의 hazard).
- 열: 영향 주는 쪽 (영화 j의 개봉).
- $\alpha_{i \leftarrow j}$: "영화 j가 개봉할 때 영화 i의 종료 hazard에 미치는 영향".
- 같은 장르일수록 α 큼. 다른 장르(예: 액션 vs 다큐) 사이는 α 작음.

이 분석이 시사하는 것.

- 어느 영화가 개봉할 때 어느 영화가 가장 타격받는가의 정량화.
- 배급 일정 결정의 근거 — "이 영화는 X 영화와 같은 주에 개봉하면 안 됨"의 hazard ratio 정량화.
- 도시 상권의 "브랜드 cannibalization" (§3.3)과 정확히 같은 도구. 도메인이 다를 뿐 모델 구조는 동일.

A.6 KOFIC 데이터와 향후 페이퍼 계획**데이터 가용성.**

- **KOFIC 박스오피스**: 일별 영화별 스크린 수·관객 수·매출 공개. API 제공. 5년치면 1,000편 이상.
- **타임스탬프 정확도**: 일 단위 정확. 부동산 LOCALDATA의 timestamp 보정 문제 (§IV.1)가 영화에서는 거의 무시 가능.
- **공변량 데이터**: 평론가·관객 평점 (네이버, 다음, 왓차), 장르·등급, 배급사 규모, 감독·주연 정보 — 다수 공개.

향후 페이퍼 계획.

- **Stage 1**: §A.2 두 축 분해 + 4사분면 분류. KOFIC 데이터로 5년치 한국 영화 시장의 분포 시각화.
- **Stage 2**: §A.3 두 가지 생존분석. KM·Cox·Andersen-Gill로 흥행 강도 생존과 공급 생존의 hazard ratio 추정.

- **Stage 3:** §A.5 cannibalization 다변량 Hawkes. 같은 주 개봉작들의 α 행렬 추정.
- **Stage 4 (선택):** Cox-Hawkes로 외생적 background(개봉 시즌·휴일·블록버스터 일정)와 내생적 cannibalization 결합.

본 연구와의 관계.

본 연구의 도구가 도메인을 넘나들 수 있다는 것을 시연하는 부록일 뿐, 본격 적용은 *본 연구가 종료된 뒤*의 별도 작업. 그렇지만 부록 A의 설계가 미리 그려져 있다는 사실이 본 연구의 학술적 자기 자리매김에 기여 — "도시 상권에 정밀화된 도구가 영화 흥행에도 적용 가능함을 미리 검증한 연구".

부록 A의 마무리. 본 연구의 본문에서 다루지 않는 영화 흥행이 부록에 살아남아 있는 이유는 단순하다 — "도시의 본성"이라는 책 제목과 부제 "점과정으로 읽는 서울의 상권과 젠트리피케이션"이 약속한 범위는 도시 부동산이지만, 본 연구가 만든 도구의 일반성은 한 도메인을 넘는다. 부록은 그 일반성의 약속을 책 안에 새겨두는 자리다.

— 이 문서는 v1.5이며 2026년 4월 현재 기준이다. v1.0은 v0.9까지의 연구 계획서를 책 《도시의 본성: 코드로 그려낸 공간의 연쇄반응》의 구조로 재편했고, v1.1은 Part IV 생존분석 신설·Part V Cox-Hawkes 격상으로 7개 Part 구조 완성, v1.2는 Part IV를 도구 시퀀스(life table → KM → Cox → AG → Frailty → Cox process)로 재설계하고 1-2~5-2 사례와 매핑, v1.3은 12개 이론적 정합성 지점을 "문제·근거·대안·채택 이유" 네 단계 박스로 본문에 정정, v1.4는 §4 수학 직관 챕터를 인식론적 입문으로 확장(평균·분산·공분산·지수분포·포아송·정규분포·maximum entropy 패턴 인식), v1.5는 영화 흥행 사례를 본문 박스 두 개(§4.4·§IV.4)로 보존하고 부록 A에 자세히 펼침. 개정 이력: v0.2 §3.6(Blue/Red 2×2)·§4.5(기존 연구 비교), v0.3 §5.5(LOCALDATA), v0.4 §3.1(H3·버거지수)·§3.6.6-7(시기별 분해·지역 확장), v0.5 §3.6.6 후반(데이터 기반 reduced set)·§3.6.8(파라미터 전이)·§6.6(시뮬레이션 거울), v0.6 §3.5 말미(5단계의 한계)·§3.7(단계 6 제안)·§4.5.5 한계 7, v0.7 §3.7.1 한계 ④(식별 문제)·§3.7.4 재설계 A 채택, v0.8 §3.2·§3.3(2·3단계 독립 산출물화· α heatmap 킬러 페이지), v0.9 §3.2.6(선행 연구 박스 — 현대우·Milcheva 2016), v1.0 책 구조 재편(7개 Part)·§4 수학 직관 신설(지수감쇠), v1.1 Part IV 생존분석 신설·Part V Cox-Hawkes 격상·Part V→VI(엔트로피)·Part VI→VII(뒷부분), v1.2 Part IV 도구 시퀀스로 재설계 (life table·KM·Cox·AG·Frailty·Cox process)·1-2~5-2 사례 매핑·"무소식이 희소식" 동기 도입·§IV.0 파트 구성 매핑표·§IV.7 5-2 버티는 힘 $\lambda_{survive}(x)$ 킬러 페이지·생존분석 참고문헌, v1.3 12개 이론적 정합성 정정(§IV.5 AG 적용 단위·§IV.7 두 Cox 구분과 spatial frailty 다리·§IV.7 "버티는 힘" 정의 정확화·§IV.1 timestamp 보정 결정성·§IV.6 frailty 분포 식별성·§V.0 AG 등치 강도 조정·§V.1 Mohler 식 정합성·§V.3 Cox-Hawkes 고유 식별 문제·§V.4 결합 형태 선택 근거·§II.6 도구별 진단 확장·§4.5.5 한계 8 hazard ratio 정책 오용), v1.4 §4 수학 직관 챕터를 인식론적 입문으로 확장 (§4.0 이 장의 목적·§4.1 평균·분산·§4.2 공분산과 ρ 의 "1 σ 따라감 비율" 직관 + 산점도 4패널 그림·§4.3 기억 없음 → 지수 분포·§4.4 독립 사건 → 포아송·§4.5 거리 비례 디스카운트 → 정규분포·§4.6 maximum entropy 패턴 인식), v1.5 영화 흥행 분석을 본문 박스 두 개(§4.4 포아송 overdispersion 박스 + §IV.4 Cox 회귀 박스 + 그림 IV.4.1 4사분면 산점도)로 추가하고 자세한

설계는 부록 A로 분리(A.1 누적 관객 수 보도의 사각지대·A.2 두 축 분해·A.3 두 가지 생존분석·A.4 4사분면 동학·A.5 cannibalization 다변량 Hawkes·A.6 KOFIC 데이터 + 후속 페이퍼 계획). 다음 개정은 단계 1의 LOCALDATA 파이프라인 파일럿 완료 시점. 매 개정에서 이전 버전의 예상과 실제 결과를 대조하여 예측 실패의 패턴을 기록한다. 틀리는 방식에서 가장 많이 배운다.